

Hafta 12 — Dizgiler: Yapılar ve Algoritmalar

CEN207 Veri Yapıları (eski adıyla CE205) · Güz 2026–2027

Bu hafta

Öğrenme çıktıları. Bu haftanın sonunda, metin düzenleyicilerin, derleyicilerin, arama motorlarının, yazım denetleyicilerin ve DNA analiz araçlarının altında yatan iki dizgi (string) algoritma ailesini açıklayabilecek, çizebilecek ve uygulayabilecek olacaksınız. Birinci aile **yapılardır (structures)**: bir dizginin bellekte gerçekte nasıl durduğu (bir `char` dizisi artı `'\0'` kuralı, ve bu kuralın olanaklı kıldığı arabellek taşması (buffer overflow) hatası), bir arabelleğin karakterler eklendikçe kendini nasıl **büyütebildiği**, bir **trie**'nin (örnek ağacı) bütün bir sözlüğü, her karakter için bir kenarla nasıl sakladığı, bir **sıkıştırılmış trie (compressed trie / radix ağacı)**'nin uzun dallanmasız zincirleri tek bir alt-dizgi etiketli kenara nasıl topladığı, ve bir **sonek dizisinin (suffix array)** bir metnin her sonekini sıralı listeleyerek "bu örüntü geçiyor mu?" sorusunu bir ikili aramayla nasıl yanıtladığı. İkinci aile **arama (search)**: bir metin ve bir örüntü (pattern) verildiğinde, örüntü metnin neresinde geçer? **Saf (naif, brute-force) arama**'yı ve onun $O(n*m)$ en kötü durumunu göreceksiniz, ardından bu en kötü durumdan her biri farklı bir yolla kaçınan üç daha akıllı algoritmayla tanışacaksınız — metin işaretçisinin hiç geri sarmaması için bir **başarısızlık işlevi (failure function)** önceden hesaplayan **Knuth-Morris-Pratt (KMP)**; ham karakterler yerine her pencerenin ucuz bir **kayan özetini (rolling hash)** karşılaştıran, her özet eşleşmesini **sahte isabetleri (spurious hits)** yakalamak için doğrulayan **Rabin-Karp**; ve her pencereyi sağdan sola tarayıp az önce gördüğüyle ileri atlayan Boyer-Moore'un **kötü karakter kuralı**. Ayrıca aynı arama problemini tek bir geçişte çözen bir kendisiyle-karşılaştırma hilesi olan **Z algoritması**'yla da tanışacaksınız. Son olarak, bu derste ilk kez **dinamik programlama (dynamic programming)** ile, iki klasik dizgi problemi üzerinden tanışacaksınız: **düzenleme uzaklığı (edit distance)** (bir dizgiyi diğerine dönüştürmenin en az sayıda ekleme, silme ve değiştirme) ve **en uzun ortak alt dizi (longest common subsequence)** (iki dizginin sırayla paylaştığı en uzun karakter dizisi). Bu çıktılar ders izlencesinin **ÖÇ.1** (temel veri yapılarını açıklama), **ÖÇ.2** (algoritmik karmaşıklık analiz etme), **ÖÇ.6** (dinamik programlama uygulama) ve **ÖÇ.7** (bir problem için doğru yapıyı seçme) maddelerine karşılık gelir.

Önceden bilmeniz gerekenler. Hafta 1 size diziyi (array) verdi — bir `char` dizisi tam olarak bir C dizgisinin üzerine kurulduğu şeydir. Hafta 2 size bağlı listeyi (linked list) ve çocuklara işaretçileri olan bir düğüm fikrini verdi; bir trie bunu doğrudan yeniden kullanır (bir trie düğümünün "sıradaki karakter" işaretçileri tam olarak genelleştirilmiş bir bağlı yapıdır). Hafta 4 size ağaçları (tree) ve özyinelemeli ağaç dolaşımını verdi, ikisi de trie'ler ve sıkıştırılmış kuzenleri için merkezidir; ayrıca size Huffman kodlamasını verdi — bunu aşağıda sıkıştırılmış trie'lerle açıkça yeniden bağlayacağız. Hafta 6 size hash'lemeyi verdi; Rabin-Karp bunu tek seferlik bir tablo araması yerine *kayan (rolling)* bir hash olarak yeniden kullanır. Hiçbir önceki hafta **dinamik programlamayı** tanıtmadı — bu hafta onu, dersteki her yeni fikrin tanıtıldığı aynı yolla, sıfırdan tanıtıyor: bir soru, çok yavaş kalan saf bir yaklaşım, ve aynı cevabı iki kez asla yeniden hesaplamayarak bunu düzelten bir tablo.

3 saatlik bir oturum için zaman planı. C dizgileri, `'\0'`, `strlen` ve arabellek güvenliği (~15 dk) · büyüyen bir dizgi arabelleği (~10 dk) · trie'ler (~20 dk) · sıkıştırılmış trie'ler / radix ağaçları, Huffman bağlantısıyla (~15 dk) · sonек dizileri (~15 dk) · kısa ara · dizgi eşleştirme problemi ve saf arama (~10 dk) · KMP'nin başarısızlık işlevi (~15 dk) · KMP araması (~15 dk) · Rabin-Karp (~15 dk) · Boyer-Moore'un kötü karakter kuralı (~15 dk) · Z algoritması (~15 dk) · karşılaştırma tablosu (~5 dk) · dinamik programlama ve düzenleme uzaklığı (~20 dk) · en uzun ortak alt dizi (~15 dk) · toplama ve kendini sinama (~10 dk).

0. Başlamadan önce

0.1 Zaten bildikleriniz

Önceki haftalardan üç fikir bu hafta en çok işe yarıyor.


Hafta 1'den — diziler. Bir `char` dizisi bitişik bir bellek bloğudur, `arr[i]` doğrudan `base_address + i` olarak hesaplanır. Bir C dizgisi, üzerine tek bir kural daha eklenmiş bir `char` dizisinden başka bir şey değildir — o kural, ve olanaklı kıldığı hata, bölüm 1'in tüm konusudur.

Hafta 2 ve Hafta 4'ten — bağlı düğümler ve ağaçlar. 26 "sıradaki karakter" işaretçisi olan bir trie düğümü, genelleştirilmiş bir bağlı liste/ağaç düğümüdür: bir `next` (liste) ya da iki çocuk (ikili ağaç) yerine, olası her sıradaki karakter için bir çocuk vardır. Özyinelemeli ekleme, arama ve serbest bırakma, Hafta 4'te ağaçlar için çalıştığı gibi çalışır.

Hafta 6'dan — hash'leme. Bir hash fonksiyonu bir anahtarı $O(1)$ sürede bir sayıya dönüştürür. Rabin-Karp (bölüm 9) aynı fikri yeniden kullanır, ama **yeni bir pencerenin** özetini **önceki pencerenin** özetinden $O(1)$ sürede hesaplar, her seferinde sıfırdan hash'lemek yerine — bir **kayan özet (rolling hash)**.

Bu hafta gerçekten yeni bir fikir: dinamik programlama. Bu haftaya kadarki her algoritma ya bir yapıyı bir kez dolaştı ($O(n)$) ya da bir arama uzayını daralttı ($O(\log n)$). Bölüm 13 ve 14 üçüncü bir strateji tanıtır: bir problemi çıkışan (overlapping) daha küçük alt problemlere bölmek, her birini **yalnız bir kez** çözmek, ve cevabı bir tabloda saklayarak asla yeniden hesaplanmamasını sağlamak. Bu **dinamik programlamadır**, ve düzenleme uzaklığı bunun mümkün olan en temiz örneklerinden biridir.

0.2 Bu haftanın haritası



Aşağıdaki her kutu kendi bölümünü alır, çoğu adım adım bir animasyon, eksiksiz bir C ve Java programı, ve karmaşıklık ile sık yapılan hatalar üzerine bir notla birlikte.

1. C dizgileri: bellek, `'\0'` ve `strlen`

1.1 Başlangıç sorusu

Şimdiye kadarki her veri yapısı *boyutunu* bir yerde sakladı — bir dizinin kapasitesi ayrı bir değişkendi, bir bağlı listenin uzunluğu `next` işaretçileri dolaşarak sayılabilirdi, bir ağacın düğüm sayısı onu dolaşarak geldi. Bir C dizgisi **hiçbir uzunluk alanı saklamaz**. Öyleyse "HELLO" tutan bir `char` dizisi varsa, hangi işlev — `printf`, `strlen`, kendi kodunuz — metnin nerede *bittiğini* nasıl bilir? C'nin cevabı, dilin 1970'lerin başında Bell Labs'ta tasarlandığı sırada seçildi (Dennis Ritchie): tek bir ayrılmış bayt, `'\0'`, NUL karakteri (değeri 0). Bir C dizgisi, bir `char` dizisi artı şu *kural*dır: ilk `'\0'` baytı "dizgi burada bitiyor" der. Ondan önceki her karakter dizginin parçasıdır; ondan sonraki her bayt, dizi gerçekte kaç bayt tutuyor olursa olsun, yalnızca kullanılmayan boşluktur.

1.2 Kural, ve olanaklı kıldığı hata

Uzunluk hiç saklanmadığından, uzunluğu bilmesi gereken *her* işlem **diziyi bayt bayt, '\0' bulana kadar dolaşmak zorundadır** — hiçbir kestirme yol yoktur. `strlen("HELLO")` cevabın 5 olduğunu bir şekilde bilmez; `H, E, L, L, O, \0` okur ve durmadan önce beş '\0'-olmayan bayt sayar. Bir diziyi kopyalamak aynı şekilde çalışır: `strcpy(dest, src)`, `src`'yi bir karakter bir karakter okur ve her birini `dest`'e yazar, ta ki '\0' 'ı da kopyalayana kadar. İşte klasik C hatası burada yatıyor: `dest` sabit boyutlu bir arabellekse ve `src` o arabelleğin tutabileceğinden daha uzunsa, korumasız bir kopyalama arabelleğin son geçerli indisinin ötesine yazmaya devam eder. O tek ekstra yazma **tanımsız davranıştır (undefined behavior, UB)** — arabelleğin hemen ardından bellekte ne yaşadığına bağlı olarak, ilgisiz bir değişkeni, kaydedilmiş bir dönüş adresini sessizce bozabilir ya da programı doğrudan çökertebilir. Bu, yazılım güvenliği tarihinin en sonuçlu hata sınıflarından biri olan **arabellek taşmasıdır (buffer overflow)**. Bu notun animasyonu ve programı, bu taşmaya neden olan *güvenli olmayan* karakter-karakter kopyalama döngüsünü gösterir, ama her yazmayı bir sınır kontrolüyle (`if (i == cap) break;`) korur, böylece gerçek sınır dışı yazma **bayraklanır ve durdurulur, hiç çalıştırılmaz** — hiç gerçekten tetiklemeden tehlikeyi görürsünüz.

1.3 Bellekte nasıl durur, ve kod

```
char buf[CAP];

int i = 0;
while (src[i] != '\0') {
    if (i == CAP) break;          /* would need buf[CAP]: out of bounds -- stop, never write it */
    buf[i] = src[i];
    i++;
}
int overflow = (src[i] != '\0'); /* loop stopped early because of the guard, not '\0' */
if (!overflow) buf[i] = '\0';    /* room guaranteed: i < CAP here */

size_t len = 0;
if (!overflow)
    while (buf[len] != '\0') len++; /* strlen: walk until the terminator */

char[] buf = new char[CAP];

int i = 0;
while (i < src.length()) {
    if (i == CAP) break;          // would need buf[CAP]: out of bounds -- stop, never write it
    buf[i] = src.charAt(i);
    i++;
}
boolean overflow = (i < src.length()); // loop stopped early because of the guard
// (no terminator byte needed in Java -- a String already carries its own length)

int len = 0;
if (!overflow)
    while (len < buf.length && buf[len] != 0) len++;
```

Animasyonu oynatarak her karakterin bir bir kopyalandığını, sonlandırıcının yazıldığını, sonra `strlen`'in aynı arabelleği ikinci bir kez, sıfırdan, uzunluğu yeniden saymak için dolaştığını izleyin.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
---	---	---	---	---	---	---	---	---	---	----	----	----	----	----	----

1. CAP = 16 baytlık bir char dizisi ayrılır. Bir C dizgisi (string) yalnız bu bayt dizisidir -- uzunluk ayrıca saklanmaz; + '\\0' + özel baytı "dizgi burada bitiyor" der.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
---	---	---	---	---	---	---	---	---	---	----	----	----	----	----	----

 i = 0

3. src[0] = 'H' -- \\0 değil, döngü devam eder.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E														

 i = 1

6. buf[1] = 'E' yazılır; i bir artar.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L													

 i = 2

8. buf[2] = 'L' yazılır; i bir artar.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L												

 i = 3

10. buf[3] = 'L' yazılır; i bir artar.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O											

 i = 5

13. src[5] = 'W' -- \\0 değil, döngü devam eder.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W										

 i = 6

15. src[6] = 'O' -- \\0 değil, döngü devam eder.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O									

 i = 7

17. src[7] = 'R' -- \\0 değil, döngü devam eder.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L							

 i = 8

20. buf[8] = 'L' yazılır; i bir artar.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L	D						

 i = 9

22. buf[9] = 'D' yazılır; i bir artar.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L	D	\\0					

 i = 10

24. strlen: len = 0 ile buf[0]'den başlayıp \\0'a kadar sayınız -- uzunluk hiçbir yerde saklı DEĞİLDİR, her seferinde yeniden sayılır.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L	D	\\0					

 i = 10

27. buf[2] = 'L' -- \\0 değil, len = 3.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L	D	\\0					

 i = 10

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L	D	\\0					

 i = 10

29. buf[4] = 'O' -- \0 değil, len = 5.

31. buf[6] = 'O' -- \0 değil, len = 7.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] = [H][E][L][L][O][W][O][R][L][D][\0] i = 10

34. buf[9] = 'D' -- \0 değil, len = 10.

CAP = 16
kaynak metin: "HELLOWORLD" (10 harf)

buf[] = [H][E][L][L][O][W][O][R][L][D][\0] i = 10

36. Bitti: 16 baytlık arabelleğe 10 harf + sonlandırıcı güvenle sığırdı (5 bayt boşta kaldı). strlen her çağırıldığında dizgiyi O(n) baştan tarar.

Seçicide ayrıca **cap=11, tam sığar (0 bayt boşluk)** (zor) ve uç durumları **cap=8, taşma — bayraklanır, hiç çalıştırılmaz** ve **tekrarlı karakter "AAAAAAAAAA"** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi kapasitenizi ve metninizi yazın.

1.4 Dene



Tam program: `c_string_memory.c` / `CStringMemory.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * C string memory: a char array plus the '\0' convention, strlen(), and a buffer-overflow edge
case that is
 * FLAGGED but never executed (no out-of-bounds write is ever performed -- the guard `if (i ==
cap) break;`
 * stops the copy one write before it would happen).
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAX_CAP 16

static char buf[MAX_CAP];

/* Copies src into buf, character by character, but never writes past index cap-1. If src needs
more than
 * cap bytes (cap-1 characters plus the terminator), the copy stops as soon as it WOULD go out of
bounds and
 * *overflow is set to 1 -- the out-of-bounds write is flagged, never executed. Returns the
number of bytes
 * actually written (== cap on overflow, since buf[0..cap-1] are all filled and all valid). */
static int safe_store(const char *src, int cap, int *overflow) {
    int i = 0;
    while (src[i] != '\0') {
        if (i == cap) break;          /* would need buf[cap]: out of bounds -- stop, never write it
*/
        buf[i] = src[i];
        i++;
    }
    *overflow = (src[i] != '\0');
    if (!*overflow) buf[i] = '\0';
    return i;
}

static void run_scenario(const char *label, const char *text, int cap) {
    printf("-- %s --\n", label);
    printf("cap = %d, source = \"%s\" (%d letters)\n", cap, text, (int) strlen(text));
    int overflow = 0;
    int written = safe_store(text, cap, &overflow);
    if (overflow) {
        printf("overflow flagged after %d bytes: buf[%d] would be out of bounds (valid indices
0..%d) -- stopped, never executed\n", written, cap, cap - 1);
    } else {
        size_t len = strlen(buf);
        printf("stored \"%s\", strlen = %zu\n", buf, len);
    }
    printf("\n");
}

int main(void) {
    run_scenario("normal: cap=16, comfortable fit", "HELLOWORLD", 16);
    run_scenario("hard: cap=12, 1 byte of slack", "ALGORITHMS", 12);
    run_scenario("edge: cap=11, exact fit (0 bytes slack)", "ALGORITHMS", 11);
    run_scenario("edge: cap=8, overflow -- flagged, never executed", "STRUCTURES", 8);
    run_scenario("edge: cap=16, repeated character", "AAAAAAAAAA", 16);
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * C string memory: a char array plus the '\0' convention, strlen(), and a buffer-overflow edge
case that is
 * FLAGGED but never executed. Java strings carry their own length, so the overflow danger below
is really a
 * C-only bug; we reproduce the same bounded-array exercise here so the two languages can be
compared side by
 * side, with the identical safety guard.
 * CEN207 Data Structures (formerly CE205)
 */
public class CStringMemory {
    static final int MAX_CAP = 16;
    static char[] buf = new char[MAX_CAP];

    // Copies src into buf, character by character, but never writes past index cap-1. Returns
the number of
    // characters actually written; overflow[0] is set to true if src needed more room than cap
allowed.
    static int safeStore(String src, int cap, boolean[] overflow) {
        int i = 0;
        while (i < src.length()) {
            if (i == cap) break;          // would need buf[cap]: out of bounds -- stop, never write
it
            buf[i] = src.charAt(i);
            i++;
        }
        overflow[0] = (i < src.length());
        return i;
    }

    static void runScenario(String label, String text, int cap) {
        System.out.println("-- " + label + " --");
        System.out.println("cap = " + cap + ", source = \"" + text + "\" (" + text.length() + "
letters)");
        boolean[] overflow = new boolean[1];
        int written = safeStore(text, cap, overflow);
        if (overflow[0]) {
            System.out.println("overflow flagged after " + written + " bytes: buf[" + cap + "]
would be out of bounds (valid indices 0.." + (cap - 1) + ") -- stopped, never executed");
        } else {
            String stored = new String(buf, 0, written);
            System.out.println("stored \"" + stored + "\", strlen = " + stored.length());
        }
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: cap=16, comfortable fit", "HELLOWORLD", 16);
        runScenario("hard: cap=12, 1 byte of slack", "ALGORITHMS", 12);
        runScenario("edge: cap=11, exact fit (0 bytes slack)", "ALGORITHMS", 11);
        runScenario("edge: cap=8, overflow -- flagged, never executed", "STRUCTURES", 8);
        runScenario("edge: cap=16, repeated character", "AAAAAAAAAA", 16);
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x c_string_memory.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: cap=16, comfortable fit --
cap = 16, source = "HELLOWORLD" (10 letters)
stored "HELLOWORLD", strlen = 10

-- hard: cap=12, 1 byte of slack --
cap = 12, source = "ALGORITHMS" (10 letters)
stored "ALGORITHMS", strlen = 10

-- edge: cap=11, exact fit (0 bytes slack) --
cap = 11, source = "ALGORITHMS" (10 letters)
stored "ALGORITHMS", strlen = 10

-- edge: cap=8, overflow -- flagged, never executed --
cap = 8, source = "STRUCTURES" (10 letters)
overflow flagged after 8 bytes: buf[8] would be out of bounds (valid indices 0..7) -- stopped, never
executed

-- edge: cap=16, repeated character --
cap = 16, source = "AAAAAAAAAA" (10 letters)
stored "AAAAAAAAAA", strlen = 10
```

```
javac -Xlint:all CStringMemory.java && java CStringMemory
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı (CStringMemory ve c_string_memory.c aynı metni bayt bayt yazdırır).

1.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. L uzunluğundaki bir dizgiyi bir arabelleğe kopyalamak $O(L)$ 'dir — her karakter tam bir kez dokunulur.

`strlen` de $O(L)$ 'dir, ve önemlisi, **her çağrıldığında** $O(L)$ 'dir, çünkü uzunluk hiçbir yerde ön belleğe alınmaz. `strlen` 'i bir döngü koşulunun içinde çağırmak (`for (i = 0; i < strlen(s); i++)`) sessizce $O(n)$ bir döngüyü $O(n^2)$ 'ye çevirir, çünkü `strlen` her yinelemede tüm dizgiyi yeniden dolaşır — bu, C'deki en yaygın kazara-karesel-süre hatalarından biridir.

⚠ Sık yapılan hatalar

- **Sonlandırıcı için +1 'i unutmak** bir arabelleği boyutlandırırken: 10 karakterlik bir sözcük 10 değil **11** bayt gerektirir (`char buf[11]`) — eksik bayt tam olarak bu bölümün uç durumundaki taşmanın olduğu yerdir.
- **`strlen` 'i bir döngünün koşulunun içinde çağırmak**, sessizce $O(n)$ bir taramayı $O(n^2)$ yapmak. Uzunluğu bir kez hesaplayın, saklayın, saklanan değeri yeniden kullanın.
- **Dizgileri `==` ile karşılaştırmak**, `strcmp` yerine. C'de, iki `char*` değeri üzerinde `==`, *karakterleri* değil *işaretçileri* (adresleri) karşılaştırır — aynı görünen iki dizgi, farklı adreslerde saklanıyorsa, `strcmp` onları doğru şekilde eşit bildirir bile `==` ile eşit çıkmaz.

✓ Kendini sına: `strlen` neden saklı bir alanı doğrudan döndüremez?



Çünkü bir C dizgisi tam olarak şöyle tanımlanır: "bir `char` dizisi artı ilk `'\0'` baytının nerede olduğu" — hiçbir struct, hiçbir uzunluk alanı yoktur, yalnızca ham baytlar. `strlen` 'in uzunluğu *okuyacağı* bir veri kaynağı yoktur; `'\0'` 'ı bulmanın tek yolu her baytı sırayla bir bulunana kadar incelemektir. Bu aynı zamanda uzunluğa ihtiyaç duyan her C dizgi işlevinin (`strcpy`, `strcat`, `strcmp`, ...) neden en az $O(L)$ olduğunun, hiçbir zaman $O(1)$ olamayacağının da nedenidir.

2. Büyüyen bir dizgi arabelleği

2.1 Başlangıç sorusu

Bölüm 1'in `buf[CAP]`'i, tek bir karakter bile yazılmadan önce seçilen *sabit* bir kapasiteye sahipti — ve dolu olduğunda iş bitmişti. Ama bir düzenleyicinin "kutuya yaz" işlemi, ya da bir dizgiyi parça parça oluşturan bir program (`printf` tarzı biçimlendirmeyi ya da bir dosyayı satır satır okumayı düşünün), son uzunluğu önceden bilmez. Ya arabellek, çağırının hiç önceden bir kapasite tahmin etmesine gerek kalmadan, ihtiyaç duyulduğunda **kendini büyütebilseydi**? Bu fikir — `java.lang.StringBuilder`'in, C++'ın `std::string`'inin, Python'ın liste-ekleme mekanizmasının ve Hafta 1'in dinamik dizisinin içinde kullanılır — bu bölümün konusudur.

2.2 Fikir: dolduğunda ikiye katla, ve neden +1 değil de katlama önemli

Büyüyen bir arabellek, ham depolamasının yanında üç sayı tutar: `len` (gerçekte kaç karakter saklandığı), `cap` (mevcut ayırmanın kaç tanesini tutabildiği), ve depolamanın kendisi. Bir karakter eklemek neredeyse her zaman basittir: `buf[len] = c; len++`. İlginç durum `len == cap` olduğunda — arabellek dolu olduğunda — ortaya çıkar. Arabellek o zaman **eski boyutun iki katı, yeni bir blok ayırır**, var olan her karakteri oraya **kopyalar**, ve ancak *o zaman* yeni karakteri yazar. Katlama (sabit bir miktarla, `+1` ya da `+10` gibi, büyütmek yerine) burada kritik tasarım kararıdır: arabellek büyüdükçe kopyalamanın **üstel olarak daha seyrek** gerçekleşmesini garanti eder, ve bu tam olarak, büyümeyi tetikleyen herhangi bir tek eklemeye `O(len)`'e mal olsa da, bir eklemenin *ortalama* maliyetinin `O(1)` olmasını sağlayan şeydir — buna **amorti edilmiş analiz (amortized analysis)** denir, ve bölüm 2.5 bunun neden geçerli olduğunu hesaplar.

2.3 Bellekte nasıl durur, ve kod

```
char *buf = malloc(cap); /* cap = INITCAP */
int len = 0;

void append(char c) {
    if (len == cap) {          /* full: grow before writing */
        cap = cap * 2;
        buf = realloc(buf, cap); /* copies every old byte across */
    }
    buf[len] = c;
    len++;
}

char[] buf = new char[cap]; // cap = INITCAP
int len = 0;

void append(char c) {
    if (len == cap) {          // full: grow before writing
        cap = cap * 2;
        char[] bigger = new char[cap];
        System.arraycopy(buf, 0, bigger, 0, len); // copies every old byte across
        buf = bigger;
    }
    buf[len] = c;
    len++;
}
```

Animasyonu oynatarak arabelleğin dolduğunu, kapasiteye ulaştığını, ve büyüdüğünü izleyin — var olan karakterler "kopyalandı" olarak görünür bir şekilde parlar, sonra satır genişler ve yeni karakter tazece büyümüş boşluğa iner.

cap = 4
len = 0

buf[] =

--	--	--	--

1. cap = 4 baytlık bir arabellek ayrılır (malloc), len = 0.
10 harf sırayla eklenecek: "HELLOWORLD".

cap = 4
len = 1

buf[] =

H			
---	--	--	--

3. buf[0] = 'H'; len bir artar (1).

cap = 4
len = 1

buf[] =

H			
---	--	--	--

4. koşul yanlış (1 != 4) -- büyümeye gerek yok.

cap = 4
len = 2

buf[] =

H	E		
---	---	--	--

6. koşul yanlış (2 != 4) -- büyümeye gerek yok.

cap = 4
len = 3

buf[] =

H	E	L	
---	---	---	--

7. buf[2] = 'L'; len bir artar (3).

cap = 4
len = 4

buf[] =

H	E	L	L
---	---	---	---

9. buf[3] = 'L'; len bir artar (4).

cap = 4
len = 4

buf[] =

H	E	L	L
---	---	---	---

dolu! cap 4 -> 8

10. append('O') -- len == cap (4 == 4), arabellek dolu.
Yeni bir cap = 8 baytlık blok ayrılır ve eski 4 bayt oraya kopyalanır: bu adım O(len).

cap = 8
len = 5

buf[] =

H	E	L	L	O			
---	---	---	---	---	--	--	--

dolu! cap 4 -> 8

12. buf[4] = 'O'; len bir artar (5).

cap = 8
len = 5

buf[] =

H	E	L	L	O			
---	---	---	---	---	--	--	--

13. koşul yanlış (5 != 8) -- büyümeye gerek yok.

cap = 8
len = 6

buf[] =

H	E	L	L	O	W		
---	---	---	---	---	---	--	--

15. koşul yanlış (6 != 8) -- büyümeye gerek yok.

cap = 8
len = 7

buf[] =

H	E	L	L	O	W	O	
---	---	---	---	---	---	---	--

16. buf[6] = 'O'; len bir artar (7).

cap = 8
len = 8

buf[] =

H	E	L	L	O	W	O	R
---	---	---	---	---	---	---	---

18. buf[7] = 'R'; len bir artar (8).

cap = 8
len = 8

buf[] =

H	E	L	L	O	W	O	R
---	---	---	---	---	---	---	---

dolu! cap 8 -> 16

cap = 16
len = 9

buf[] =

H	E	L	L	O	W	O	R	L							
---	---	---	---	---	---	---	---	---	--	--	--	--	--	--	--

dolu! cap 8 -> 16

19. `append('L') -- len == cap (8 == 8)`, arabellek dolu.
Yeni bir `cap = 16` baytlık blok ayrılır ve eski 8 bayt
oraya kopyalanır: bu adım $O(len)$.

21. buf[8] = 'L'; len bir artar (9).

```
cap = 16
len = 9
```

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L							

22. koşul yanlış ($9 \neq 16$) -- büyümeye gerek yok.

```
cap = 16
len = 10
```

buf[] =

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
H	E	L	L	O	W	O	R	L	D						

24. Bitti: 10 harf eklendi, 2 büyüme oldu, son kapasite = 16 (6 bayt boşta). Büyüme ender ve pahalı (O(len)) ama toplamda amorti edilmiş O(1) ekleme sağlar.

Seçicide ayrıca **initCap=2**, art arda çok sayıda büyüme (zor) ve uç durumları **initCap=10**, tam sığar, hiç büyüme yok, **initCap=1**, en küçük olası başlangıç, ve **initCap=9**, tam sınırdaki tek bir büyüme deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi başlangıç kapasitenizi ve metninizi yazın.

2.4 Dene



Tam program: `string_builder.c` / `StringBuilderDemo.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * Growable string buffer: characters are appended one at a time; when full, a new block double
the size is
 * allocated, every existing byte is copied across (realloc), then the new character is written.
Appending is
 * O(1) most of the time and O(len) only on the rare growth step -- amortized O(1) overall.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <stdlib.h>
#include <string.h>

typedef struct {
    char *buf;
    int len;
    int cap;
    int growths;
} Builder;

static void builder_init(Builder *b, int init_cap) {
    b->cap = init_cap;
    b->buf = malloc((size_t) b->cap);
    b->len = 0;
    b->growths = 0;
}

static void builder_append(Builder *b, char c) {
    if (b->len == b->cap) { /* full: grow before writing */
        b->cap = b->cap * 2;
        b->buf = realloc(b->buf, (size_t) b->cap); /* copies every old byte across */
        b->growths++;
    }
    b->buf[b->len] = c;
    b->len++;
}

static void builder_free(Builder *b) {
    free(b->buf);
    b->buf = NULL;
}

static void run_scenario(const char *label, int init_cap, const char *chars) {
    printf("-- %s --\n", label);
    printf("initCap = %d, appending \"%s\" (%d letters)\n", init_cap, chars, (int)
strlen(chars));
    Builder b;
    builder_init(&b, init_cap);
    for (int i = 0; chars[i] != '\0'; i++) builder_append(&b, chars[i]);
    printf("result: \"%.s\", len = %d, finalCap = %d, growths = %d\n\n", b.len, b.buf, b.len,
b.cap, b.growths);
    builder_free(&b);
}

int main(void) {
    run_scenario("normal: initCap=4", 4, "HELLOWORLD");
    run_scenario("hard: initCap=2, many growths back to back", 2, "ALGORITHMSDATA");
    run_scenario("edge: initCap=10, exact fit, no growth at all", 10, "ABCDEFGHJIJ");
    run_scenario("edge: initCap=1, the smallest possible start", 1, "ABCDEFGHJIJ");
    run_scenario("edge: initCap=9, a single growth right at the boundary", 9, "ABCDEFGHJIJ");
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Growable string buffer, built by hand (java.lang.StringBuilder does exactly this internally).
 * Characters
 * are appended one at a time; when full, a new array double the size is allocated, every
 * existing character
 * is copied across, then the new character is written. Amortized O(1) append.
 * CEN207 Data Structures (formerly CE205)
 */
public class StringBuilderDemo {
    static class Builder {
        char[] buf;
        int len;
        int cap;
        int growths;

        Builder(int initCap) {
            cap = initCap;
            buf = new char[cap];
            len = 0;
            growths = 0;
        }

        void append(char c) {
            if (len == cap) { // full: grow before writing
                cap = cap * 2;
                char[] bigger = new char[cap];
                System.arraycopy(buf, 0, bigger, 0, len); // copies every old byte across
                buf = bigger;
                growths++;
            }
            buf[len] = c;
            len++;
        }
    }

    static void runScenario(String label, int initCap, String chars) {
        System.out.println("-- " + label + " --");
        System.out.println("initCap = " + initCap + ", appending \"" + chars + "\" (" +
chars.length() + " letters)");
        Builder b = new Builder(initCap);
        for (int i = 0; i < chars.length(); i++) b.append(chars.charAt(i));
        System.out.println("result: \"" + new String(b.buf, 0, b.len) + "\", len = " + b.len + ",
finalCap = " + b.cap + ", growths = " + b.growths);
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: initCap=4", 4, "HELLOWORLD");
        runScenario("hard: initCap=2, many growths back to back", 2, "ALGORITHMSDATA");
        runScenario("edge: initCap=10, exact fit, no growth at all", 10, "ABCDEFGHJIJ");
        runScenario("edge: initCap=1, the smallest possible start", 1, "ABCDEFGHJIJ");
        runScenario("edge: initCap=9, a single growth right at the boundary", 9, "ABCDEFGHJIJ");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x string_builder.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: initCap=4 --
initCap = 4, appending "HELLOWORLD" (10 letters)
result: "HELLOWORLD", len = 10, finalCap = 16, growths = 2

-- hard: initCap=2, many growths back to back --
initCap = 2, appending "ALGORITHMSDATA" (14 letters)
result: "ALGORITHMSDATA", len = 14, finalCap = 16, growths = 3

-- edge: initCap=10, exact fit, no growth at all --
initCap = 10, appending "ABCDEFGHJIJ" (10 letters)
result: "ABCDEFGHJIJ", len = 10, finalCap = 10, growths = 0

-- edge: initCap=1, the smallest possible start --
initCap = 1, appending "ABCDEFGHJIJ" (10 letters)
result: "ABCDEFGHJIJ", len = 10, finalCap = 16, growths = 4

-- edge: initCap=9, a single growth right at the boundary --
initCap = 9, appending "ABCDEFGHJIJ" (10 letters)
result: "ABCDEFGHJIJ", len = 10, finalCap = 18, growths = 1
```

```
javac -Xlint:all StringBuilderDemo.java && java StringBuilderDemo
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

2.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. Yer varsa tek bir ekleme $O(1)$ 'dir, ender olarak bir büyümeyi tetiklediğinde $O(len)$ 'dir. n karakteri birer birer eklemek, toplamda, n 'e (sıradan yazmalar) artı $1 + 2 + 4 + 8 + \dots + n$ 'e (her büyümede yapılan kopyalama, $2n$ 'i aşmayan bir geometrik seri) mal olur — böylece n ekleme toplam $O(n)$ 'e mal olur, yani ekleme başına **amorti edilmiş** $O(1)$. Bu, Hafta 1'in dinamik dizisiyle aynı argüman ve aynı garantidir.



Sık yapılan hatalar

- **Sabit bir miktarla büyötmek** ($cap = cap + 10$) katlama yerine. Bu, n eklemeyi toplam $O(n^2)$ işe çevirir — $n/10$ büyümeyle, her biri n 'e kadar bayt kopyalayarak, toplam kopyalama $O(n^2/10)$ 'dur, $O(n)$ değil.
- **realloc 'tan sonra işaretçiyi güncellemeyi unutmak** (yalnızca C). `realloc` bloğu yeni bir adrese taşıyabilir; eski adresi referans alan her işaretçi artık sarkıktır ve bir daha kullanılmamalıdır — yalnızca döndürülen işaretçi geçerlidir.
- **len bayt okumak ama len + 1 'den az ayırmak**, arabellek daha sonra bir C dizgisi olarak işlenecekse (bir `'\0'` 'a da ihtiyaç var) — buradaki büyüyen arabellek, tam olarak bu tuzaktan kaçınmak için, bir C dizgisi değil, açık bir `len` 'le ham karakterler saklar.



Kendini sına: katlama neden sabit bir büyüme miktarından daha iyidir?



Katlamayla, tüm büyümeler boyunca kopyalanan toplam bayt sayısı, son boyutla sınırlı geometrik bir seridir ($1 + 2 + 4 + \dots + n/2 < n$). Sabit bir k büyümesiyle, n/k büyüme vardır, ve i 'inci büyüme yaklaşık $i*k$ bayt kopyalar, böylece toplam kabaca $k * (1 + 2 + \dots + n/k) = O(n^2/k)$ 'dir — herhangi bir sabit k için karesel, doğrusal değil. Katlama, tüm kopyalamanın *toplamını* doğrusal tutan şeydir.

3. Trie'ler: her karakter için bir kenar

3.1 Başlangıç sorusu

Diyelim ki koca bir sözlüğü — on binlerce sözcüğü — saklamanız ve iki soruyu hızlıca yanıtlamanız gerekiyor: "X bir sözcük mü?" ve "X öneki ile hangi sözcükler başlıyor?" (tam olarak bir otomatik tamamlama kutusunun ya da bir yazım denetleyicisinin ihtiyaç duyduğu şey). Bir hash tablosu (Hafta 6) birinci soruyu ortalama $O(1)$ sürede yanıtlar, ama ikincisini hiç yanıtlayamaz — hash'leme, benzer anahtarları bilerek ilgisiz hücrelere dağıtır, "ile başlıyor" kavramını yok eder. Ya bunun yerine, bir öneki paylaşan her sözcük, o öneki temsil eden *yolu* da veri yapısı içinde paylaşırdı? Bu **trie**'dir (ad "re**trie**val"dan gelir, ama "tree" ile karışmaması için genellikle "try" diye okunur — Edward Fredkin yapıyı ve adı 1960 tarihli bir makalede tanıttı). Bir trie, **her kenarının bir karakterle etiketlendiği** bir ağaçtır, ve kökten başlayarak bir sözcüğün harflerinin çizdiği kenarları izlemek, o sözcüğün ağaç içindeki yolunu izler.

3.2 Fikir: paylaşılan önekler düğümleri paylaşır

"CAT", sonra "CAR", sonra "CARD", sonra "DOG" 'u boş bir trie'ye ekleyin. "CAT" üç yeni düğüm oluşturur, harf başına bir tane, sonuncusu "sözcük sonu" olarak işaretlenmiş. "CAR", trie'nin ilk iki yeni düğümünü (C, sonra A) "CAT" ile paylaşır — $C \rightarrow A$ kenarları zaten var — ve yalnız bir yepyeni düğüme, R'ye, "son" olarak işaretlenmiş, ihtiyaç duyar. "CARD", $C \rightarrow A \rightarrow R$ 'ı "CAR" ile paylaşır ve bir yeni düğüm, D, ekler. "DOG", diğer üçüyle hiçbir şey paylaşmaz (burada hiçbir sözcük D ile başlamıyor) ve kökten tamamen yeni bir dal oluşturur. Dikkat edin: bir düğüm hem tam bir sözcüğün sonu **hem de** daha uzun bir sözcüğün devamının başlangıcı olabilir — "CAR" 'ın R düğümü, trie D'ye devam ederek "CARD" 'a uzansa bile "son" olarak işaretlidir.

İşlem	Ne yapar	Maliyet
<code>insert(word)</code>	Karakter başına bir kenar izler/oluşturur; son düğümü "son" olarak işaretler	$O(L)$, L = sözcüğün uzunluğu
<code>search(word)</code>	Karakter başına bir kenar izler; yalnız her kenar varsa ve son düğüm "son" ise bulunur	$O(L)$
önek kontrolü	<code>search</code> ile aynı yürüyüş, ama başarı yalnız her kenarın var olmasını gerektirir (son düğümün "son" olması gerekmez)	$O(L)$

Buradaki en önemli tek özellik şudur: her trie işleminin maliyeti **yalnız sözcüğün uzunluğu L 'ye bağlıdır** — trie'nin başka kaç sözcük daha tuttuğuna asla bağlı değildir. 10 sözcüklü bir trie ile 10 milyon sözcüklü bir trie, `search("CAT")` 'i tam olarak aynı sayıda adımda yanıtlar.

3.3 Bellekte nasıl durur, ve kod

```

#define ALPHA 26
typedef struct TrieNode { struct TrieNode *child[ALPHA]; bool isEnd; } TrieNode;

void insert(TrieNode *root, const char *word) {
    TrieNode *cur = root;
    for (int i = 0; word[i] != '\0'; i++) {
        int c = word[i] - 'A';
        if (cur->child[c] == NULL) {
            cur->child[c] = new_node();
        }
        cur = cur->child[c];
    }
    cur->isEnd = true;
}

bool search(TrieNode *root, const char *word, bool *isPrefix) {
    TrieNode *cur = root;
    for (int i = 0; word[i] != '\0'; i++) {
        int c = word[i] - 'A';
        if (cur->child[c] == NULL) {
            *isPrefix = false;
            return false;
        }
        cur = cur->child[c];
    }
    *isPrefix = true;
    return cur->isEnd;
}

static class TrieNode {
    Map<Character, TrieNode> child = new HashMap<>();
    boolean isEnd = false;
}

void insert(TrieNode root, String word) {
    TrieNode cur = root;
    for (char c : word.toCharArray()) {
        if (!cur.child.containsKey(c)) {
            cur.child.put(c, new TrieNode());
        }
        cur = cur.child.get(c);
    }
    cur.isEnd = true;
}







boolean search(TrieNode root, String word, boolean[] isPrefix) {
    TrieNode cur = root;
    for (char c : word.toCharArray()) {
        if (!cur.child.containsKey(c)) {
            isPrefix[0] = false;
            return false;
        }
        cur = cur.child.get(c);
    }
    isPrefix[0] = true;
    return cur.isEnd;
}


```

İki dilin "her karakter için bir kenar"a gerçekten farklı yaklaştığına dikkat edin: C, düğüm başına **sabit 26 hücreli bir dizi** kullanır (hızlı, $O(1)$ arama, ama az çocuklu düğümler için bellek israf eder), yukarıdaki Java sürümü ise düğüm başına bir


HashMap kullanır (belleği gerçek çocuk sayısı ile orantılı tutar, bedeli doğrudan dizi indeksleme yerine bir hash araması olur) — bu dersin dışında da tekrar tekrar karşılaşacağınız gerçek, yaygın bir ödüneşimdir.

Animasyonu oynatarak paylaşılan öneklerin var olan düğümleri yeniden kullandığını, yeni dalların taze düğümler oluşturduğunu, ve aramaların aynı kenarları izleyerek "bulundu", "yalnız önek" ya da "bulunamadı" bildirdiğini izleyin.




insert(CARD)


15. R: $cur \rightarrow child[R]$ zaten var -- ortak önek, yeni düğüm gerekmez.

insert(DOG)


18. insert("DOG") -- köke gideriz, sonra her harf için bir kenar izleriz.

insert(DOG)

20. O: $cur \rightarrow child[O]$ boştu (NULL) -- yeni bir düğüm oluşturulur.

search(CAR)


23. search("CAR") -- köke gideriz, harf harf kenar izleriz.

search(CAR)

25. A: kenar var -- devam ederiz.


search(CAR)

tam sözcük -- bulundu



27. Tüm harfler bir kenar buldu VE son düğüm isEnd -- "CAR" bulundu.


search(CARS)



30. A: kenar var -- devam ederiz.


search(CARS)

kenar yok -- yol kırıldı




32. S: cur->child[S] NULL -- yol burada kırılıyor. bulunamadı, ve örnek de değil.

search(DO)



35. O: kenar var -- devam ederiz.



37. Bitti: 4 sözcük eklendi, 3 arama yapıldı (1 bulundu). Her işlem, sözcüğün uzunluğu L ile $O(L)$ -- trie boyutundan (kaç sözcük olduğundan) bağımsız.

Seçicide ayrıca **TRIE sözcük ailesi**: **TRIE, TRIED, TRIES, TRY, TRUE, TRUCK** (zor) ve uç durumları **hiç paylaşılan örnek yok, yinelenen bir ekleme (değişmez)**, ve **dallanmasız bir zincir**: **A, AB, ABC, ABCD** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi sözcüklerinizi ve aramalarınızı yazın.

3.4 Dene



Tam program: `trie_insert_search.c` / `TrieInsertSearch.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * Trie (prefix tree): insert and search, one edge per character, a fixed 26-letter alphabet
 * array per node.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdbool.h>
#include <stdio.h>
#include <stdlib.h>

#define ALPHA 26

typedef struct TrieNode {
    struct TrieNode *child[ALPHA];
    bool is_end;
} TrieNode;

static TrieNode *new_node(void) {
    TrieNode *n = malloc(sizeof(TrieNode));
    for (int i = 0; i < ALPHA; i++) n->child[i] = NULL;
    n->is_end = false;
    return n;
}

static void insert(TrieNode *root, const char *word) {
    TrieNode *cur = root;
    for (int i = 0; word[i] != '\0'; i++) {
        int c = word[i] - 'A';
        if (cur->child[c] == NULL)
            cur->child[c] = new_node();
        cur = cur->child[c];
    }
    cur->is_end = true;
}

static bool search(TrieNode *root, const char *word, bool *is_prefix) {
    TrieNode *cur = root;
    for (int i = 0; word[i] != '\0'; i++) {
        int c = word[i] - 'A';
        if (cur->child[c] == NULL) {
            *is_prefix = false;
            return false;
        }
        cur = cur->child[c];
    }
    *is_prefix = true;
    return cur->is_end;
}

static void free_trie(TrieNode *n) {
    if (n == NULL) return;
    for (int i = 0; i < ALPHA; i++) free_trie(n->child[i]);
    free(n);
}

static void run_scenario(const char *label, const char *const words[], int nwords, const char
*const queries[], int nqueries) {
    printf("-- %s --\n", label);
    TrieNode *root = new_node();
    for (int i = 0; i < nwords; i++) {
        insert(root, words[i]);
        printf("insert(%s)\n", words[i]);
    }
    for (int i = 0; i < nqueries; i++) {
        bool is_prefix = false;

```

```
        bool found = search(root, queries[i], &is_prefix);
        printf("search(%s) -> found=%s, isPrefix=%s\n", queries[i], found ? "true" : "false",
is_prefix ? "true" : "false");
    }
    free_trie(root);
    printf("\n");
}

int main(void) {
    const char *const w1[] = {"CAT", "CAR", "CARD", "DOG"};
    const char *const q1[] = {"CAR", "CARS", "DO"};
    run_scenario("normal: CAT, CAR, CARD, DOG; search CAR/CARS/DO", w1, 4, q1, 3);

    const char *const w2[] = {"TRIE", "TRIED", "TRIES", "TRY", "TRUE", "TRUCK"};
    const char *const q2[] = {"TRIE", "TR", "TRUCKS", "TRY", "TRUST"};
    run_scenario("hard: the TRIE word family, 5 searches", w2, 6, q2, 5);

    const char *const w3[] = {"AB", "CD", "EF", "GH", "IJ"};
    const char *const q3[] = {"AB", "XY", "A"};
    run_scenario("edge: no shared prefix, every word branches from the root", w3, 5, q3, 3);

    const char *const w4[] = {"DATA", "DATA", "STRUCTURE"};
    const char *const q4[] = {"DATA", "DAT", "STRUCTURES"};
    run_scenario("edge: duplicate insert of DATA (idempotent)", w4, 3, q4, 3);

    const char *const w5[] = {"A", "AB", "ABC", "ABCD"};
    const char *const q5[] = {"A", "ABCD", "ABCDE"};
    run_scenario("edge: a branchless chain A, AB, ABC, ABCD", w5, 4, q5, 3);

    return 0;
}
```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Trie (prefix tree): insert and search, one edge per character, a HashMap of children per node.
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.HashMap;
import java.util.Map;

public class TrieInsertSearch {
    static class TrieNode {
        Map<Character, TrieNode> child = new HashMap<>();
        boolean isEnd = false;
    }

    static void insert(TrieNode root, String word) {
        TrieNode cur = root;
        for (char c : word.toCharArray()) {
            if (!cur.child.containsKey(c))
                cur.child.put(c, new TrieNode());
            cur = cur.child.get(c);
        }
        cur.isEnd = true;
    }

    static boolean search(TrieNode root, String word, boolean[] isPrefix) {
        TrieNode cur = root;
        for (char c : word.toCharArray()) {
            if (!cur.child.containsKey(c)) {
                isPrefix[0] = false;
                return false;
            }
            cur = cur.child.get(c);
        }
        isPrefix[0] = true;
        return cur.isEnd;
    }

    static void runScenario(String label, String[] words, String[] queries) {
        System.out.println("-- " + label + " --");
        TrieNode root = new TrieNode();
        for (String w : words) {
            insert(root, w);
            System.out.println("insert(" + w + ")");
        }
        for (String q : queries) {
            boolean[] isPrefix = new boolean[1];
            boolean found = search(root, q, isPrefix);
            System.out.println("search(" + q + ") -> found=" + found + ", isPrefix=" +
isPrefix[0]);
        }
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: CAT, CAR, CARD, DOG; search CAR/CARS/DO",
            new String[]{"CAT", "CAR", "CARD", "DOG"}, new String[]{"CAR", "CARS", "DO"});

        runScenario("hard: the TRIE word family, 5 searches",
            new String[]{"TRIE", "TRIED", "TRIES", "TRY", "TRUE", "TRUCK"},
            new String[]{"TRIE", "TR", "TRUCKS", "TRY", "TRUST"});

        runScenario("edge: no shared prefix, every word branches from the root",
            new String[]{"AB", "CD", "EF", "GH", "IJ"}, new String[]{"AB", "XY", "A"});

        runScenario("edge: duplicate insert of DATA (idempotent)",

```

```
        new String[]{"DATA", "DATA", "STRUCTURE"}, new String[]{"DATA", "DAT",  
        "STRUCTURES"}));  
  
        runScenario("edge: a branchless chain A, AB, ABC, ABCD",  
        new String[]{"A", "AB", "ABC", "ABCD"}, new String[]{"A", "ABCD", "ABCDE"});  
    }  
}
```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x trie_insert_search.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: CAT, CAR, CARD, DOG; search CAR/CARS/DO --
insert(CAT)
insert(CAR)
insert(CARD)
insert(DOG)
search(CAR) -> found=true, isPrefix=true
search(CARS) -> found=false, isPrefix=false
search(DO) -> found=false, isPrefix=true

-- hard: the TRIE word family, 5 searches --
insert(TRIE)
insert(TRIED)
insert(TRIES)
insert(TRY)
insert(TRUE)
insert(TRUCK)
search(TRIE) -> found=true, isPrefix=true
search(TR) -> found=false, isPrefix=true
search(TRUCKS) -> found=false, isPrefix=false
search(TRY) -> found=true, isPrefix=true
search(TRUST) -> found=false, isPrefix=false

-- edge: no shared prefix, every word branches from the root --
insert(AB)
insert(CD)
insert(EF)
insert(GH)
insert(IJ)
search(AB) -> found=true, isPrefix=true
search(XY) -> found=false, isPrefix=false
search(A) -> found=false, isPrefix=true

-- edge: duplicate insert of DATA (idempotent) --
insert(DATA)
insert(DATA)
insert(STRUCTURE)
search(DATA) -> found=true, isPrefix=true
search(DAT) -> found=false, isPrefix=true
search(STRUCTURES) -> found=false, isPrefix=false

-- edge: a branchless chain A, AB, ABC, ABCD --
insert(A)
insert(AB)
insert(ABC)
insert(ABCD)
search(A) -> found=true, isPrefix=true
search(ABCD) -> found=true, isPrefix=true
search(ABCDE) -> found=false, isPrefix=false
```

```
javac -Xlint:all TrieInsertSearch.java && java TrieInsertSearch
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

3.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. `insert`, `search`, ve bir önek kontrolü hepsi sözcüğün uzunluğu L 'de $O(L)$ 'dir, n 'den, **şu anda kaç sözcük saklandığından bağımsız olarak** — bir trie'nin sıralı bir dizi ya da dengeli bir ağaç üzerindeki en büyük avantajı, ikisi de $O(L * \log n)$ 'e mal olur ($O(\log n)$ karşılaştırmanın her biri, iki dizgiyi karşılaştırmak için kendisi $O(L)$ 'ye kadar mal olabilir). Bedel bellektir: C tarzı düğüm başına 26-hücreli diziyile bir trie, sözcüklerin kendisinin ihtiyacı duyduğundan çok daha fazla

bellek kullanabilir, özellikle çoğu düğümün yalnız bir ya da iki gerçek çocuğu olduğu ağacın derinliklerinde — tam olarak bölüm 4'ün sıkıştırılmış trie'sinin ortadan kaldırdığı israf.

⚠ Sık yapılan hatalar

- **"Bulundu"yu "bir önektir" ile karıştırmak.** Sorgunun sonuna gerçek kenarları izleyerek ulaşmak yalnız sorgunun saklı bir şeyin **öneki** olduğunu kanıtlar; yalnız o son düğüm de `isEnd` olarak işaretliyse tam bir **sözcüktür**. `search("CAR")` ve `search("CARP")`, "CARPET" tutan bir trie'de aynı ilk üç kenarı izler, ama yalnız biri saklı bir sözcüktür.
- **Bir düğümün hem `isEnd` hem de çocuklu olabileceğini unutmak.** "CAR" 'ın tam bir sözcük olması, "CARD" 'ın da bir sözcük olmasını engellemez — yaygın bir hata, sonraki kodun "çocukları var" ile "tam bir sözcük" ün birbirini dışladığını varsaydığı yerde bir düğümün `isEnd` bayrağını yanlış işler ya da siler.
- **Trie'yi hiç serbest bırakmamak (yalnız C).** Her `new_node()` çağrısı bir `malloc` 'tur; her çocuğu ebeveyn serbest bırakılmadan önce ziyaret eden özyinelemeli bir `free_trie` olmadan, uzun süre çalışan bir program belleği bir düğüm bir düğüm sızdırır.

✓ Kendini sına: bir trie'nin maliyeti neden kaç sözcük tuttuğundan bağımsızdır? ✓

Çünkü her işlemin işi tam olarak "sorgunun her karakteri için bir kenar izle"dir — trie'nin başka bir yerinde saklı *diğer* sözcüklerin sayısı bu yürüyüşe hiç girmez. Bir hash tablosunun ortalama $O(1)$ araması *istatistiksel* bir garantidir (kötü hash'leme ya da yüksek yükte kötüleşebilir); bir trie'nin $O(L)$ sınırı doğrudan şeklinin bir sonucudur ve herhangi bir n için koşulsuz olarak geçerlidir.

4. Sıkıştırılmış trie'ler (radix ağaçları)

4.1 Başlangıç sorusu

Boş bir düz trie'ye yalnız tek uzun bir sözcük, diyelim "INTERNATIONAL" (13 harf) ekleyin. Bu **13 yeni düğüm** oluşturur, her birinin yalnız bir çocuğu vardır — hiç dallanması olmayan uzun, ince bir zincir, tam olarak bir bağlı liste gibi. Prensip tek bir 13 karakterlik dizgi olarak saklanabilecek bir şeyi temsil etmek için çok fazla bellek ve çok fazla işaretçi izleme. Ya bir kenar tek bir karakter yerine bütün bir **alt-dizgi** taşıyabilseydi, ve düğümler yalnız trie'nin gerçekten **dallandığı** yerlerde var olmak zorunda kalsaydı? Bu **sıkıştırılmış trie, radix ağacı** ya da klasik biçiminde **PATRICIA trie** de denir (Donald R. Morrison, 1968 — ad "Practical Algorithm To Retrieve Information Coded In Alphanumeric" in kısaltmasıdır). Bu, düz bir trie'nin kullandığı aynı fikirdir, her maksimal dallanmasız zincir tek bir kenara toplanmış hali.

4.2 Fikir: uzat, oluştur ya da böl

Sıkıştırılmış bir trie'ye bir sözcük eklemek kökten karakter karakter yürür, ama artık tek karakterler yerine bütün **kenar etiketleriyle** karşılaştırır, ve her kenarda üç şeyden biri olabilir:

1. **Sözcüğün kalan soneki kenar etiketiyle tam olarak eşleşir.** Onu geçip inin ve sözcükten kalanla devam edin (belki hiçbir şey kalmamıştır, bu durumda kenarın götürdüğü düğüm yalnız "son" olarak işaretlenir).
2. **Sözcüğün sıradaki karakteriyle başlayan hiçbir kenar yoktur.** Kalan sonek tamamen yeni bir yaprak kenar olur — tam olarak düz bir trie gibi, yalnız tek bir harf yerine bütün bir alt-dizgi tutar.
3. **Sözcük var olan bir kenarın etiketiyle yalnız kısmi bir önek paylaşır.** Kenar **bölünür**: paylaşılan öneki tutan yeni bir dallanma düğümü belirir, eski kenarın (şimdi kısaltılmış) kalanı ve yeni sözcüğün kalanı onun iki çocuğu olur.

Durum 3 burada gerçekten yeni olan fikirdir. "TEST" i boş bir trie'ye ekleyin: "TEST" etiketli tek bir yaprak kenar. Şimdi "TEA" yı ekleyin: bu, ayrılmadan önce (S ile A) var olan "TEST" kenarıyla yalnız "TE" yi paylaşır, böylece "TEST" kenarı bölünür — "TE" tutan yeni bir düğüm belirir, iki çocuğuyla: eski düğüm (artık kısaltılmış "ST" kenarıyla ulaşılır) ve kalan "A" için yepyeni bir düğüm.

4.3 Hafta 4'e bağlantı: bir ağacı küçültmenin iki farklı yolu

Şimdi bir ağacı fazlalığı kaldırarak küçültmenin **iki** tamamen farklı tekniğiyle, iki farklı haftada tanıştınız, ve aradaki farkı açıkça adlandırmaya değer. Hafta 4'ün **Huffman kodlaması**, sık simgeleri ucuz (kısa bir kök-yaprak yolu) ve *nadir* simgeleri pahalı yapacak şekilde seçilmiş bir *şekle* sahip bir ağaç kurar — çarpık bir **olasılık dağılımını** simgeler üzerinde sömürerek sıkıştırır. Bu haftanın **sıkıştırılmış trie**'si tamamen farklı bir fazlalık türünü sıkıştırır: çarpık sıklıklar değil, saklanan gerçek karakter dizilerinin belirlediği bir şekildeki **uzun dallanmasız zincirler**, her birinin ne kadar sık geçtiğinden bağımsız olarak. Başka bir deyişle: Huffman kodlaması "en sık gördüğüm simgeler için sembol başına *daha az bit* nasıl kullanırım?" diye sorar; sıkıştırılmış bir trie "başka hiçbir yere dallanma olmayan uzun bir uzanım için her tek karakter için bir ağaç düğümü saklamaktan nasıl kaçınırım?" diye sorar. İkisi de bu dersten ağaç sıkıştırma fikirleridir, ve ikisi de küçük bir ekstra defter tutma (kanonik bir kod tablosu; tek bir karakter yerine bir kenar etiketi) karşılığında gerçek bir yapısal tasarruf sağlar — ama temelde farklı şeyleri sıkıştırırlar.

4.4 Bellekte nasıl durur, ve kod

```
typedef struct RNode {
    char *label;          /* edge INTO this node; root's label is "" */
    bool isEnd;
    struct RNode *child[26]; /* indexed by the first letter of each child edge */
} RNode;

int common_prefix_len(const char *a, const char *b) {
    int j = 0;
    while (a[j] && b[j] && a[j] == b[j]) j++;
    return j;
}

void insert(RNode *node, const char *word) {
    int i = 0;
    while (word[i] != '\0') {
        int c = word[i] - 'A';
        if (node->child[c] == NULL) {
            node->child[c] = new_leaf(word + i); /* whole remaining suffix */
            return;
        }
        RNode *child = node->child[c];
        int j = common_prefix_len(word + i, child->label);
        if (j == (int) strlen(child->label)) { /* whole edge matches: descend */
            node = child; i += j;
            if (word[i] == '\0') { node->isEnd = true; return; }
            continue;
        }
        RNode *mid = split_edge(node, child, j); /* new node at the mismatch */
        if (word[i + j] == '\0') { mid->isEnd = true; return; }
        mid->child[word[i + j] - 'A'] = new_leaf(word + i + j);
        return;
    }
}
```

```

static class RNode {
    String label;           // edge INTO this node; root's label is ""
    boolean isEnd;
    Map<Character, RNode> child = new HashMap<>();
}

void insert(RNode node, String word) {
    int i = 0;
    while (i < word.length()) {
        char c = word.charAt(i);
        if (!node.child.containsKey(c)) {
            node.child.put(c, newLeaf(word.substring(i))); // whole remaining suffix
            return;
        }
        RNode child = node.child.get(c);
        int j = commonPrefixLen(word.substring(i), child.label);
        if (j == child.label.length()) { // whole edge matches: descend
            node = child; i += j;
            if (i == word.length()) { node.isEnd = true; return; }
            continue;
        }
        RNode mid = splitEdge(node, child, j); // new node at the mismatch
        if (i + j == word.length()) { mid.isEnd = true; return; }
        mid.child.put(word.charAt(i + j), newLeaf(word.substring(i + j)));
        return;
    }
}

```

Animasyonu oynatarak bir kenarın oluşturulduğunu, uzatıldığını, ya da bölündüğünü izleyin — paylaşılan örnek, iki sözcüğün ilk uyuşmadığı tam karakterde kendi dallanma düğümüne çekilir.




1. Boş bir sıkıştırılmış trie: yalnız kök var. Her kenar bir alt DİZİ taşıyacak, tek bir harf değil.

insert(TEST)




2. insert("TEST") -- köke gideriz.

insert(TEA)



4. insert("TEA") -- köke gideriz.

insert(TEA)




5. Ortak önek yalnız "TE" (uzunluk 2), kenar etiketinden kısa -- kenar burada BÖLÜNÜR: yeni bir dallanma düğümü oluşur.

insert(TEAM)




insert(TEAM)






7. insert("TEAM") -- köke gideriz.




8. TE" kenarı tamamen eşleşiyor (ortak önek uzunluğu 2) -- aşağı ineriz.

insert(TEAM)




10. M' ile başlayan kenar yok -- kalan "M" tamamı yeni bir yaprak kenar olur. Bitti.

search(TEA)



11. search("TEA") -- köke gideriz.


search(TEA)




13. edge "A" tamamen eşleşiyor -- devam ederiz.

search(TEA)

tam sözcük -- bulundu




14. Tüm kenarlar tükendi VE düğüm isEnd -- "TEA" bulundu.

search(TE)


16. edge "TE" tamamen eşleşiyor -- devam ederiz.

search(TE)


örnek, ama tam sözcük değil



17. Tüm kenarlar tükendi ama düğüm isEnd değil -- "TE" bir örnek, tam sözcük değil.

search(TEAMS)



19. edge "TE" tamamen eşleşiyor -- devam ederiz.


search(TEAMS)

20. edge "A" tamamen eşleşiyor -- devam ederiz.


search(TEAMS)

kenar yok





22. S' ile başlayan kenar yok -- bulunamadı, önek de değil.



23. Bitti: 3 sözcük eklendi, 3 arama (1 bulundu). Bölünmeler sayesinde düğüm sayısı sözcüklerin toplam harf sayısından çok daha az kalır.

Seçicide ayrıca **ROMAN sözcük ailesi: ROMAN, ROMANE, ROMANUS, ROMULUS** (zor, art arda birkaç bölünme) ve uç durumları **hiç paylaşılan önek yok, CAR'ın kendisi CARPET ve CARD'ın öneki**, ve **ANT, ARM, ART, AXE — iç içe bölünmeler** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi sözcüklerinizi ve aramalarınızı yazın.

4.5 Dene



Tam program: `compressed_trie.c` / `CompressedTrie.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * Compressed trie (radix tree): each edge carries a whole substring; a new word either extends
an existing
 * edge, becomes a brand-new leaf edge, or SPLITS an existing edge at the point where it first
diverges.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdbool.h>
#include <stdio.h>
#include <stdlib.h>
#include <string.h>

#define ALPHA 26

typedef struct RNode {
    char *label;           /* edge INTO this node; root's label is "" */
    bool is_end;
    struct RNode *child[ALPHA]; /* indexed by the first letter of each child edge */
} RNode;

static char *dup_str(const char *s, int len) {
    char *r = malloc((sizeof(size_t) len + 1));
    memcpy(r, s, (sizeof(size_t) len));
    r[len] = '\0';
    return r;
}

static RNode *new_node(const char *label, int label_len, bool is_end) {
    RNode *n = malloc(sizeof(RNode));
    n->label = dup_str(label, label_len);
    n->is_end = is_end;
    for (int i = 0; i < ALPHA; i++) n->child[i] = NULL;
    return n;
}

static int common_prefix_len(const char *a, const char *b) {
    int j = 0;
    while (a[j] && b[j] && a[j] == b[j]) j++;
    return j;
}

static void insert(RNode *node, const char *word) {
    if (word[0] == '\0') { node->is_end = true; return; } /* the empty word ends exactly at
this node */
    int i = 0;
    while (word[i] != '\0') {
        int c = word[i] - 'A';
        if (node->child[c] == NULL) {
            node->child[c] = new_node(word + i, (int) strlen(word + i), true); /* whole
remaining suffix */
            return;
        }
        RNode *child = node->child[c];
        int label_len = (int) strlen(child->label);
        int j = common_prefix_len(word + i, child->label);
        if (j == label_len) { /* whole edge matches: descend */
            node = child;
            i += j;
            if (word[i] == '\0') { node->is_end = true; return; }
            continue;
        }
        /* split: a new node holds the shared prefix; child keeps only its tail */
        RNode *mid = new_node(child->label, j, false);
        char *tail = dup_str(child->label + j, label_len - j);
    }
}

```

```

        free(child->label);
        child->label = tail;
        mid->child[(unsigned char) (child->label[0] - 'A')] = child;
        node->child[c] = mid;
        if (word[i + j] == '\0') {
            mid->is_end = true;                /* the inserted word ends exactly at the split
point */
            return;
        }
        mid->child[word[i + j] - 'A'] = new_node(word + i + j, (int) strlen(word + i + j), true);
        return;
    }
}

static bool search(RNode *root, const char *word, bool *is_prefix) {
    RNode *node = root;
    int i = 0;
    while (word[i] != '\0') {
        int c = word[i] - 'A';
        if (node->child[c] == NULL) {
            *is_prefix = false;
            return false;
        }
        RNode *child = node->child[c];
        int label_len = (int) strlen(child->label);
        int j = common_prefix_len(word + i, child->label);
        if (j < label_len) {
            *is_prefix = (word[i + j] == '\0');
            return false;
        }
        node = child;
        i += j;
    }
    *is_prefix = true;
    return node->is_end;
}

static void free_radix(RNode *n) {
    if (n == NULL) return;
    for (int i = 0; i < ALPHA; i++) free_radix(n->child[i]);
    free(n->label);
    free(n);
}

static void run_scenario(const char *label, const char *const words[], int nwords, const char
*const queries[], int nqueries) {
    printf("-- %s --\n", label);
    RNode *root = new_node("", 0, false);
    for (int i = 0; i < nwords; i++) {
        insert(root, words[i]);
        printf("insert(%s)\n", words[i]);
    }
    for (int i = 0; i < nqueries; i++) {
        bool is_prefix = false;
        bool found = search(root, queries[i], &is_prefix);
        printf("search(%s) -> found=%s, isPrefix=%s\n", queries[i], found ? "true" : "false",
is_prefix ? "true" : "false");
    }
    free_radix(root);
    printf("\n");
}

int main(void) {
    const char *const w1[] = {"TEST", "TEA", "TEAM"};

```

```
const char *const q1[] = {"TEA", "TE", "TEAMS"};
run_scenario("normal: TEST, TEA, TEAM -- one edge splits in two", w1, 3, q1, 3);

const char *const w2[] = {"ROMAN", "ROMANE", "ROMANUS", "ROMULUS"};
const char *const q2[] = {"ROMAN", "ROM", "ROMANEQ", "ROMULUS"};
run_scenario("hard: the ROMAN word family -- several splits back to back", w2, 4, q2, 4);

const char *const w3[] = {"APPLE", "BANANA"};
const char *const q3[] = {"APPLE", "AP"};
run_scenario("edge: no shared prefix, every word is a single long edge", w3, 2, q3, 2);

const char *const w4[] = {"CAR", "CARPET", "CARD"};
const char *const q4[] = {"CAR", "CARP", "CARPET"};
run_scenario("edge: CAR is a prefix of CARPET and CARD", w4, 3, q4, 3);

const char *const w5[] = {"ANT", "ARM", "ART", "AXE"};
const char *const q5[] = {"ART", "AR", "ARK"};
run_scenario("edge: ANT, ARM, ART, AXE -- splits nested inside splits", w5, 4, q5, 3);

return 0;
}
```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Compressed trie (radix tree): each edge carries a whole substring; a new word either extends
an existing
 * edge, becomes a brand-new leaf edge, or SPLITS an existing edge at the point where it first
diverges.
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.HashMap;
import java.util.Map;

public class CompressedTrie {
    static class RNode {
        String label; // edge INTO this node; root's label is ""
        boolean isEnd;
        Map<Character, RNode> child = new HashMap<>();
        RNode(String label, boolean isEnd) { this.label = label; this.isEnd = isEnd; }
    }

    static int commonPrefixLen(String a, String b) {
        int j = 0;
        while (j < a.length() && j < b.length() && a.charAt(j) == b.charAt(j)) j++;
        return j;
    }

    static void insert(RNode node, String word) {
        if (word.isEmpty()) { node.isEnd = true; return; } // the empty word ends exactly at
this node
        int i = 0;
        while (i < word.length()) {
            char c = word.charAt(i);
            if (!node.child.containsKey(c)) {
                node.child.put(c, new RNode(word.substring(i), true)); // whole remaining
suffix
                return;
            }
            RNode child = node.child.get(c);
            int j = commonPrefixLen(word.substring(i), child.label);
            if (j == child.label.length()) { // whole edge matches: descend
                node = child;
                i += j;
                if (i == word.length()) { node.isEnd = true; return; }
                continue;
            }
            // split: a new node holds the shared prefix; child keeps only its tail
            RNode mid = new RNode(child.label.substring(0, j), false);
            child.label = child.label.substring(j);
            mid.child.put(child.label.charAt(0), child);
            node.child.put(c, mid);
            if (i + j == word.length()) {
                mid.isEnd = true; // the inserted word ends exactly at the
split point
                return;
            }
            mid.child.put(word.charAt(i + j), new RNode(word.substring(i + j), true));
            return;
        }
    }

    static boolean search(RNode root, String word, boolean[] isPrefix) {
        RNode node = root;
        int i = 0;
        while (i < word.length()) {
            char c = word.charAt(i);
            if (!node.child.containsKey(c)) {

```

```

        isPrefix[0] = false;
        return false;
    }
    RNode child = node.child.get(c);
    int j = commonPrefixLen(word.substring(i), child.label);
    if (j < child.label.length()) {
        isPrefix[0] = (i + j == word.length());
        return false;
    }
    node = child;
    i += j;
}
isPrefix[0] = true;
return node.isEnd;
}

static void runScenario(String label, String[] words, String[] queries) {
    System.out.println("-- " + label + " --");
    RNode root = new RNode("", false);
    for (String w : words) {
        insert(root, w);
        System.out.println("insert(" + w + ")");
    }
    for (String q : queries) {
        boolean[] isPrefix = new boolean[1];
        boolean found = search(root, q, isPrefix);
        System.out.println("search(" + q + ") -> found=" + found + ", isPrefix=" +
isPrefix[0]);
    }
    System.out.println();
}

public static void main(String[] args) {
    runScenario("normal: TEST, TEA, TEAM -- one edge splits in two",
        new String[]{"TEST", "TEA", "TEAM"}, new String[]{"TEA", "TE", "TEAMS"});

    runScenario("hard: the ROMAN word family -- several splits back to back",
        new String[]{"ROMAN", "ROMANE", "ROMANUS", "ROMULUS"},
        new String[]{"ROMAN", "ROM", "ROMANEQ", "ROMULUS"});

    runScenario("edge: no shared prefix, every word is a single long edge",
        new String[]{"APPLE", "BANANA"}, new String[]{"APPLE", "AP"});

    runScenario("edge: CAR is a prefix of CARPET and CARD",
        new String[]{"CAR", "CARPET", "CARD"}, new String[]{"CAR", "CARP", "CARPET"});

    runScenario("edge: ANT, ARM, ART, AXE -- splits nested inside splits",
        new String[]{"ANT", "ARM", "ART", "AXE"}, new String[]{"ART", "AR", "ARK"});
}
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x compressed_trie.c && /tmp/x
```

Beklenen çıktı:

```

-- normal: TEST, TEA, TEAM -- one edge splits in two --
insert(TEST)
insert(TEA)
insert(Team)
search(TEA) -> found=true, isPrefix=true
search(TE) -> found=false, isPrefix=true
search(TEAMS) -> found=false, isPrefix=false

-- hard: the ROMAN word family -- several splits back to back --
insert(ROMAN)
insert(ROMANE)
insert(ROMANUS)
insert(ROMULUS)
search(ROMAN) -> found=true, isPrefix=true
search(ROM) -> found=false, isPrefix=true
search(ROMANEQ) -> found=false, isPrefix=false
search(ROMULUS) -> found=true, isPrefix=true

-- edge: no shared prefix, every word is a single long edge --
insert(APPLE)
insert(BANANA)
search(APPLE) -> found=true, isPrefix=true
search(AP) -> found=false, isPrefix=true

-- edge: CAR is a prefix of CARPET and CARD --
insert(CAR)
insert(CARPET)
insert(CARD)
search(CAR) -> found=true, isPrefix=true
search(CARP) -> found=false, isPrefix=true
search(CARPET) -> found=true, isPrefix=true

-- edge: ANT, ARM, ART, AXE -- splits nested inside splits --
insert(ANT)
insert(ARM)
insert(ART)
insert(AXE)
search(ART) -> found=true, isPrefix=true
search(AR) -> found=false, isPrefix=true
search(ARK) -> found=false, isPrefix=false

```

```
javac -Xlint:all CompressedTrie.java && java CompressedTrie
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

4.6 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. `insert` ve `search`, düz bir trie ile tam olarak aynı şekilde, sözcüğün uzunluğu L 'de $O(L)$ kalır — her kenardaki ekstra `common_prefix_len` karşılaştırması, karmaşıklık sınıfını değiştirmez, çünkü tüm yürüyüş boyunca toplamda hiçbir zaman L 'den fazla karakter çiftini karşılaştırmaz. Tasarruflar **alanda**dır: düğüm sayısı **dallanma noktaları ve sözcük sonlarının** sayısı ile sınırlıdır, toplam karakter sayısı ile değil, böylece uzun dallanmasız uzanımlı sözcükler ("INTERNATIONAL" gibi) saklayan sıkıştırılmış bir trie, aynı sözcükleri saklayan düz bir trie'den çarpıcı biçimde daha az düğüm kullanır.



Sık yapılan hatalar

- **Yanlış uzunlukta bölmek.** Bölme noktası, kalan sorgu ile var olan kenar etiketi arasındaki **ortak önek uzunluğudur** — ne birinin ne de diğerinin tek başına uzunluğu değil. Bunu yanlış yapın, yeni dallanma düğümünün etiketi ya çok kısa (paylaşılan karakterleri kaybeder) ya da çok uzun (iki sözcüğün gerçekte paylaşımadığı bir bölgeye geçer) olur.
- **Bölünen çocuğu yeniden anahtarlamayı unutmak.** `child->label`'i kısalttıktan sonra, o çocuk yeni `mid` düğümünün çocuk dizisine/haritasına **yeni** ilk karakteri altında (kısaltmadan *sonraki* `child->label[0]`) yeniden eklenmelidir, eskisi altında değil.
- **"Yol var"ı "sözcük bulundu" ile aynı saymak.** Tam olarak bölüm 3'te olduğu gibi, gerçek kenarları izleyerek bir sorgunun sonuna ulaşmak (bir kenarın ortasında bile olsa) sorgunun bir **önek** olduğunu kanıtlar, saklı tam bir **sözcük** olduğunu değil — bunu hâlâ son düğümün `isEnd` bayrağı belirler.



Kendini sına: INTERNATIONAL burada neden düz trie'den bu kadar az düğüme ihtiyaç duyar?



Düz bir trie yol başına bir düğüme ihtiyaç duyar — hiç paylaşılan önek olmayan 13 harfli bir sözcük için 13 düğüm, her birinin tam olarak bir çocuğu olsa bile. Sıkıştırılmış bir trie bütün o dallanmasız uzanımı **tek bir kenara**, "INTERNATIONAL" etiketli, toplar, yalnız bir yaprak düğüm kullanarak. Tasarruflar, dallanmasız uzanımların ne kadar *uzun* olduğuyla orantılı ölçeklenir — erken ve sık dallanan sözcükler (kısa, benzer önekler) daha az fayda görür, saklı başka herhangi bir şeyle neredeyse hiçbir şey paylaşmayan sözcükler daha çok görür.

5. Sonek dizileri

5.1 Başlangıç sorusu

Bir trie "X saklı bir sözcük mü?" sorusunu yanıtlar, ama bu "P örüntüsü tek bir uzun T metninin *herhangi bir yerinde* geçiyor mu?" sorusundan farklıdır — bir metin düzenleyicinin "bul" özelliğinin, ya da bir DNA sırasını arayan bir genom tarayıcısının sürekli sorduğu, genellikle aynı T karşısında her seferinde *farklı* bir P ile sorduğu türden bir soru. T'nin her alt-dizgisinin bir trie'sini kurmak bunu yanıtlardı, ama n uzunluğundaki bir dizginin $O(n^2)$ alt-dizgisi vardır — fazlasıyla çok. Ya bunun yerine yalnız T'nin her **soneğine** ihtiyacınız olsaydı (bunlardan yalnız n tane vardır), ve bunlar bir **ikili aramanın**, m örüntünün uzunluğu olmak üzere, herhangi bir örüntünün geçtiği yerleri $O(m \log n)$ sürede bulabilmesi için sıralansaydı? Sonek başlangıç konumlarının o sıralı listesi bir **sonek dizisidir (suffix array)**.

5.2 Fikir: her sonek, sözlük sırasına göre sıralı

n uzunluğundaki bir metnin sonek dizisi, basitçe 0, 1, ..., n-1 tamsayılarının bir dizisidir, öyle yeniden sıralanmış ki `text[sa[0]..], text[sa[1]..], ..., text[sa[n-1]..]` sıralı (sözlük) sırada olsun. Aynı sonlu dizginin iki farklı soneği her zaman **farklı uzunluklara** sahip olduğundan, biri diğerinin bayt bayt bir kopyası olamaz — biri diğerinin öneki olduğunda, *daha kısa* olan basitçe önce sıralanır (tam olarak "CAR" 'ın bir sözlükte "CARD" 'dan önce sıralandığı gibi), böylece hiçbir özel dizgi-sonu işaretine gerek kalmaz bağları çözmek için. Bu not, sonek dizisini `strcmp` tarzı sonek karşılaştırmaları üzerinde **ekleme sıralamasıyla (insertion sort)** kurar — canlandırması basittir, ve her sonek aynı alttaki arabelleğe bir işaretçidir, sıralama sırasında hiçbir karakter kopyalanmaz. Üretim kütüphaneleri bunun yerine $O(n \log n)$ (hatta $O(n)$) bir kurma algoritması kullanır, ama son sıralı sıra her iki durumda da aynıdır.

5.3 Bellekte nasıl durur, ve kod

```

int compare_suffix(const char *text, int a, int b) {
    return strcmp(text + a, text + b);    /* pointer INTO the same buffer, no copy */
}

void build_suffix_array(const char *text, int n, int sa[]) {
    for (int i = 0; i < n; i++) sa[i] = i;    /* start: unsorted, index order */
    for (int i = 1; i < n; i++) {
        int key = sa[i], j = i - 1;
        while (j >= 0 && compare_suffix(text, sa[j], key) > 0) {
            sa[j + 1] = sa[j];
            j--;
        }
        sa[j + 1] = key;
    }
}

static int compareSuffix(String text, int a, int b) {
    return text.substring(a).compareTo(text.substring(b));
}

static void buildSuffixArray(String text, int[] sa) {
    int n = text.length();
    for (int i = 0; i < n; i++) sa[i] = i;    // start: unsorted, index order
    for (int i = 1; i < n; i++) {
        int key = sa[i], j = i - 1;
        while (j >= 0 && compareSuffix(text, sa[j], key) > 0) {
            sa[j + 1] = sa[j];
            j--;
        }
        sa[j + 1] = key;
    }
}

```

Animasyonu oynatarak her soneği, kendi satırı olarak çizilmiş, zaten yerleştirilmiş satırlar arasında sıralı konumuna kaydığını izleyin — tam olarak bir dizgi listesini ekleme sıralamasıyla sıralamak gibi.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

1. sa[] = {0,1,...,10}: başlangıçta sonekler indis sırasında, hiç sıralı değil. Ekleme sıralaması (insertion sort) ile sıralayacağız.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

2. i=0: tek bir soneği sıralı bir dizi saymak yeterli, hiç karşılaştırma yok.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

3. i=1: key = sa[1] = 1, yeni sonek geçici olarak en alta konur.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0
> ile başlıyor -- yer değiştir

4. i=0 soneği ("MISSISSIPPI") "ISSISSIPPI"den büyük -- yer değiştirirler.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

6. i=2: key = sa[2] = 2, yeni sonek geçici olarak en alta konur.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

7. j >= 0 yanlış ya da artık büyük değil -- sa[2] = 2 ile yerine oturur.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

i=3:

S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---

8. i=3: key = sa[3] = 3, yeni sonek geçici olarak en alta konur.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

i=3:

S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---

i=2
> ile başlıyor -- yer değiştir

9. i=2 soneği ("SSISSIPPI") "SISSIPPI"den büyük -- yer değiştirirler.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=3:

S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

10. j >= 0 yanlış ya da artık büyük değil -- sa[2] = 3 ile yerine oturur.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=4:

I	S	S	I	P	P	I
---	---	---	---	---	---	---

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=3:

S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

11. i=4: "ISSIPPI" 4 kaydırmadan sonra 0. sıraya yerleşir.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=4:

I	S	S	I	P	P	I
---	---	---	---	---	---	---

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=3:

S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---

i=5:

S	S	I	P	P	I
---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

12. i=5: "SSIPPI" 1 kaydırmadan sonra 4. sıraya yerleşir.

text[] =

0	1	2	3	4	5	6	7	8	9	10
M	I	S	S	I	S	S	I	P	P	I

i=4:

I	S	S	I	P	P	I
---	---	---	---	---	---	---

i=1:

I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---

i=0:

M	I	S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---	---	---

i=6:

S	I	P	P	I
---	---	---	---	---

i=3:

S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---

i=5:

S	S	I	P	P	I
---	---	---	---	---	---

i=2:

S	S	I	S	S	I	P	P	I
---	---	---	---	---	---	---	---	---

13. i=6: "SIPPI" 3 kaydırmadan sonra 3. sıraya yerleşir.

text[] = M I S S I S S I P P I

i=7: I P P I
i=4: I S S I P P I
i=1: I S S I S S I P P I
i=0: M I S S I S S I P P I
i=8: P P I
i=6: S I P P I
i=3: S I S S I P P I
i=5: S S I P P I
i=2: S S I S S I P P I

15. i=8: "PPI" 4 kaydırmadan sonra 4. sıraya yerleşir.

text[] = M I S S I S S I P P I

i=7: I P P I
i=4: I S S I P P I
i=1: I S S I S S I P P I
i=0: M I S S I S S I P P I
i=9: P I
i=8: P P I
i=6: S I P P I
i=3: S I S S I P P I
i=5: S S I P P I
i=2: S S I S S I P P I

16. i=9: "PI" 5 kaydırmadan sonra 4. sıraya yerleşir.

text[] = 0 1 2 3 4 5 6 7 8 9 10
M I S S I S S I P P I

i=10: I
i=7: I P P I
i=4: I S S I P P I
i=1: I S S I S S I P P I
i=0: M I S S I S S I P P I
i=9: P I
i=8: P P I
i=6: S I P P I
i=3: S I S S I P P I
i=5: S S I P P I
i=2: S S I S S I P P I

17. i=10: "I" 10 kaydırmadan sonra 0. sıraya yerleşir.

text[] = 0 1 2 3 4 5 6 7 8 9 10
M I S S I S S I P P I

i=10: I
i=7: I P P I
i=4: I S S I P P I
i=1: I S S I S S I P P I
i=0: M I S S I S S I P P I
i=9: P I
i=8: P P I
i=6: S I P P I
i=3: S I S S I P P I
i=5: S S I P P I
i=2: S S I S S I P P I

18. Bitti: sonek dizisi = [10, 7, 4, 1, 0, 9, 8, 6, 3, 5, 2].
Artık pattern aramak, sıralı listede ikili arama ile yapılabilir -- $O(m \log n)$.

Seçicide ayrıca **"ABABABABAB"**: **baştan sona neredeyse-berabere karşılaştırmalar** (zor) ve uç durumları **"AAAAAAAAAA"**: **her karakter aynı**, **"ABCDEFGHJIJ"**: **zaten artan**, ve **"JIHGFEDCBA"**: **azalan**, **en çok kaydırma** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi metninizi yazın.

5.4 Dene

Tam program: `suffix_array.c` / `SuffixArray.java`

```

/* Week 12 -- Strings: Structures and Algorithms
 * Suffix array: every starting position of text, sorted by the suffix beginning there, built
 here with
 * insertion sort over strcmp(text+a, text+b) -- each suffix is just a pointer into the same
 buffer, no copy.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXN 24

static int compare_suffix(const char *text, int a, int b) {
    return strcmp(text + a, text + b); /* pointer INTO the same buffer, no copy */
}

static void build_suffix_array(const char *text, int n, int sa[]) {
    for (int i = 0; i < n; i++) sa[i] = i; /* start: unsorted, index order */
    for (int i = 1; i < n; i++) {
        int key = sa[i], j = i - 1;
        while (j >= 0 && compare_suffix(text, sa[j], key) > 0) {
            sa[j + 1] = sa[j];
            j--;
        }
        sa[j + 1] = key;
    }
}

static void run_scenario(const char *label, const char *text) {
    printf("-- %s --\n", label);
    int n = (int) strlen(text);
    printf("text = \"%s\" (%d letters)\n", text, n);
    int sa[MAXN];
    build_suffix_array(text, n, sa);
    printf("suffix array:");
    for (int i = 0; i < n; i++) printf(" %d", sa[i]);
    printf("\n");
    for (int i = 0; i < n; i++) printf(" sa[%d]=%d -> \"%s\"\n", i, sa[i], text + sa[i]);
    printf("\n");
}

int main(void) {
    run_scenario("normal: MISSISSIPPI, many repeating suffixes", "MISSISSIPPI");
    run_scenario("hard: ABABABABAB, near-ties throughout", "ABABABABAB");
    run_scenario("edge: AAAAAAAAAA, every character identical", "AAAAAAAAAA");
    run_scenario("edge: ABCDEFGHIJ, already ascending", "ABCDEFGHIJ");
    run_scenario("edge: JIHGFEDCBA, descending, the most shifting", "JIHGFEDCBA");
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Suffix array: every starting position of text, sorted by the suffix beginning there, built
 here with
 * insertion sort over String.compareTo on substrings.
 * CEN207 Data Structures (formerly CE205)
 */
public class SuffixArray {
    static int compareSuffix(String text, int a, int b) {
        return text.substring(a).compareTo(text.substring(b));
    }

    static int[] buildSuffixArray(String text) {
        int n = text.length();
        int[] sa = new int[n];
        for (int i = 0; i < n; i++) sa[i] = i;    // start: unsorted, index order
        for (int i = 1; i < n; i++) {
            int key = sa[i], j = i - 1;
            while (j >= 0 && compareSuffix(text, sa[j], key) > 0) {
                sa[j + 1] = sa[j];
                j--;
            }
            sa[j + 1] = key;
        }
        return sa;
    }

    static void runScenario(String label, String text) {
        System.out.println("-- " + label + " --");
        System.out.println("text = \"\" + text + "\"" (" + text.length() + " letters)");
        int[] sa = buildSuffixArray(text);
        StringBuilder line = new StringBuilder("suffix array:");
        for (int v : sa) line.append(' ').append(v);
        System.out.println(line);
        for (int i = 0; i < sa.length; i++) System.out.println("  sa[" + i + "]=" + sa[i] + " ->
\"\" + text.substring(sa[i]) + "\"");
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: MISSISSIPPI, many repeating suffixes", "MISSISSIPPI");
        runScenario("hard: ABABABABAB, near-ties throughout", "ABABABABAB");
        runScenario("edge: AAAAAAAAAA, every character identical", "AAAAAAAAAA");
        runScenario("edge: ABCDEFGHIJ, already ascending", "ABCDEFGHIJ");
        runScenario("edge: JIHGFEDCBA, descending, the most shifting", "JIHGFEDCBA");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x suffix_array.c && /tmp/x
```

Beklenen çıktı:

```

-- normal: MISSISSIPPI, many repeating suffixes --
text = "MISSISSIPPI" (11 letters)
suffix array: 10 7 4 1 0 9 8 6 3 5 2
sa[0]=10 -> "I"
sa[1]=7 -> "IPPI"
sa[2]=4 -> "ISSIPPI"
sa[3]=1 -> "ISSISSIPPI"
sa[4]=0 -> "MISSISSIPPI"
sa[5]=9 -> "PI"
sa[6]=8 -> "PPI"
sa[7]=6 -> "SIPPI"
sa[8]=3 -> "SISSIPPI"
sa[9]=5 -> "SSIPPI"
sa[10]=2 -> "SSISSIPPI"

-- hard: ABABABABAB, near-ties throughout --
text = "ABABABABAB" (10 letters)
suffix array: 8 6 4 2 0 9 7 5 3 1
sa[0]=8 -> "AB"
sa[1]=6 -> "ABAB"
sa[2]=4 -> "ABABAB"
sa[3]=2 -> "ABABABAB"
sa[4]=0 -> "ABABABABAB"
sa[5]=9 -> "B"
sa[6]=7 -> "BAB"
sa[7]=5 -> "BABAB"
sa[8]=3 -> "BABABAB"
sa[9]=1 -> "BABABABAB"

-- edge: AAAAAAAAAA, every character identical --
text = "AAAAAAAAAA" (10 letters)
suffix array: 9 8 7 6 5 4 3 2 1 0
sa[0]=9 -> "A"
sa[1]=8 -> "AA"
sa[2]=7 -> "AAA"
sa[3]=6 -> "AAAA"
sa[4]=5 -> "AAAAA"
sa[5]=4 -> "AAAAAA"
sa[6]=3 -> "AAAAAAA"
sa[7]=2 -> "AAAAAAAA"
sa[8]=1 -> "AAAAAAAAA"
sa[9]=0 -> "AAAAAAAAAA"

-- edge: ABCDEFGHIJ, already ascending --
text = "ABCDEFGHIJ" (10 letters)
suffix array: 0 1 2 3 4 5 6 7 8 9
sa[0]=0 -> "ABCDEFGHIJ"
sa[1]=1 -> "BCDEFGHIJ"
sa[2]=2 -> "CDEFGHIJ"
sa[3]=3 -> "DEFGHIJ"
sa[4]=4 -> "EFGHIJ"
sa[5]=5 -> "FGHIJ"
sa[6]=6 -> "GHIJ"
sa[7]=7 -> "HIJ"
sa[8]=8 -> "IJ"
sa[9]=9 -> "J"

-- edge: JIHGFEDCBA, descending, the most shifting --
text = "JIHGFEDCBA" (10 letters)
suffix array: 9 8 7 6 5 4 3 2 1 0
sa[0]=9 -> "A"
sa[1]=8 -> "BA"
sa[2]=7 -> "CBA"
sa[3]=6 -> "DCBA"

```

```

sa[4]=5 -> "EDCBA"
sa[5]=4 -> "FEDCBA"
sa[6]=3 -> "GFEDCBA"
sa[7]=2 -> "HGFEDCBA"
sa[8]=1 -> "IHGFEDCBA"
sa[9]=0 -> "JIHGFEDCBA"

```

```
javac -Xlint:all SuffixArray.java && java SuffixArray
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

5.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. n sonek üzerinde ekleme sıralaması en kötü durumda $O(n^2)$ karşılaştırmaya mal olur, ve her karşılaştırma kendisi $O(n)$ karaktere kadar mal olabilir — burada gösterilen basit kurma için en kötü durumda toplam $O(n^3)$. Gerçek kütüphaneler bunun yerine $O(n \log n)$ ya da $O(n)$ sürede bir sonek dizisi kurar. Ama bir kez kurulduktan sonra, her uygulama aynı şekilde karşılığını verir: m uzunluğundaki bir örüntüyü aramak sıralı sonekler üzerinde bir **ikili aramadır**, $O(m \log n)$ — aynı sabit metne karşı birçok farklı örüntü aranacaksa, tüm metni taramaktan ($O(n)$) çarpıcı biçimde daha hızlıdır.

⚠ Sık yapılan hatalar

- **Bir önek olduğunda daha-kısa-olan-daha-küçüktür kuralının otomatik olduğunu unutup**, gereksiz bir bitiş işareti eklemek. Aynı dizinin iki soneği her zaman uzunlukta farklı olduğundan, düz sözlük karşılaştırması biri diğerinin öneki olduğunda daha kısa olanı zaten önce koyar — hiçbir $\$$ işaretine gerek yoktur (bazı diğer sonek-dizisi algoritmaları başka teknik bir nedenle *gerçekten* bir tanesine ihtiyaç duyar, ama karşılaştırma kuralının kendisi duymaz).
- **Alt-dizgileri kopyalayarak soneklerin karşılaştırılması**, yerinde karşılaştırma yerine. `text.substring(a)` (Java) ya da elle kopyalama (C), her tek karşılaştırma için yeni bir dizgi ayırır — `strcmp(text + a, text + b)` (C) aynı alttaki baytları hiç ayırma yapmadan karşılaştırılabilirken pahalı.
- **Sonek dizisinin indislerini soneklerin karakterleriyle karıştırmak.** `sa[i]`, orijinal metinde bir **başlangıç konumudur**, soneğin kendisinin bir kopyası değil — `text + sa[i]` 'yi (C) ya da `text.substring(sa[i])` 'yi (Java) yazdırmak gerçek sonek metnini görüntülemek için kullanılan yoldur.

✓ Kendini sına: burada neden hiçbir bitiş işaretine gerek yok?



Bir bitiş işareti (her gerçek karakterden küçük bir karakter, metnin sonuna bir kez eklenir), *diğer* sonek-dizisi algoritmalarında karşılaştırmaların arabelleğin sonunun ötesine hiç geçmemesini garanti etmek için yaygın bir hiledir. Ama karşılaştırma kuralının kendisi için — "sonek A, sonek B'den önce mi sıralanır?" — sıradan sözlük karşılaştırması, bir soneğin diğerinin öneki olduğu durumu zaten doğru işler: diğerinin başlangıcıyla eşleşen daha kısa bir dizgi, tanım gereği ondan "küçüktür" (tam olarak bir sözlük sırasının zaten çalıştığı gibi: "CAR", "CARD" 'dan önce gelir). Aynı dizginin hiçbir soneği, başka bir soneğiyle hem içerikte hem uzunlukta asla eşit olamaz, böylece bağların bu kuralın ötesinde hiçbir şeyle çözülmesine gerek kalmaz.

6. Dizgi eşleştirme problemi, ve saf arama

6.1 Başlangıç sorusu

Bu bölüm yeni bir aile başlatıyor: bir **metin** ve bir **örüntü (pattern)** verildiğinde, örüntü metnin neresinde (varsa) geçer? Bölüm 5'in son ek dizisinin aksine (gelecekte *birçok* sorguyu hızlıca yanıtlamak için baştan bir sıralama maliyeti öder), bu ve sonraki dört bölümdeki dört algoritmanın her biri, metnin kendisine hiçbir ön işleme uygulamadan, ham metne karşı doğrudan **tek** bir aramayı yanıtlar (KMP, Rabin-Karp ve Z algoritması normalde metinden çok daha kısa olan **örüntüyü** ön işler). Olabilecek en basit yaklaşım — her konumu dene, karakter karakter karşılaştır, ilk uyuşmazlıkta vazgeç ve devam et — ****saf (naif, brute-force) arama****dır, ve size daha akıllı bir şey öğretilmemiş olsaydı tam olarak başlayacağınız yerdir.

6.2 Fikir: her kaydırmayı dene

Örüntüyü metin üzerinde bir seferde bir konum (bir **kaydırma (shift)** s) kaydırın. Her kaydirmada, `pattern[0]`'ı `text[s]` ile karşılaştırın, sonra `pattern[1]`'i `text[s+1]` ile, ve böyle devam edin, soldan sağa, ilk uyuşmazlıkta durarak (bir sonraki kaydırmaya geçin) ya da tam bir eşleşmeye kadar devam ederek (s konumunda bir oluşum kaydedin, ve **yine de** bir sonraki kaydırmaya geçin — eşleşmeler çakışabilir, ve saf arama hepsini bulur). n uzunluğundaki bir metin ve m uzunluğundaki bir örüntü için $n - m + 1$ olası kaydırma vardır.

6.3 Bellekte nasıl durur, ve kod

```
void naive_search(const char *text, int n, const char *pattern, int m, int occ[], int *count) {
    int c = 0;
    for (int s = 0; s <= n - m; s++) {          /* try every shift */
        int j = 0;
        while (j < m && text[s + j] == pattern[j]) j++; /* compare left to right */
        if (j == m) occ[c++] = s;                /* whole pattern matched: occurrence at s */
    }
    *count = c;
}

static int[] naiveSearch(String text, String pattern) {
    int n = text.length(), m = pattern.length(), c = 0;
    int[] occ = new int[n];
    for (int s = 0; s <= n - m; s++) {          // try every shift
        int j = 0;
        while (j < m && text.charAt(s + j) == pattern.charAt(j)) j++; // compare left to right
        if (j == m) occ[c++] = s;                // whole pattern matched: occurrence at s
    }
    return Arrays.copyOf(occ, c);
}
```

Animasyonu oynatarak örüntünün bir seferde bir konum kaydırdığını, soldan sağa karşılaştırdığını, ve bir uyuşmazlık bulunur bulunmaz durduğunu izleyin.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 0$

1. pattern (5 harf) text (10 harf) üzerinde soldan sağa kaydırılacak: $s = 0, 1, \dots, 5$.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' == 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 0$

2. $\text{text}[0] = A == \text{pattern}[0]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' == 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 0$

4. $\text{text}[2] = A == \text{pattern}[2]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'B' == 'B'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 0$

5. $\text{text}[3] = B == \text{pattern}[3]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' != 'C'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 0$

6. $\text{text}[4] = A != \text{pattern}[4] = C$ -- uyumsuzluk, bu kaydırma bitti.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' == 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 2$

8. $\text{text}[2] = A == \text{pattern}[0]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'B' == 'B'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 2$

9. $\text{text}[3] = B == \text{pattern}[1]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' == 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 2$

10. $\text{text}[4] = A == \text{pattern}[2]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'B' != 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 3$

12. $\text{text}[3] = B != \text{pattern}[0] = A$ -- uyumsuzluk, bu kaydırma bitti.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' == 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 4$

13. $\text{text}[4] = A == \text{pattern}[0]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'A' != 'B'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 4$

14. $\text{text}[5] = A != \text{pattern}[1] = B$ -- uyumsuzluk, bu kaydırma bitti.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$ 'B' == 'B'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 5$

16. $\text{text}[6] = B == \text{pattern}[1]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 5$

17. $\text{text}[7] = A == \text{pattern}[2]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 5$

18. $\text{text}[8] = B == \text{pattern}[3]$ -- eşleşti, devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 5$

20. $j == m(5)$ -- tüm örüntü eşleşti: $s = 5$ 'te bulundu.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & B & A & A & B & A & B & C \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 \\ A & B & A & B & C \end{matrix}$
 $\text{shift } s = 5$

21. Bitti: 6 kaydırma denendi, 1 oluşum bulundu (5). En kötü durumda $O(n*m)$ karşılaştırma.

Seçicide ayrıca **text="AAAAAAAAA"**, **pattern="AAAB"**: en kötü durum, hep geç başarısız (zor) ve uç durumları hiç bulunmaz, hep erken başarısız, her kaydırmada çakışan bir eşleşme, ve **text == pattern**, tek olası kaydırma deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi metnizi ve örüntünüzü yazın.

6.4 Dene

Tam program: `naive_search.c` / `NaiveSearch.java`

```

/* Week 12 -- Strings: Structures and Algorithms
 * Naive (brute-force) substring search: try every shift, compare left to right until a mismatch
or a full
 * match. Worst case O(n*m).
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXOCC 32

static int naive_search(const char *text, int n, const char *pattern, int m, int occ[]) {
    int c = 0;
    for (int s = 0; s <= n - m; s++) {          /* try every shift */
        int j = 0;
        while (j < m && text[s + j] == pattern[j]) j++; /* compare left to right */
        if (j == m) occ[c++] = s;                /* whole pattern matched: occurrence at s */
    }
    return c;
}

static void print_occ(const int occ[], int count) {
    if (count == 0) { printf("(none)"); return; }
    for (int i = 0; i < count; i++) printf("%s%d", i ? ", " : "", occ[i]);
}

static void run_scenario(const char *label, const char *text, const char *pattern) {
    printf("-- %s --\n", label);
    printf("text = \"%s\" (%d letters), pattern = \"%s\" (%d letters)\n",
           text, (int) strlen(text), pattern, (int) strlen(pattern));
    int occ[MAXOCC];
    int count = naive_search(text, (int) strlen(text), pattern, (int) strlen(pattern), occ);
    printf("occurrences (%d): ", count);
    print_occ(occ, count);
    printf("\n\n");
}

int main(void) {
    run_scenario("normal: a few false starts", "ABABAABABC", "ABABC");
    run_scenario("hard: worst case, fails late every time", "AAAAAAAAA", "AAAB");
    run_scenario("edge: never found, always fails early", "THEQUICKFOX", "ZEBRA");
    run_scenario("edge: an overlapping match at every shift", "AAAAAAAAA", "AAA");
    run_scenario("edge: text == pattern, only one possible shift", "ALGORITHMS", "ALGORITHMS");
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Naive (brute-force) substring search: try every shift, compare left to right until a mismatch
or a full
 * match. Worst case  $O(n*m)$ .
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.ArrayList;
import java.util.List;

public class NaiveSearch {
    static List<Integer> naiveSearch(String text, String pattern) {
        int n = text.length(), m = pattern.length();
        List<Integer> occ = new ArrayList<>();
        for (int s = 0; s <= n - m; s++) {           // try every shift
            int j = 0;
            while (j < m && text.charAt(s + j) == pattern.charAt(j)) j++; // compare left to
right
            if (j == m) occ.add(s);                  // whole pattern matched: occurrence at s
        }
        return occ;
    }

    static void runScenario(String label, String text, String pattern) {
        System.out.println("-- " + label + " --");
        System.out.println("text = \"" + text + "\" (" + text.length() + " letters), pattern =
\"" + pattern + "\" (" + pattern.length() + " letters)");
        List<Integer> occ = naiveSearch(text, pattern);
        System.out.print("occurrences (" + occ.size() + "): ");
        if (occ.isEmpty()) System.out.print("(none)");
        else {
            for (int i = 0; i < occ.size(); i++) System.out.print((i > 0 ? ", " : "") +
occ.get(i));
        }
        System.out.println();
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: a few false starts", "ABABAABABC", "ABABC");
        runScenario("hard: worst case, fails late every time", "AAAAAAAAA", "AAAB");
        runScenario("edge: never found, always fails early", "THEQUICKFOX", "ZEBRA");
        runScenario("edge: an overlapping match at every shift", "AAAAAAAAA", "AAA");
        runScenario("edge: text == pattern, only one possible shift", "ALGORITHMS",
"ALGORITHMS");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x naive_search.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: a few false starts --
text = "ABABAABABC" (10 letters), pattern = "ABABC" (5 letters)
occurrences (1): 5

-- hard: worst case, fails late every time --
text = "AAAAAAAAAA" (10 letters), pattern = "AAAB" (4 letters)
occurrences (0): (none)

-- edge: never found, always fails early --
text = "THEQUICKFOX" (11 letters), pattern = "ZEBRA" (5 letters)
occurrences (0): (none)

-- edge: an overlapping match at every shift --
text = "AAAAAAAAAA" (10 letters), pattern = "AAA" (3 letters)
occurrences (8): 0, 1, 2, 3, 4, 5, 6, 7

-- edge: text == pattern, only one possible shift --
text = "ALGORITHMS" (10 letters), pattern = "ALGORITHMS" (10 letters)
occurrences (1): 0
```

```
javac -Xlint:all NaiveSearch.java && java NaiveSearch
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

6.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. En iyi durum $O(n)$ (her kaydırma tam ilk karşılaştırmasında başarısız olur — zengin bir alfabe ve kazara tekrar yoksa olur). En kötü durum $O(n*m)$: "AAAA...AB" gibi bir metne karşı "AAAB" gibi bir örüntü, son başarısız olmadan önce neredeyse her kaydırmada örüntünün neredeyse tamamını yeniden karşılaştırır — tam olarak yukarıdaki "zor" senaryonun gösterdiği şey. Bu en kötü durum, saf aramanın bu nottaki tüm var oluş nedenidir: bölüm 7–11'in her biri bunu farklı bir yolla düzeltir.

⚠ Sık yapılan hatalar

- **Eşleşmelerin çıkışabileceğini unutmak.** s kaydırmasında tam bir eşleşmeden sonra, bir sonraki $s + 1$ kaydırması hâlâ denenmelidir — yaygın bir hata, bir eşleşmeden sonra m konum ileri atlar (sanki eşleşmeler asla çakışmazmış gibi), yukarıdaki "AAAAAAAA" 'daki sekiz çıkışan "AAA" eşleşmesi gibi oluşumları sessizce kaçırmak.
- **s 'yi $n - m$ yerine n 'e kadar döndürmek.** Metinde m 'den az karakter kaldığında, hiçbir sonraki kaydırma tam bir eşleşme üretmez; yine de karşılaştırmak ya dizinin sonunun ötesini okur ya da başarılı olamayacak karşılaştırmalarla zaman israf eder.
- **Saf aramanın "kötü" olduğunu ve asla kullanılmaması gerektiğini varsaymak.** Kısa bir metne karşı kısa bir örüntü için (ya da bir örüntüyü ön işlemenin değmeyeceği tek seferlik bir arama), saf aramanın basitliği ve küçük sabit çarpanı onu *pratikte* daha akıllı bir algoritmadan sıkça daha hızlı yapar — en kötü durum karmaşıklığı tek dikkate alınacak şey değildir.

✓ Kendini sına: kendi en kötü durum girdinizi oluşturun



Yalnız iki harfli bir alfabe kullanarak, saf aramayı, hiç eşleşme bulunamadan önce, **her tek** kaydırmada örüntünün **dört** karakterinin tümünü karşılaştırmaya zorlayan 10 uzunluğunda bir `text` ve 4 uzunluğunda bir `pattern` oluşturun. (İpucu: yukarıdaki "zor" senaryoya bakın ve uyumsuzluğun neden örüntünün *ilk* karakterinde değil de *son* karakterinde olduğunu bir cümlede açıklayın.)

Cevap. `text = "AAAAAAAAA"`, `pattern = "AAAB"` tam olarak bu durumdur: her kaydırmada, `pattern[0..2]` ("AAA") metinden üç A ile eşleşir, ve yalnız `pattern[3]` ('B') metnin 'A' 'sıyla eşleşemez — uyumsuzluk tam olarak son karakterde olur, çünkü örüntünün ilk üç karakteri metnin tekrarlı harfinden ayırt edilemez.

7. Knuth-Morris-Pratt: başarısızlık işlevi

7.1 Başlangıç sorusu

Saf aramanın en kötü durumu, belirli, düzeltilebilir bir şekilde iş israf eder: "AAA" 'yı eşleştirip dördüncü karakterde başarısız olduktan sonra, tam öğrendiği *her şeyi* atar ve bir sonraki kaydırmayı sıfırdan yeniden başlatır, örüntünün ilk karakterini yeniden en baştan karşılaştırır — incelenmiş metin karakterleri zaten bilinse bile. Donald Knuth, James H. Morris, ve Vaughan Pratt, 1977'de bu bilgiyi asla atmayan bir algoritma yayımladı (Morris ve Pratt tarafından 1970 civarında, Knuth tarafından biraz daha sonra bağımsız olarak geliştirildi): **yalnız örüntüden**, bir uyumsuzlukta ne kadar güvenle ileri atlanabileceğini, **zaten bakılmış bir metin karakterini asla yeniden incelemeyen** önceden hesaplar. O önceden hesaplanmış tablo **başarısızlık işlevidir (failure function)**, genellikle `lps[]` denir — "en uzun uygun önek ki aynı zamanda sonek de olsun" (longest proper prefix that is also a suffix).

7.2 Fikir: `lps[i]` ne anlama gelir

Örüntünün her `pattern[0..i]` öneki için, `lps[i]`, o önekin **uygun** (proper — "bütünü değil" anlamına gelir) en uzun öneki ki aynı zamanda **sonek de olsun**, uzunluğudur. `pattern = "ABABCABABA"` için: `lps[3]`, "ABAB" önekine bakar ve "hem ABAB 'ın uygun bir öneki hem de soneği olan en uzun dizgi nedir?" diye sorar — cevap "AB" 'dir (uzunluk 2), çünkü "AB" hem "ABAB" 'ın nasıl başladığı hem de nasıl bittiğidir, ve daha uzun bir eşleşme ("ABA") her iki koşulu da sağlamaz. Bu tablo önemlidir çünkü bir arama ilk `j` örüntü karakterini eşleştirdikten sonra uyumsuzluğa düştüğünde, `lps[j-1]`, o zaten eşleşmiş karakterlerin kaç tanesinin bir sonraki denemenin başlangıcı olarak **yeniden kullanılabileceğini** tam olarak söyler — onları metinle yeniden karşılaştırmaya hiç gerek yoktur (bölüm 8 tabloyu bu şekilde kullanır). Tablo, örüntünün **kendisiyle** karşılaştırılarak kurulur: iki işaretçi, `i` (o anda uzatılan önek) ve `len` (o anki eşleşmiş önek-sonek uzunluğu); bir uyumsuzlukta, `len`, 0'a sıfırlanmak yerine `lps[len-1]` 'e geri düşer — aynı "zaten bildiğini yeniden kullan" hilesi özyinelemeli olarak uygulanır — ve tam olarak bu, tüm tabloyu kurmayı $O(m^2)$ değil $O(m)$ bir işlem olarak tutan şeydir.

7.3 Bellekte nasıl durur, ve kod

```

void compute_lps(const char *pattern, int m, int lps[]) {
    lps[0] = 0;
    int len = 0, i = 1;
    while (i < m) {
        if (pattern[i] == pattern[len]) {
            len++;
            lps[i] = len;
            i++;
        } else if (len != 0) {
            len = lps[len - 1];          /* fall back, do NOT advance i */
        } else {
            lps[i] = 0;
            i++;
        }
    }
}

static int[] computeLps(String pattern) {
    int m = pattern.length();
    int[] lps = new int[m];
    int len = 0, i = 1;
    while (i < m) {
        if (pattern.charAt(i) == pattern.charAt(len)) {
            len++;
            lps[i] = len;
            i++;
        } else if (len != 0) {
            len = lps[len - 1];          // fall back, do NOT advance i
        } else {
            lps[i] = 0;
            i++;
        }
    }
    return lps;
}

```

Animasyonu oynatarak `len`'in bir eşleşmede büyüdüğünü, bir uyumsuzlıkta `lps[len-1]` üzerinden geri düştüğünü (asla doğrudan 0'a değil), ve tablonun bir seferde bir girdi dolduğunu izleyin.




1. lps[0] = 0 her zaman -- tek karakterlik bir önekin özdeş olmayan bir soneki olamaz.




2. pattern[1] = B != pattern[0] = A, ve len zaten 0 -- daha geri düşülemez: lps[1] = 0, i bir artar.




3. pattern[2] = A, pattern[len] = A -- eşleşiyor: len bir artar (1), lps[2] = 1.




4. pattern[3] = B, pattern[len] = B -- eşleşiyor: len bir artar (2), lps[3] = 2.




5. pattern[4] = C != pattern[len] = A -- uyuşmazlık, ama len (2) sıfır değil: sıfıra değil, lps[len-1] = lps[1] = 0'e geri düşeriz. i İLERLEMEZ.



6. pattern[4] = C != pattern[0] = A, ve len zaten 0 -- daha geri düşülemez: lps[4] = 0, i bir artar.




7. pattern[5] = A, pattern[len] = A -- eşleşiyor: len bir artar (1), lps[5] = 1.




8. pattern[6] = B, pattern[len] = B -- eşleşiyor: len bir artar (2), lps[6] = 2.




9. pattern[7] = A, pattern[len] = A -- eşleşiyor: len bir artar (3), lps[7] = 3.



10. pattern[8] = B, pattern[len] = B -- eşleşiyor: len bir artar (4), lps[8] = 4.



11. pattern[9] = A != pattern[len] = C -- uyuşmazlık, ama len (4) sıfır değil: sıfıra değil, lps[len-1] = lps[3] = 2'e geri düşeriz. i İLERLEMEZ.



12. pattern[9] = A, pattern[len] = A -- eşleşiyor: len bir artar (3), lps[9] = 3.

	0	1	2	3	4	5	6	7	8	9
pattern[] =	A	B	A	B	C	A	B	A	B	A
lps[] =	0	0	1	2	0	1	2	3	4	3

13. Bitti: lps[] = [0, 0, 1, 2, 0, 1, 2, 3, 4, 3]. Bu tablo $O(m)$ sürede kuruldu ve KMP aramasının metni asla geri sarmamasını sağlayacak.

Seçicide ayrıca "AAAAAAAAA": her adımda büyür, lps[i] = i (zor) ve uç durumları hiç tekrar yok, lps hep 0, sürekli salınan bir örüntü, ve geri düşüş bir zinciri izler (lps[len-1]) deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi örüntünüzü yazın.

7.4 Dene

Tam program: `kmp_failure_function.c` / `KmpFailureFunction.java`

```

/* Week 12 -- Strings: Structures and Algorithms
 * KMP failure function (lps[]): for every prefix pattern[0..i], lps[i] is the length of the
 * longest proper
 * prefix of that prefix that is also a suffix of it. Built in O(m) by comparing the pattern to
 * itself.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

static void compute_lps(const char *pattern, int m, int lps[]) {
    lps[0] = 0;
    int len = 0, i = 1;
    while (i < m) {
        if (pattern[i] == pattern[len]) {
            len++;
            lps[i] = len;
            i++;
        } else if (len != 0) {
            len = lps[len - 1];      /* fall back, do NOT advance i */
        } else {
            lps[i] = 0;
            i++;
        }
    }
}

static void run_scenario(const char *label, const char *pattern) {
    printf("-- %s --\n", label);
    int m = (int) strlen(pattern);
    printf("pattern = \"%s\" (%d letters)\n", pattern, m);
    int lps[64];
    compute_lps(pattern, m, lps);
    printf("lps:");
    for (int i = 0; i < m; i++) printf(" %d", lps[i]);
    printf("\n\n");
}

int main(void) {
    run_scenario("normal: mixed growth and fallback", "ABABCABABA");
    run_scenario("hard: grows at every step, lps[i] = i", "AAAAAAAAA");
    run_scenario("edge: no repetition at all, lps is always 0", "ABCDEFGHJIJ");
    run_scenario("edge: a constantly oscillating pattern", "ABABABABAB");
    run_scenario("edge: the fallback chases a chain (lps[len-1])", "AABAACAABAA");
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * KMP failure function (lps[]): for every prefix pattern[0..i], lps[i] is the length of the
 * longest proper
 * prefix of that prefix that is also a suffix of it. Built in O(m) by comparing the pattern to
 * itself.
 * CEN207 Data Structures (formerly CE205)
 */
public class KmpFailureFunction {
    static int[] computeLps(String pattern) {
        int m = pattern.length();
        int[] lps = new int[m];
        int len = 0, i = 1;
        while (i < m) {
            if (pattern.charAt(i) == pattern.charAt(len)) {
                len++;
                lps[i] = len;
                i++;
            } else if (len != 0) {
                len = lps[len - 1]; // fall back, do NOT advance i
            } else {
                lps[i] = 0;
                i++;
            }
        }
        return lps;
    }

    static void runScenario(String label, String pattern) {
        System.out.println("-- " + label + " --");
        System.out.println("pattern = \"\" + pattern + "\" (" + pattern.length() + " letters)");
        int[] lps = computeLps(pattern);
        StringBuilder line = new StringBuilder("lps:");
        for (int v : lps) line.append(' ').append(v);
        System.out.println(line);
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: mixed growth and fallback", "ABABCABABA");
        runScenario("hard: grows at every step, lps[i] = i", "AAAAAAAAAA");
        runScenario("edge: no repetition at all, lps is always 0", "ABCDEFGHJIJ");
        runScenario("edge: a constantly oscillating pattern", "ABABABABAB");
        runScenario("edge: the fallback chases a chain (lps[len-1])", "AABAACAABAA");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x kmp_failure_function.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: mixed growth and fallback --
pattern = "ABABCABABA" (10 letters)
lps: 0 0 1 2 0 1 2 3 4 3

-- hard: grows at every step, lps[i] = i --
pattern = "AAAAAAAAAA" (10 letters)
lps: 0 1 2 3 4 5 6 7 8 9

-- edge: no repetition at all, lps is always 0 --
pattern = "ABCDEFGHJIJ" (10 letters)
lps: 0 0 0 0 0 0 0 0 0 0

-- edge: a constantly oscillating pattern --
pattern = "ABABABABAB" (10 letters)
lps: 0 0 1 2 3 4 5 6 7 8

-- edge: the fallback chases a chain (lps[len-1]) --
pattern = "AABAACAABAA" (11 letters)
lps: 0 1 0 1 2 0 1 2 3 4 5
```

```
javac -Xlint:all KmpFailureFunction.java && java KmpFailureFunction
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

7.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. m uzunluğundaki bir örüntü için tüm tabloyu kurmak $O(m)$ 'dir — geri düşüş döngüsüne rağmen, len her geri düşüşte kesin olarak azalır ve her eşleşmede kesin olarak artar, böylece tüm kurma boyunca len en fazla arttığı kadar azalabilir, toplam işi $O(m^2)$ değil $O(m)$ ile sınırlar.

⚠ Sık yapılan hatalar

- **Her uyuşmazlıkta len 'i 0'a sıfırlamak**, $lps[len-1]$ 'e geri düşmek yerine. Bu, sıfırdan bir KMP uygulamasındaki en yaygın tek hatadır — yine de *bir* tablo üretir, ama yanlış olanı, daha sonra ne kadar güvenle atlanabileceğini eksik bildiren bir tablo.
- **"Önek uzunluğu" ile "indis" arasında birer kayma.** $lps[i]$, $pattern[0..i]$ önekini (uzunluk $i+1$) tanımlar, böylece olası bir uzatma için karşılaştırılan karakter $pattern[len]$ 'dir, $pattern[len+1]$ ya da $pattern[len-1]$ değil — sık görülen bir dizi-sonrası ya da dizi-öncesi hata kaynağı.
- **$lps[0] = 0$ 'ın döngü tarafından değil, sabit bir taban durumu olduğunu unutmak.** Tek karakterli bir öneğin hiç uygun öneki yoktur (yalnız 0 uzunluğundaki boş dizgi), böylece $lps[0]$ karşılaştırmayla değil, tanım gereği her zaman 0 olmalıdır.

✓ Kendini sına: $lps[m-1]$ tüm örüntü hakkında size ne söyler?



$lps[m-1]$, tüm örüntünün en uzun uygun öneki ki aynı zamanda tüm örüntünün soneği olsun — başka bir deyişle, örüntünün en uzun **sınırının (border)** uzunluğudur. $lps[m-1] = 0$ olan bir örüntünün (hiç kendisiyle örtüşmesi yok, "ABCDEFGHJIJ" gibi) son karakterinde başarısız olursa yeniden kullanacak yararlı hiçbir şeyi yoktur; büyük bir $lps[m-1]$ olan bir örüntü ("AAAAAAAAA" gibi, $lps[m-1] = m-1$) zaten eşleştirdiği neredeyse her şeyi yeniden kullanabilir.

8. Knuth-Morris-Pratt: arama

8.1 Başlangıç sorusu

Bölüm 7, `lps[]` tablosunu yalnız örüntüden kurdu; bu bölüm onu işe koşar. KMP araması iki işaretçi tutar — `i` metine, `j` örüntüye — saf aramanın veremeyeceği bir garantiyle: `i` **asla geri gitmez**. Bir uyuşmazlıkta, örüntüyü *bir sonraki* metin konumunda ilk karakterinden yeniden başlatmak yerine (saf aramanın yaklaşımı, zaten bakılmış metin karakterlerini yeniden inceler), `j`, `lps[j-1]` 'e geri düşer — zaten bulunan kısmi eşleşmeyi yeniden kullanarak — `i` ise basitçe ileri devam eder. Sonuç: her metin karakteri küçük, sınırlı sayıda kez incelenir, metin ya da örüntü ne kadar tekrarlı olursa olsun toplam $O(n + m)$ süre verir.

8.2 Bellekte nasıl durur, ve kod

```
void kmp_search(const char *text, int n, const char *pattern, int m, const int lps[], int occ[], int *count) {
    int i = 0, j = 0, c = 0;
    while (i < n) {
        if (text[i] == pattern[j]) {
            i++; j++;
            if (j == m) {
                occ[c++] = i - m;          /* occurrence found; keep scanning */
                j = lps[j - 1];
            }
        } else if (j > 0) {
            j = lps[j - 1];                /* fall back in the PATTERN; i never moves back */
        } else {
            i++;
        }
    }
    *count = c;
}

static int[] kmpSearch(String text, String pattern, int[] lps) {
    int n = text.length(), m = pattern.length(), i = 0, j = 0, c = 0;
    int[] occ = new int[n];
    while (i < n) {
        if (text.charAt(i) == pattern.charAt(j)) {
            i++; j++;
            if (j == m) {
                occ[c++] = i - m;          // occurrence found; keep scanning
                j = lps[j - 1];
            }
        } else if (j > 0) {
            j = lps[j - 1];                // fall back in the PATTERN; i never moves back
        } else {
            i++;
        }
    }
    return Arrays.copyOf(occ, c);
}
```

Animasyonu oynatarak `i` 'nin (metin işaretçisi) sürekli ileri yürüdüğünü, örüntünün hizalamasının bir uyuşmazlıkta `lps` 'i kullanarak atladığını izleyin — metin asla yeniden taranmaz.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

1. Önce pattern için lps[] tablosu kurulur (önceki animasyon) -- lps = [0, 0, 1, 2, 0, 1, 2, 3, 4]. Şimdi arama: i (metin) yalnız İLERİ gider, hiç geri sarmaz.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

4. text[2] == pattern[2] -- eşleşti, ikisi de bir artar (i=3, j=3).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

7. text[4] = D != pattern[2] = A -- uyuşmazlık, ama j (2) sıfır değil: j = lps[1] = 0. i YERİNDE kalır -- bu karakter yeniden okunmaz.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

11. text[7] == pattern[2] -- eşleşti, ikisi de bir artar (i=8, j=3).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

14. text[8] = C != pattern[0] = A, ve j zaten 0 -- geri düşülecek yer yok: yalnız i bir artar.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

17. text[11] == pattern[1] -- eşleşti, ikisi de bir artar (i=12, j=2).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

20. text[14] == pattern[4] -- eşleşti, ikisi de bir artar (i=15, j=5).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

3. text[1] == pattern[1] -- eşleşti, ikisi de bir artar (i=2, j=2).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

6. text[4] = D != pattern[4] = C -- uyuşmazlık, ama j (4) sıfır değil: j = lps[3] = 2. i YERİNDE kalır -- bu karakter yeniden okunmaz.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

9. text[5] == pattern[0] -- eşleşti, ikisi de bir artar (i=6, j=1).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

12. text[8] = C != pattern[3] = B -- uyuşmazlık, ama j (3) sıfır değil: j = lps[2] = 1. i YERİNDE kalır -- bu karakter yeniden okunmaz.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

15. text[9] = D != pattern[0] = A, ve j zaten 0 -- geri düşülecek yer yok: yalnız i bir artar.

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

19. text[13] == pattern[3] -- eşleşti, ikisi de bir artar (i=14, j=4).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

22. text[16] == pattern[6] -- eşleşti, ikisi de bir artar (i=17, j=7).

```

text[] = 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
         A B A B D A B A C D A B A B C A B A B
pattern[] = 0 1 2 3 4 5 6 7 8
           A B A B C A B A B
lps[] = 0 0 1 2 0 1 2 3 4

```

23. `text[17] == pattern[7]` -- eşleşti, ikisi de bir artar
(`i=18, j=8`).

25. Bitti: `i` yalnız 19 kez ilerledi (metin uzunluğu kadar),
hiç geri gitmedi. 1 oluşum bulundu (10). Toplam süre
 $O(n + m)$.

Seçicide ayrıca `text="AAAAAAAAAAAAAAB"`, `pattern="AAAAB"`: çok sayıda lps geri düşüşü (zor) ve uç durumları hiç bulunmaz, çakışan eşleşmeler, ve `text == pattern`, tek eşleşme, hiç geri düşüş yok deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi metnizi ve örüntünüzü yazın.

8.3 Dene



Tam program: `kmp_search.c` / `KmpSearch.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * KMP search: uses the lps[] failure-function table so the text pointer i never moves backward.
O(n + m).
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXOCC 32

static void compute_lps(const char *pattern, int m, int lps[]) {
    lps[0] = 0;
    int len = 0, i = 1;
    while (i < m) {
        if (pattern[i] == pattern[len]) {
            len++;
            lps[i] = len;
            i++;
        } else if (len != 0) {
            len = lps[len - 1];
        } else {
            lps[i] = 0;
            i++;
        }
    }
}

static int kmp_search(const char *text, int n, const char *pattern, int m, const int lps[], int
occ[]) {
    if (m == 0) { /* the empty pattern matches at every position, including n
*/
        for (int s = 0; s <= n; s++) occ[s] = s;
        return n + 1;
    }
    int i = 0, j = 0, c = 0;
    while (i < n) {
        if (text[i] == pattern[j]) {
            i++; j++;
            if (j == m) {
                occ[c++] = i - m; /* occurrence found; keep scanning */
                j = lps[j - 1];
            }
        } else if (j > 0) {
            j = lps[j - 1]; /* fall back in the PATTERN; i never moves back */
        } else {
            i++;
        }
    }
    return c;
}

static void print_occ(const int occ[], int count) {
    if (count == 0) { printf("(none)"); return; }
    for (int i = 0; i < count; i++) printf("%s%d", i ? ", " : "", occ[i]);
}

static void run_scenario(const char *label, const char *text, const char *pattern) {
    printf("-- %s --\n", label);
    int n = (int) strlen(text), m = (int) strlen(pattern);
    printf("text = \"%s\" (%d letters), pattern = \"%s\" (%d letters)\n", text, n, pattern, m);
    int lps[64];
    compute_lps(pattern, m, lps);
    int occ[MAXOCC];
    int count = kmp_search(text, n, pattern, m, lps, occ);
}

```

```
    printf("occurrences (%d): ", count);  
    print_occ(occ, count);  
    printf("\n\n");  
}  
  
int main(void) {  
    run_scenario("normal: the classic CLRS-style example", "ABABDABACDABABCABAB", "ABABCABAB");  
    run_scenario("hard: many lps fallbacks", "AAAAAAAAAAAAAAB", "AAAAB");  
    run_scenario("edge: never found", "THEQUICKBROWNFOX", "ZEBRA");  
    run_scenario("edge: overlapping matches", "AAAAAAAAA", "AAA");  
    run_scenario("edge: text == pattern, one match, no fallback at all", "ALGORITHMS",  
"ALGORITHMS");  
    return 0;  
}
```

```

/* Week 12 -- Strings: Structures and Algorithms
 * KMP search: uses the lps[] failure-function table so the text pointer i never moves backward.
 * O(n + m).
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.ArrayList;
import java.util.List;

public class KmpSearch {
    static int[] computeLps(String pattern) {
        int m = pattern.length();
        int[] lps = new int[m];
        int len = 0, i = 1;
        while (i < m) {
            if (pattern.charAt(i) == pattern.charAt(len)) {
                len++;
                lps[i] = len;
                i++;
            } else if (len != 0) {
                len = lps[len - 1];
            } else {
                lps[i] = 0;
                i++;
            }
        }
        return lps;
    }

    static List<Integer> kmpSearch(String text, String pattern, int[] lps) {
        int n = text.length(), m = pattern.length(), i = 0, j = 0;
        List<Integer> occ = new ArrayList<>();
        if (m == 0) {
            // the empty pattern matches at every position, including n
            for (int s = 0; s <= n; s++) occ.add(s);
            return occ;
        }
        while (i < n) {
            if (text.charAt(i) == pattern.charAt(j)) {
                i++; j++;
                if (j == m) {
                    occ.add(i - m); // occurrence found; keep scanning
                    j = lps[j - 1];
                }
            } else if (j > 0) {
                j = lps[j - 1]; // fall back in the PATTERN; i never moves back
            } else {
                i++;
            }
        }
        return occ;
    }

    static void runScenario(String label, String text, String pattern) {
        System.out.println("-- " + label + " --");
        System.out.println("text = \"" + text + "\"" + (" " + text.length() + " letters), pattern = "
            + "\"" + pattern + "\"" + (" " + pattern.length() + " letters"));
        int[] lps = computeLps(pattern);
        List<Integer> occ = kmpSearch(text, pattern, lps);
        System.out.print("occurrences (" + occ.size() + "): ");
        if (occ.isEmpty()) System.out.print("(none)");
        else {
            for (int i = 0; i < occ.size(); i++) System.out.print((i > 0 ? ", " : "") +
                occ.get(i));
        }
        System.out.println();
    }
}

```

```

        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: the classic CLRS-style example", "ABABDABACDABABCABAB",
"ABABCABAB");
        runScenario("hard: many lps fallbacks", "AAAAAAAAAAAAAAB", "AAAAB");
        runScenario("edge: never found", "THEQUICKBROWNFOX", "ZEBRA");
        runScenario("edge: overlapping matches", "AAAAAAAAAA", "AAA");
        runScenario("edge: text == pattern, one match, no fallback at all", "ALGORITHMS",
"ALGORITHMS");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x kmp_search.c && /tmp/x
```

Beklenen çıktı:

```

-- normal: the classic CLRS-style example --
text = "ABABDABACDABABCABAB" (19 letters), pattern = "ABABCABAB" (9 letters)
occurrences (1): 10

-- hard: many lps fallbacks --
text = "AAAAAAAAAAAAAAB" (16 letters), pattern = "AAAAB" (5 letters)
occurrences (1): 11

-- edge: never found --
text = "THEQUICKBROWNFOX" (16 letters), pattern = "ZEBRA" (5 letters)
occurrences (0): (none)

-- edge: overlapping matches --
text = "AAAAAAAAAA" (10 letters), pattern = "AAA" (3 letters)
occurrences (8): 0, 1, 2, 3, 4, 5, 6, 7

-- edge: text == pattern, one match, no fallback at all --
text = "ALGORITHMS" (10 letters), pattern = "ALGORITHMS" (10 letters)
occurrences (1): 0

```

```
javac -Xlint:all KmpSearch.java && java KmpSearch
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

8.4 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. $O(n + m)$: `lps[]` 'i kurmak için $O(m)$ (bölüm 7), aramanın kendisi için $O(n)$ — i en fazla n kez ilerler (asla geri gitmez), ve j 'nin geri düşüşleri, tabloyu kurmak için kullanılan aynı amorti edilmiş argümanla sınırlıdır. Bu, **metnin ya da örüntünün içeriğinden bağımsız olarak** geçerlidir — saf aramanın $O(n*m)$ en kötü durumunun aksine, KMP'nin hiç kötü girdisi yoktur.

⚠ Sık yapılan hatalar

- **Bir geri düşüşte i 'yi ilerletmek.** lps 'in tüm amacı, j geri düşerken i 'nin yerinde kalmasıdır — i 'yi de ilerletmek, örüntünün yeni (daha kısa) hizalamasıyla hâlâ karşılaştırılması gereken metin karakterlerini sessizce atlardı.
- **Tam bir eşleşmeden sonra tekrar geri düşmeyi unutmak** (bir oluşumu kaydettikten sonra $j = lps[j-1]$). Bunsuz, bir sonraki karşılaştırma yanlışlıkla örüntünün kendi örtüşmesinden devam etmek yerine $j = m$ 'den yeniden başlar, çakışan oluşumları kaçırır.
- **Farklı bir örüntü için bayat bir $lps[]$ tablosunu yeniden kullanmak.** Tablo, kurulduğu tam örüntüye özgüdür — yanlış tabloyla aramak sessizce yanlış atlama miktarları üretir, çökme değil, bu da bu hatayı fark etmeyi zorlaştırır.

✓ Kendini sına: $O(n + m)$ burada neden mümkün, saf arama için neden değil?



Saf aramanın $O(n*m)$ en kötü durumu, **aynı metin karakterlerinin farklı kaydırmalar arasında yeniden incelenmesinden** gelir — bir uyumsuzluktan sonra, bir sonraki kaydırma, *önceki* kaydırmanın başladığı yerin hemen sonrasında karşılaştırmaya başlar, zaten bakılmış karakterleri yeniden okur. KMP'nin lps tablosu, i 'nin asla geri gitmemesini garanti eder, böylece **hiçbir metin karakteri küçük, sınırlı bir sayıdan fazla karşılaştırılmaz** — toplam karşılaştırma sayısı n 'e (i için) artı m 'e (tabloyu kurmak için) orantılıdır, hiçbir zaman çarpımlarına değil.

9. Rabin-Karp: kayan özet ve sahte isabetler

9.1 Başlangıç sorusu

KMP, saf aramanın en kötü durumunu *nereye* bakılacağı konusunda daha akıllı olarak düzeltir. Michael O. Rabin ve Richard M. Karp, 1987 tarihli bir makalede, tamamen farklı bir yaklaşım aldı: yaygın durumda karakterleri hiç karşılaştırmak yerine, her pencerenin bir **özetini (hash)** örüntünün özetiyle karşılaştırın. İki farklı metin parçası, iyi seçilmiş bir hash ile, neredeyse hiç aynı değere hash'lenmez, böylece bir hash **uyuşmazlığı** bir pencereyi anında, hiç karakter karşılaştırması yapmadan eler. Tek incelik — ve önemlidir — bir hash **eşleşmesinin** yalnız bir *aday* olmasıdır: iki farklı alt-dizgi, prensipte, aynı değere hash'lenebilir (bir **çakışma**, tam olarak Hafta 6'nın hash tablolarındaki gibi), böylece bir oluşum bildirmeden önce karakterler yine de **doğrulanmalıdır**. Doğrulamadan başarısız olan bir hash eşleşmesine **sahte isabet (spurious hit)** denir.

9.2 Fikir: özeti yeniden hesaplamak yerine kaydır

Her karakteri sabit bir $base$ 'te bir basamak gibi ele alın (bu not $base = 31$ kullanır, 'A' 'yı 0. basamak sayar), ve bir pencereyi bir sayının değerini hesaplar gibi hash'leyin: $h = c_0 * base^{(m-1)} + c_1 * base^{(m-2)} + \dots + c_{(m-1)}$, hepsi bir mod üzerinden alınmış. Sıfırdan hesaplandığında, bu pencere başına $O(m)$ 'dir — saf aramadan iyi değil. Hile **kaydırmaktır**: pencereyi bir konum ileri kaydırmak yalnız çıkan karakterin katkısını çıkarır, kalan her terimi $base$ 'in bir gücü kadar kaydırır, ve giren karakteri ekler — bir $O(1)$ güncelleme, $((eskıHash - çıkkanKarakter * base^{(m-1)}) * base + girenKarakter) \bmod mod$, **pencerenin ortasındaki $m-2$ karaktere hiç yeniden bakmadan** hesaplanır. Bu, KMP'nin lps tablosuyla aynı "yapılan işi yeniden yapma" ruhudur, karakter karşılaştırması yerine hash'lemeye uygulanmıştır.

9.3 Bellekte nasıl durur, ve kod

```

long long window_hash(const char *s, int m, long long base, long long mod) {
    long long h = 0;
    for (int k = 0; k < m; k++) h = (h * base + (s[k] - 'A')) % mod;
    return h;
}

void rabin_karp(const char *text, int n, const char *pattern, int m, long long base, long long mod,
int occ[], int *count) {
    long long pHash = window_hash(pattern, m, base, mod);
    long long hPow = 1;
    for (int k = 0; k < m - 1; k++) hPow = (hPow * base) % mod;
    long long tHash = window_hash(text, m, base, mod); /* first window, computed directly */
    int c = 0;
    for (int s = 0; s <= n - m; s++) {
        if (s > 0)
            tHash = ((tHash - (text[s - 1] - 'A') * hPow % mod + mod) * base + (text[s + m - 1] -
            'A')) % mod;
        if (tHash == pHash && strncmp(text + s, pattern, m) == 0) /* VERIFY: hash match is only a
candidate */
            occ[c++] = s;
    }
    *count = c;
}

static long windowHash(String s, int m, long base, long mod) {
    long h = 0;
    for (int k = 0; k < m; k++) h = (h * base + (s.charAt(k) - 'A')) % mod;
    return h;
}

static int[] rabinKarp(String text, String pattern, long base, long mod) {
    int n = text.length(), m = pattern.length(), c = 0;
    long pHash = windowHash(pattern, m, base, mod);
    long hPow = 1;
    for (int k = 0; k < m - 1; k++) hPow = (hPow * base) % mod;
    long tHash = windowHash(text, m, base, mod); // first window, computed directly
    int[] occ = new int[n];
    for (int s = 0; s <= n - m; s++) {
        if (s > 0)
            tHash = ((tHash - (text.charAt(s - 1) - 'A') * hPow % mod + mod) * base + (text.charAt(s
+ m - 1) - 'A')) % mod;
        if (tHash == pHash && text.regionMatches(s, pattern, 0, m)) // VERIFY: hash match is only a
candidate
            occ[c++] = s;
    }
    return Arrays.copyOf(occ, c);
}

```

**Bu notu hazırlarken yakalanan gerçek bir hata**

Yukarıdaki C programının ilk taslağı hash değişkenlerini `long long` yerine `long` olarak bildirmişti. Bu dersin Windows/MinGW araç zincirinde, `long` yalnız **32 bittir**, ve `mod = 1000000007` `base = 31` ile birleşince yaklaşık $3.1 * 10^{10}$ 'a kadar ara çarpımlar (`h * base`) üretir — 32 bitlik bir `long`'un tutabileceğinden daha büyük, hiçbir derleyici uyarısı olmadan sessiz işaretli-tamsayı taşmasına (tanımsız davranış) ve **yanlış bir cevaba** neden olur. C ve Java çıktısını karşılaştırmak bunu hemen yakaladı (Java'nın `long`'u *her zaman* 64 bittir, böylece Java sürümü baştan itibaren doğrudur). Ders geneller: C'de **`long` 'un 64 bit anlamına geldiğini asla varsaymayın** — boyutu platforma bağlıdır; gerçekten 64 bite ihtiyaç duyduğunuzda `long long`'u (C99'dan beri en az 64 bit garantili) ya da `int64_t`'yi (`<stdint.h>`'den) kullanın.

Animasyonu oynatarak her pencerenin özetinin öncekini ileri kaydırarak hesaplandığını, ve — "zor" ve "hiç gerçek eşleşme yok" örneklerinde — bir hash eşleşmesinin yine de karakter-karakter doğrulamada başarısız olduğunu, bir **sahte isabeti**, izleyin.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

1. pattern'in özeti bir kez hesaplanır: $H(\text{pattern}) = 60$. Her pencerenin özeti bununla karşılaştırılacak.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 43

2. İlk pencere $\text{text}[0..4] = \text{"HELLO"}$ için özet doğrudan hesaplanır: 43.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 43

izlenler farklı -- bu karşılaştırma gereksizdir

3. $H(\text{window}) = 43 \neq H(\text{pattern}) = 60$ -- kesinlikle eşleşemez, hiçbir karakter karşılaştırılmaz.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 84

izlenler farklı -- bu karşılaştırma gereksizdir

4. Pencere kayar: H'nin katkısı çıkarılır, W eklenir -- yeniden baştan hesaplamadan, $O(1)$: 43 -> 84.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 84

izlenler farklı -- bu karşılaştırma gereksizdir

5. $H(\text{window}) = 84 \neq H(\text{pattern}) = 60$ -- kesinlikle eşleşemez, hiçbir karakter karşılaştırılmaz.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 16

izlenler farklı -- bu karşılaştırma gereksizdir

6. Pencere kayar: E'nin katkısı çıkarılır, O eklenir -- yeniden baştan hesaplamadan, $O(1)$: 84 -> 16.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 16

izlenler farklı -- bu karşılaştırma gereksizdir

7. $H(\text{window}) = 16 \neq H(\text{pattern}) = 60$ -- kesinlikle eşleşemez, hiçbir karakter karşılaştırılmaz.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 74

izlenler farklı -- bu karşılaştırma gereksizdir

8. Pencere kayar: L'nin katkısı çıkarılır, R eklenir -- yeniden baştan hesaplamadan, $O(1)$: 16 -> 74.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 74

izlenler farklı -- bu karşılaştırma gereksizdir

9. $H(\text{window}) = 74 \neq H(\text{pattern}) = 60$ -- kesinlikle eşleşemez, hiçbir karakter karşılaştırılmaz.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 48

izlenler farklı -- bu karşılaştırma gereksizdir

10. Pencere kayar: L'nin katkısı çıkarılır, L eklenir -- yeniden baştan hesaplamadan, $O(1)$: 74 -> 48.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 48

izlenler farklı -- bu karşılaştırma gereksizdir

11. $H(\text{window}) = 48 \neq H(\text{pattern}) = 60$ -- kesinlikle eşleşemez, hiçbir karakter karşılaştırılmaz.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 60

izlenler farklı -- bu karşılaştırma gereksizdir

12. Pencere kayar: O'nin katkısı çıkarılır, D eklenir -- yeniden baştan hesaplamadan, $O(1)$: 48 -> 60.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

H(window) = 60

izlenler aynı! 5'i düşeriz sadece -- GİZLİLEŞME

13. $H(\text{window}) == H(\text{pattern})$ -- aday! Karakter karakter DOĞRULAMA: "WORLD" == "WORLD" -- gerçek eşleşme. s = 5.

base = 31, mod = 101, m(pattern) = 60

text[] =

0	1	2	3	4	5	6	7	8	9
H	E	L	L	O	W	O	R	L	D

pattern[] =

0	1	2	3	4
W	O	R	L	D

14. Bitti: 6 pencere denendi, 1 gerçek eşleşme (5), 0 sahte isabet. Ortalama $O(n + m)$; kötü durumda (çok sahte isabet) $O(n*m)$ 'e vaklasabilir.

Seçicide ayrıca **mod=7 (küçük): 1 gerçek + 2 sahte isabet (zor)** ve uç durumları **mod=7: hiç gerçek eşleşme yok ama 3 sahte özet çakışması var, her yerde gerçek çakışan bir eşleşme**, ve **mod = 1.000.000.007 (büyük asal): sahte isabet neredeyse imkansız** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi metninizi, örüntünüzü ve modülünüzü yazın.

9.4 Dene



Tam program: `rabin_karp.c` / `RabinKarp.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * Rabin-Karp search: compare a rolling hash of each window against the pattern's hash; a hash
match is only
 * a candidate and must be VERIFIED character by character (a "spurious hit" is a hash match that
fails
 * verification).
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXOCC 32

static long long window_hash(const char *s, int m, long long base, long long mod) {
    long long h = 0;
    for (int k = 0; k < m; k++) h = (h * base + (s[k] - 'A')) % mod;
    return h;
}

static int rabin_karp(const char *text, int n, const char *pattern, int m, long long base, long
long mod, int occ[], int *spurious) {
    int c = 0;
    *spurious = 0;
    if (m == 0) { /* the empty pattern matches at every position, including n
*/
        for (int s = 0; s <= n; s++) occ[s] = s;
        return n + 1;
    }
    if (n < m) return 0; /* pattern longer than the text: no window fits, nothing to
hash */
    long long p_hash = window_hash(pattern, m, base, mod);
    long long h_pow = 1;
    for (int k = 0; k < m - 1; k++) h_pow = (h_pow * base) % mod;
    long long t_hash = window_hash(text, m, base, mod); /* first window, computed directly
*/
    for (int s = 0; s <= n - m; s++) {
        if (s > 0)
            t_hash = ((t_hash - (text[s - 1] - 'A') * h_pow % mod + mod) * base + (text[s + m -
1] - 'A')) % mod;
        if (t_hash == p_hash) { /* candidate: VERIFY before counting it
*/
            if (strncmp(text + s, pattern, (size_t) m) == 0)
                occ[c++] = s;
            else
                (*spurious)++;
        }
    }
    return c;
}

static void print_occ(const int occ[], int count) {
    if (count == 0) { printf("(none)"); return; }
    for (int i = 0; i < count; i++) printf("%s%d", i ? ", " : "", occ[i]);
}

static void run_scenario(const char *label, const char *text, const char *pattern, long long
base, long long mod) {
    printf("-- %s --\n", label);
    int n = (int) strlen(text), m = (int) strlen(pattern);
    printf("text = \"%s\" (%d letters), pattern = \"%s\" (%d letters), base=%lld, mod=%lld\n",
text, n, pattern, m, base, mod);
    int occ[MAXOCC], spurious;
    int count = rabin_karp(text, n, pattern, m, base, mod, occ, &spurious);
    printf("occurrences (%d): ", count);
}

```

```
    print_occ(occ, count);
    printf(", spurious hits: %d\n\n", spurious);
}

int main(void) {
    run_scenario("normal: mod=101, no spurious hits", "HELLOWORLD", "WORLD", 31, 101);
    run_scenario("hard: mod=7 (small), 1 genuine + 2 spurious hits", "AADBDDBCDBB", "AAD", 4, 7);
    run_scenario("edge: mod=7, no genuine match but 3 spurious collisions", "DBCADADABDC", "BAD",
4, 7);
    run_scenario("edge: a genuine overlapping match everywhere", "AAAAAAAAA", "AAA", 31, 101);
    run_scenario("edge: mod=1000000007 (large prime), a spurious hit is practically impossible",
"ALGORITHMS", "RITHM", 31, 1000000007);
    return 0;
}
```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Rabin-Karp search: compare a rolling hash of each window against the pattern's hash; a hash
match is only
 * a candidate and must be VERIFIED character by character (a "spurious hit" is a hash match that
fails
 * verification).
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.ArrayList;
import java.util.List;

public class RabinKarp {
    static long windowHash(String s, int m, long base, long mod) {
        long h = 0;
        for (int k = 0; k < m; k++) h = (h * base + (s.charAt(k) - 'A')) % mod;
        return h;
    }

    static class Result {
        List<Integer> occurrences = new ArrayList<>();
        int spurious = 0;
    }

    static Result rabinKarp(String text, String pattern, long base, long mod) {
        int n = text.length(), m = pattern.length();
        Result r = new Result();
        if (m == 0) { // the empty pattern matches at every position, including n
            for (int s = 0; s <= n; s++) r.occurrences.add(s);
            return r;
        }
        if (n < m) return r; // pattern longer than the text: no window fits, nothing to
hash
        long pHash = windowHash(pattern, m, base, mod);
        long hPow = 1;
        for (int k = 0; k < m - 1; k++) hPow = (hPow * base) % mod;
        long tHash = windowHash(text, m, base, mod); // first window, computed directly
        for (int s = 0; s <= n - m; s++) {
            if (s > 0)
                tHash = ((tHash - (text.charAt(s - 1) - 'A') * hPow % mod + mod) * base +
(text.charAt(s + m - 1) - 'A')) % mod;
            if (tHash == pHash) { // candidate: VERIFY before counting
it
                if (text.regionMatches(s, pattern, 0, m)) r.occurrences.add(s);
                else r.spurious++;
            }
        }
        return r;
    }

    static void runScenario(String label, String text, String pattern, long base, long mod) {
        System.out.println("-- " + label + " --");
        System.out.println("text = \"" + text + "\" (" + text.length() + " letters), pattern =
\"" + pattern + "\" (" + pattern.length() + " letters), base=" + base + ", mod=" + mod);
        Result r = rabinKarp(text, pattern, base, mod);
        System.out.print("occurrences (" + r.occurrences.size() + "): ");
        if (r.occurrences.isEmpty()) System.out.print("(none)");
        else {
            for (int i = 0; i < r.occurrences.size(); i++) System.out.print((i > 0 ? ", " : "") +
r.occurrences.get(i));
        }
        System.out.println(", spurious hits: " + r.spurious);
        System.out.println();
    }
}

```

```

public static void main(String[] args) {
    runScenario("normal: mod=101, no spurious hits", "HELLOWORLD", "WORLD", 31, 101);
    runScenario("hard: mod=7 (small), 1 genuine + 2 spurious hits", "AADBDBCDBB", "AAD", 4,
7);
    runScenario("edge: mod=7, no genuine match but 3 spurious collisions", "DBCADADABDC",
"BAD", 4, 7);
    runScenario("edge: a genuine overlapping match everywhere", "AAAAAAAAA", "AAA", 31,
101);
    runScenario("edge: mod=100000007 (large prime), a spurious hit is practically
impossible", "ALGORITHMS", "RITHM", 31, 100000007L);
}
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x rabin_karp.c && /tmp/x
```

Beklenen çıktı:

```

-- normal: mod=101, no spurious hits --
text = "HELLOWORLD" (10 letters), pattern = "WORLD" (5 letters), base=31, mod=101
occurrences (1): 5, spurious hits: 0

-- hard: mod=7 (small), 1 genuine + 2 spurious hits --
text = "AADBDBCDBB" (11 letters), pattern = "AAD" (3 letters), base=4, mod=7
occurrences (1): 0, spurious hits: 2

-- edge: mod=7, no genuine match but 3 spurious collisions --
text = "DBCADADABDC" (11 letters), pattern = "BAD" (3 letters), base=4, mod=7
occurrences (0): (none), spurious hits: 3

-- edge: a genuine overlapping match everywhere --
text = "AAAAAAAAA" (10 letters), pattern = "AAA" (3 letters), base=31, mod=101
occurrences (8): 0, 1, 2, 3, 4, 5, 6, 7, spurious hits: 0

-- edge: mod=100000007 (large prime), a spurious hit is practically impossible --
text = "ALGORITHMS" (10 letters), pattern = "RITHM" (5 letters), base=31, mod=100000007
occurrences (1): 4, spurious hits: 0

```

```
javac -Xlint:all RabinKarp.java && java RabinKarp
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

9.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. Ortalama durum $O(n + m)$: örüntüyü ve ilk pencereyi hash'lemek için $O(m)$, sonraki her pencere için $O(1)$ (kaydıran güncelleme), artı özeti gerçekten eşleşen ender pencereler için **yalnız** $O(m)$ (iyi seçilmiş büyük bir asal modül, pratikte sahte isabetleri yok denecek kadar azaltır). En kötü durum, modül küçük ya da kötü seçilmişse ve *her* pencere çıkışırsa $O(n \cdot m)$ 'e doğru bozulur — tam olarak yukarıdaki "zor" ve "hiç gerçek eşleşme yok" senaryolarının, bilerek $\text{mod} = 7$ kullanarak bu en kötü durumu görünür kıldığı yer.



Sık yapılan hatalar

- **Doğrulamayı atlamak.** Bir eşleşmeyi yalnız hash eşitliğiyle, `strcmp` ya da `regionMatches` ile doğrulamadan bildirmek, sahte isabetleri sessizce gerçek oluşumlar olarak bildirir — doğruluk, yalnız verimlilik değil, her adayın doğrulanmasına bağlıdır.
- **"Basitlik için" çok küçük bir modül kullanmak.** Küçük bir `mod` (bu bölümün bilerek gösterdiği gibi) sık sahte isabetlere neden olur, Rabin-Karp'ın ortalama-durum avantajını yok eder; üretim kodu büyük bir asal, sıkça düşmanca girdilere karşı savunmak için rastgele bir tabanla birlikte kullanır.
- **Aritmetik için çok dar sabit genişlikli bir tür kullanmak,** tam olarak yukarıda kutulanmış `long -e- long long` hatası. Bir hash uygulamasının ara değerlerinin seçilen türü taşamayacağını her zaman doğrulayın, özellikle C'de tamsayı genişliği platforma bağlıdır.



Kendini sına: bir hash eşleşmesi neden her zaman doğrulanmalıdır?



Bir hash fonksiyonu, olası alt-dizgilerin (genellikle devasa) uzayını, `mod` olası hash değerinden oluşan küçük bir kümeye eşler, güvercin yuvası ilkesiyle (pigeonhole principle) bazı farklı alt-dizgilerin bir hash değerini paylaşmak zorunda olduğunu garanti eder, olası alt-dizgi sayısı `mod` 'un izin verdiği kadar fazla olduğunda. İki farklı alt-dizginin aynı değere hash'lenmesi — bir çakışma — bu yüzden bir hata değil, bazı girdiler için matematiksel bir kesinliktir; gerçek bir eşleşmeyi bir sahte olandan ayırt etmenin tek yolu gerçek karakterleri karşılaştırmaktır.

10. Boyer-Moore: kötü karakter kuralı

10.1 Başlangıç sorusu

Şimdiye kadarki her algoritma örüntüyü her pencereyle **soldan sağa** karşılaştırır. Robert S. Boyer ve J Strother Moore, 1977 tarihli bir makalede, ilk bakışta neredeyse tersmiş gibi görünen bir şey fark etti: bunun yerine **sağdan sola** karşılaştırmak, tek bir uyuşmazlığın metnin potansiyel olarak büyük bir uzanımı hakkında bilgiyi bir kerede atmasına izin verir, birden fazla konumluk atlamaları — bazen örüntünün tüm uzunluğu kadar büyük — mümkün kılar. Bu not, Boyer-Moore'un iki kuralından yalnız daha basit olanını, **kötü karakter kuralını** kapsar (tam algoritma bunun üzerine bu dersin kapsamı dışında olan ikinci bir "iyi sonek" kuralı ekler).

10.2 Fikir: geriye tara, sonra az önce gördüğünü kullanarak atla

`pattern[m-1]` 'i önce `text[s+m-1]` ile karşılaştırmak, sonra `pattern[m-2]` 'yi `text[s+m-2]` ile, ve böyle devam edin, **sağdan sola**. `ch` metin karakterine karşı `j` örüntü konumunda bir uyuşmazlıkta, `ch` 'nin örüntüdeki **son** oluşumuna bakın (arama başlamadan önce bir kez önceden hesaplanmış): `ch` örüntüde hiç geçmiyorsa, tüm örüntü onun **ötesine** güvenle atlayabilir — olası en büyük atlama, `j + 1` konum. `ch` örüntüde geçiyor ama yalnız `j` konumunun **solunda** ise, örüntü o oluşumu `ch` ile hizalayacak kadar kaydırılır. Atlama asla 1'den küçük olmasına izin verilmez (0 ya da negatif bir "atlama" yerinde durmak ya da geri gitmek anlamına gelirdi).

10.3 Bellekte nasıl durur, ve kod

```

void bad_char_table(const char *pattern, int m, int last[256]) {
    for (int c = 0; c < 256; c++) last[c] = -1;
    for (int j = 0; j < m; j++) last[(unsigned char) pattern[j]] = j;
}

void boyer_moore_bad_char(const char *text, int n, const char *pattern, int m, const int last[256],
int occ[], int *count) {
    int s = 0, c = 0;
    while (s <= n - m) {
        int j = m - 1;
        while (j >= 0 && pattern[j] == text[s + j]) j--; /* compare RIGHT to LEFT */
        if (j < 0) {
            occ[c++] = s; /* full match at shift s */
            s += 1;
        } else {
            int lo = last[(unsigned char) text[s + j]];
            int shift = j - lo;
            s += shift > 1 ? shift : 1; /* always advance by at least 1 */
        }
    }
    *count = c;
}

static Map<Character, Integer> badCharTable(String pattern) {
    Map<Character, Integer> last = new HashMap<>();
    for (int j = 0; j < pattern.length(); j++) last.put(pattern.charAt(j), j);
    return last;
}

static int[] boyerMooreBadChar(String text, String pattern, Map<Character, Integer> last) {
    int n = text.length(), m = pattern.length(), s = 0, c = 0;
    int[] occ = new int[n];
    while (s <= n - m) {
        int j = m - 1;
        while (j >= 0 && pattern.charAt(j) == text.charAt(s + j)) j--; // compare RIGHT to LEFT
        if (j < 0) {
            occ[c++] = s; // full match at shift s
            s += 1;
        } else {
            int lo = last.getOrDefault(text.charAt(s + j), -1);
            int shift = j - lo;
            s += shift > 1 ? shift : 1; // always advance by at least 1
        }
    }
    return Arrays.copyOf(occ, c);
}

```

Animasyonu oynatarak karşılaştırmanın örüntünün sağ ucundan geriye doğru çalıştığını, ve uyuşmayan metin karakteri örüntüde nadirse ya da hiç yoksa örüntünün bir konumdan fazla ileri atladığını izleyin.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 0$

1. Kötü karakter tablosu (yalnız örüntüdeki harfler için): $\text{last}[c] = 0$ harfin örüntüdeki EN SAĞDAKİ konumu. A=0 B=1 C=2 (yoksa -1).

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' != 'A'
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 0$

2. $\text{pattern}[2] = C \neq \text{text}[2] = A$ -- uyuşmazlık, bu pencere bitti.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' != 'A'
 $\text{last}[A] = 0 \rightarrow \text{atla } 2$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 0$

3. $\text{text}[2] = A$, $\text{last}[A] = 0$ -- $\text{shift} = 2 - 0 = 2$. Örüntü 2 konum kaydırılır.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' != 'A'
 $\text{last}[A] = 0 \rightarrow \text{atla } 2$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 2$

4. $\text{pattern}[2] = C \neq \text{text}[4] = A$ -- uyuşmazlık, bu pencere bitti.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' != 'A'
 $\text{last}[A] = 0 \rightarrow \text{atla } 2$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 2$

5. $\text{text}[4] = A$, $\text{last}[A] = 0$ -- $\text{shift} = 2 - 0 = 2$. Örüntü 2 konum kaydırılır.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' == 'C'
 $\text{last}[A] = 0 \rightarrow \text{atla } 2$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 4$

6. sağdan sola, $\text{pattern}[2] = C == \text{text}[6]$ -- eşleşti, sola devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'B' == 'B'
 $\text{last}[A] = 0 \rightarrow \text{atla } 2$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 4$

7. sağdan sola, $\text{pattern}[1] = B == \text{text}[5]$ -- eşleşti, sola devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'A' == 'A'
 $\text{last}[A] = 0 \rightarrow \text{atla } 2$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 4$

8. sağdan sola, $\text{pattern}[0] = A == \text{text}[4]$ -- eşleşti, sola devam.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'A' == 'A'
 $\text{tüm örüntü eşleşti -- bulundu!}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 4$

9. $j < 0$: örüntünün tamamı eşleşti -- $s = 4$ 'te bulundu. s bir artar.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' != 'D'
 $\text{tüm örüntü eşleşti -- bulundu!}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 5$

10. $\text{pattern}[2] = C \neq \text{text}[7] = D$ -- uyuşmazlık, bu pencere bitti.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$ 'C' != 'D'
 $\text{last}[D] = -1 \rightarrow \text{atla } 3$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 5$

11. $\text{text}[7] = D$, $\text{last}[D] = -1$ [object Object] -- $\text{shift} = 2 - (-1) = 3$. Örüntü 3 konum kaydırılır.

$\text{text}[] = \begin{matrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ A & B & A & A & A & B & C & D & A & B \end{matrix}$
 $\text{pattern}[] = \begin{matrix} 0 & 1 & 2 \\ A & B & C \end{matrix}$
 $\text{shift } s = 5$

12. Bitti: 1 oluşum bulundu (4). Kötü karakter kuralı, geniş alfabede sık büyük atlamalar sağlar -- en iyi durumda $O(n/m)$.

Seçicide ayrıca **düşük çeşitlilik, zayıf atlamalar** (zor) ve uç durumları **hiç bulunmaz, Z örüntüde yok — her seferinde en büyük atlama**, ve **eşleşme sona yakın** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi metninizi ve örüntünüzü yazın.

10.4 Dene

**Tam program:** `boyer_moore_bad_character.c` / `BoyerMooreBadCharacter.java`

```

/* Week 12 -- Strings: Structures and Algorithms
 * Boyer-Moore, bad-character rule only: compare the pattern to each window RIGHT to LEFT; on a
 mismatch, use
 * the mismatched character's last occurrence in the pattern to jump forward as far as safely
 possible.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXOCC 32

static void bad_char_table(const char *pattern, int m, int last[256]) {
    for (int c = 0; c < 256; c++) last[c] = -1;
    for (int j = 0; j < m; j++) last[(unsigned char) pattern[j]] = j;
}

static int boyer_moore_bad_char(const char *text, int n, const char *pattern, int m, const int
last[256], int occ[]) {
    int s = 0, c = 0;
    while (s <= n - m) {
        int j = m - 1;
        while (j >= 0 && pattern[j] == text[s + j]) j--; /* compare RIGHT to LEFT */
        if (j < 0) {
            occ[c++] = s; /* full match at shift s */
            s += 1;
        } else {
            int lo = last[(unsigned char) text[s + j]];
            int shift = j - lo;
            s += shift > 1 ? shift : 1; /* always advance by at least 1 */
        }
    }
    return c;
}

static void print_occ(const int occ[], int count) {
    if (count == 0) { printf("(none)"); return; }
    for (int i = 0; i < count; i++) printf("%s%d", i ? ", " : "", occ[i]);
}

static void run_scenario(const char *label, const char *text, const char *pattern) {
    printf("-- %s --\n", label);
    int n = (int) strlen(text), m = (int) strlen(pattern);
    printf("text = \"%s\" (%d letters), pattern = \"%s\" (%d letters)\n", text, n, pattern, m);
    int last[256];
    bad_char_table(pattern, m, last);
    int occ[MAXOCC];
    int count = boyer_moore_bad_char(text, n, pattern, m, last, occ);
    printf("occurrences (%d): ", count);
    print_occ(occ, count);
    printf("\n\n");
}

int main(void) {
    run_scenario("normal: mixed-size jumps", "ABAAABCDAB", "ABC");
    run_scenario("hard: low diversity, weak jumps", "AAAAAAAAA", "AAAB");
    run_scenario("edge: never found", "THEQUICKBROWNFOX", "ZEBRA");
    run_scenario("edge: Z is not in the pattern -- the biggest possible jump every time",
"ZZZZZZZZZ", "ABC");
    run_scenario("edge: the match is near the end", "XXXXXXXABC", "ABC");
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Boyer-Moore, bad-character rule only: compare the pattern to each window RIGHT to LEFT; on a
mismatch, use
 * the mismatched character's last occurrence in the pattern to jump forward as far as safely
possible.
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.ArrayList;
import java.util.HashMap;
import java.util.List;
import java.util.Map;

public class BoyerMooreBadCharacter {
    static Map<Character, Integer> badCharTable(String pattern) {
        Map<Character, Integer> last = new HashMap<>();
        for (int j = 0; j < pattern.length(); j++) last.put(pattern.charAt(j), j);
        return last;
    }

    static List<Integer> boyerMooreBadChar(String text, String pattern, Map<Character, Integer>
last) {
        int n = text.length(), m = pattern.length(), s = 0;
        List<Integer> occ = new ArrayList<>();
        while (s <= n - m) {
            int j = m - 1;
            while (j >= 0 && pattern.charAt(j) == text.charAt(s + j)) j--; // compare RIGHT to
LEFT
            if (j < 0) {
                occ.add(s); // full match at shift s
                s += 1;
            } else {
                int lo = last.getOrDefault(text.charAt(s + j), -1);
                int shift = j - lo;
                s += shift > 1 ? shift : 1; // always advance by at least 1
            }
        }
        return occ;
    }

    static void runScenario(String label, String text, String pattern) {
        System.out.println("-- " + label + " --");
        System.out.println("text = \"" + text + "\" (" + text.length() + " letters), pattern =
\"" + pattern + "\" (" + pattern.length() + " letters)");
        Map<Character, Integer> last = badCharTable(pattern);
        List<Integer> occ = boyerMooreBadChar(text, pattern, last);
        System.out.print("occurrences (" + occ.size() + "): ");
        if (occ.isEmpty()) System.out.print("(none)");
        else {
            for (int i = 0; i < occ.size(); i++) System.out.print((i > 0 ? ", " : "") +
occ.get(i));
        }
        System.out.println();
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: mixed-size jumps", "ABAAABCDAB", "ABC");
        runScenario("hard: low diversity, weak jumps", "AAAAAAAAA", "AAB");
        runScenario("edge: never found", "THEQUICKBROWNFOX", "ZEBRA");
        runScenario("edge: Z is not in the pattern -- the biggest possible jump every time",
"ZZZZZZZZZ", "ABC");
        runScenario("edge: the match is near the end", "XXXXXXABC", "ABC");
    }
}

```

```
}  
}
```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x boyer_moore_bad_character.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: mixed-size jumps --  
text = "ABAAABCDAB" (10 letters), pattern = "ABC" (3 letters)  
occurrences (1): 4  
  
-- hard: low diversity, weak jumps --  
text = "AAAAAAAAAA" (10 letters), pattern = "AAAB" (4 letters)  
occurrences (0): (none)  
  
-- edge: never found --  
text = "THEQUICKBROWNFOX" (16 letters), pattern = "ZEBRA" (5 letters)  
occurrences (0): (none)  
  
-- edge: Z is not in the pattern -- the biggest possible jump every time --  
text = "ZZZZZZZZZZ" (10 letters), pattern = "ABC" (3 letters)  
occurrences (0): (none)  
  
-- edge: the match is near the end --  
text = "XXXXXXXABC" (10 letters), pattern = "ABC" (3 letters)  
occurrences (1): 7
```

```
javac -Xlint:all BoyerMooreBadCharacter.java && java BoyerMooreBadCharacter
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

10.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. En iyi durum $O(n/m)$ — alfabe zenginse ve uyumsuzluklar örüntüde bulunmayan karakterlerde hemen olursa, her pencere tam örüntü uzunluğunca atlayabilir. En kötü durum $O(n*m)$ (yalnız kötü karakter kuralı, iyi sonek kuralı olmadan, düşük çeşitlilikli metinde bozulabilir — yukarıdaki "zor" senaryo, alfabe yalnız iki farklı harf içerdiğinde atlama miktarlarının 1'e doğru küçüldüğünü gösterir). Boyer-Moore varyantları, pratikte, doğal dil metni ve büyük alfabeler için en hızlı dizgi arama algoritmaları arasındadır, tam olarak gerçek metnin en kötü durumu nadiren tetiklemesi nedeniyle.



Sık yapılan hatalar

- **shift >= 1 korumasını unutmak.** Kötü karakterin son oluşumu geçerli uyumsuzluk konumu `j` 'nin **sağındaysa** (örüntü tekrarlı karakterler içerdiğinde mümkün), `j - 1` **sıfır ya da negatif** olabilir — en az 1'e kırpmadan, örüntü yerinde kalır ya da geriye gider, sonsuza dek döngüye girer.
- **Kötü karakter tablosunu metinden, örüntüden değil, kurmak.** Tablo "bu karakter *örüntüde* en son nerede geçer?" sorusunu yanıtlar — tam olarak KMP'nin `lps` tablosu gibi yalnız örüntüden bir kez kurulur, her pencerede değişmeden yeniden kullanılır.
- **Alışkanlıkla soldan sağa karşılaştırmak.** Boyer-Moore'un tüm avantajı **sağdan sola** karşılaştırmaktan gelir — bunun yerine soldan sağa karşılaştırmak yine de doğru eşleşmeler üretir ama algoritmanın tüm amacı olan büyük-atlama faydasını atar.



Kendini sına: Boyer-Moore, saf aramanın incelemek zorunda olduğu karakterleri neden atlayabilir?



Çünkü tek bir sağdan sola karşılaştırma, bir uyumsuzlukta, algoritmanın hemen üzerinde muhakeme edebileceği bir metin karakterini ortaya çıkarır: "bu karakter *örüntüde* en son nerede geçerse (hiç geçmiyorsa), örüntü onunla hizalanacak şekilde yeniden konumlandırılmalıdır — daha yakın hiçbir yer bir eşleşme üretemez." O tek bilgi parçası, algoritmanın eşleşme içermediğini *kanıtlayabildiği* birkaç metin konumunu, atlanan konumlardaki karakterlere hiç bakmadan atlamasına izin verir — saf aramanın soldan sağa, bir seferde bir konumluk yaklaşımının hiçbir şekilde yapamadığı bir şey.

11. Z algoritması

11.1 Başlangıç sorusu

Şimdiye kadarki her algoritma kendi özel defter tutmasını kurar — KMP için `lps[]`, Rabin-Karp için kayan bir özet, Boyer-Moore için bir kötü karakter tablosu. **Z algoritması** farklı, neredeyse el çabukluğu gibi bir yaklaşım alır: tüm arama problemini tek bir dizinin **tek bir kendisiyle karşılaştırmasına** indirir, ve cevabı doğrudan sonuçtan okur.

11.2 Fikir: $Z[i]$, " $S[i..]$, S 'in kendisiyle ne kadar eşleşir?" demektir

Herhangi bir S dizisi için, $Z[i]$ 'yi ($i \geq 1$ için) $S[i]$ 'de başlayan, aynı zamanda S 'nin de bir öneki olan en uzun alt-dizinin uzunluğu olarak tanımlayın — başka bir deyişle, " $S[i..]$, S 'nin kendisiyle, baştan sayarak, kaç karakter paylaşır?" Şimdi $S = \text{pattern} + \# + \text{text}$ olsun, burada $\#$ her iki dizinin de hiçbir yerinde geçmeyeceği garanti edilen bir ayraç karakteridir. S 'nin **metin** kısmındaki herhangi bir i konumu, $Z[i] \geq |\text{pattern}|$ ile, oradan başlayan metnin S 'nin kendi başlangıcıyla en az $|\text{pattern}|$ karakter paylaştığı anlamına gelir — bu tam olarak pattern 'in kendisidir, böylece bu bir oluşumdur. Tüm $Z[]$ dizisini $O(n + m)$ sürede hesaplamak, *şimdiye kadar* bulunan en sağdaki eşleşmeyi hatırlayan çalışan bir $[l, r]$ penceresi kullanır: i , o pencerenin içine düştüğünde, $Z[i]$ sıfırdan karşılaştırmak yerine zaten bilinen $Z[i-1]$ değerini yeniden kullanabilir, ve yalnız r 'nin ötesine taşabilecek kısım karakter karakter kontrol edilir — KMP'yi ve Rabin-Karp'ı hızlı yapan aynı "zaten bildiğini hatırla" ruhu.

11.3 Bellekte nasıl durur, ve kod

```
int *z_array(const char *s, int n) {
    int *z = calloc(n, sizeof(int));
    int l = 0, r = 0;
    for (int i = 1; i < n; i++) {
        if (i < r)
            z[i] = (r - i < z[i - 1]) ? r - i : z[i - 1];    /* reuse the [l,r) window */
        while (i + z[i] < n && s[z[i]] == s[i + z[i]])
            z[i]++;                                          /* extend by direct comparison */
        if (i + z[i] > r) { l = i; r = i + z[i]; }          /* window grew: remember it */
    }
    return z;
}

static int[] zArray(String s) {
    int n = s.length();
    int[] z = new int[n];
    int l = 0, r = 0;
    for (int i = 1; i < n; i++) {
        if (i < r)
            z[i] = Math.min(r - i, z[i - 1]);    // reuse the [l,r) window
        while (i + z[i] < n && s.charAt(z[i]) == s.charAt(i + z[i]))
            z[i]++;                                // extend by direct comparison
        if (i + z[i] > r) { l = i; r = i + z[i]; } // window grew: remember it
    }
    return z;
}
```

Animasyonu oynatarak `[l, r)` penceresinin büyüdüğünü, içine düşen sonraki konumlar için yeniden kullanıldığını, ve KMP ile Rabin-Karp'ın bulduğu aynı oluşumları, tamamen farklı bir yoldan, ürettiğini izleyin.

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

--	--	--	--	--	--	--	--	--	--	--	--	--

1. S = "AB#ABABABABAB" (uzunluk 13). Z[0] hiç kullanılmaz; i = 1'den başlarız, pencere [l, r) = [0, 0) -- boş.

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0												
---	--	--	--	--	--	--	--	--	--	--	--	--

 Z[1] = 0
pencere -> [1, 1)

2. i = 1: i >= r -- 0'dan başlarız, hiç ek karşılaştırma gerekmeden Z[1] = 0 bulunur. Pencere büyüdü: [l,r) = [1, 1).

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0											
---	---	--	--	--	--	--	--	--	--	--	--	--

 Z[2] = 0
pencere -> [2, 2)

3. i = 2: i >= r -- 0'dan başlarız, hiç ek karşılaştırma gerekmeden Z[2] = 0 bulunur. Pencere büyüdü: [l,r) = [2, 2).

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0										
---	---	---	--	--	--	--	--	--	--	--	--	--

 Z[3] = 2
pencere -> [3, 5)

4. i = 3: i >= r -- 0'dan başlarız, 2 doğrudan karşılaştırmayla Z[3] = 2 bulunur. Pencere büyüdü: [l,r) = [3, 5).

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0									
---	---	---	---	--	--	--	--	--	--	--	--	--

 Z[4] = 0
pencere değişmedi

5. i = 4: i < r (4 < 5) -- pencereden min(r-i, Z[i-l]) = 0 ile başlarız, hiç ek karşılaştırma gerekmeden Z[4] = 0 bulunur.

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0								
---	---	---	---	---	--	--	--	--	--	--	--	--

 Z[5] = 2
pencere -> [5, 7)

6. i = 5: i >= r -- 0'dan başlarız, 2 doğrudan karşılaştırmayla Z[5] = 2 bulunur. Pencere büyüdü: [l,r) = [5, 7).

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0	0							
---	---	---	---	---	---	--	--	--	--	--	--	--

 Z[6] = 0
pencere değişmedi

7. i = 6: i < r (6 < 7) -- pencereden min(r-i, Z[i-l]) = 0 ile başlarız, hiç ek karşılaştırma gerekmeden Z[6] = 0 bulunur.

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0	0	0						
---	---	---	---	---	---	---	--	--	--	--	--	--

 Z[7] = 2
pencere -> [7, 9)

8. i = 7: i >= r -- 0'dan başlarız, 2 doğrudan karşılaştırmayla Z[7] = 2 bulunur. Pencere büyüdü: [l,r) = [7, 9).

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0	0	0	0					
---	---	---	---	---	---	---	---	--	--	--	--	--

 Z[8] = 0
pencere değişmedi

9. i = 8: i < r (8 < 9) -- pencereden min(r-i, Z[i-l]) = 0 ile başlarız, hiç ek karşılaştırma gerekmeden Z[8] = 0 bulunur.

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0	0	0	0	0				
---	---	---	---	---	---	---	---	---	--	--	--	--

 Z[9] = 2
pencere -> [9, 11)

10. i = 9: i >= r -- 0'dan başlarız, 2 doğrudan karşılaştırmayla Z[9] = 2 bulunur. Pencere büyüdü: [l,r) = [9, 11).

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0	0	0	0	0	0			
---	---	---	---	---	---	---	---	---	---	--	--	--

 Z[10] = 0
pencere değişmedi

11. i = 10: i < r (10 < 11) -- pencereden min(r-i, Z[i-l]) = 0 ile başlarız, hiç ek karşılaştırma gerekmeden Z[10]

pattern-"AB" text-"ABABABABAB" (birlik: S - pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

Z[] =

0	0	0	0	0	0	0	0	0	0	0		
---	---	---	---	---	---	---	---	---	---	---	--	--

 Z[11] = 2
pencere -> [11, 13)

12. i = 11: i >= r -- 0'dan başlarız, 2 doğrudan karşılaştırmayla Z[11] = 2 bulunur. Pencere büyüdü:

= 0 bulunur.

pattern = "AB" text = "ABABABABAB" (birleşik: S = pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

 Z[12] = 0
pencere değişmedi

Z[] =

0	0	2	0	2	0	2	0	2	0	2	0	0
---	---	---	---	---	---	---	---	---	---	---	---	---

13. $i = 12$: $i < r$ ($12 < 13$) -- pencereden $\min(r-i, Z[i-l])$
= 0 ile başlarız, hiç ek karşılaştırma gerekmeden $Z[12]$
= 0 bulunur.

[l,r) = [11, 13).

pattern = "AB" text = "ABABABABAB" (birleşik: S = pattern + # + text)

S[] =

0	1	2	3	4	5	6	7	8	9	10	11	12
A	B	#	A	B	A	B	A	B	A	B	A	B

 Z[12] = 0

Z[] =

0	0	2	0	2	0	2	0	2	0	2	0	0
---	---	---	---	---	---	---	---	---	---	---	---	---

14. Bitti: Z[] = [0, 0, 0, 2, 0, 2, 0, 2, 0, 2, 0, 2, 0]. text
kısımında $Z[i] \geq 2$ olan konumlar pattern'in
oluşumlarıdır: 0, 2, 4, 6, 8. Toplam süre $O(n + m)$.

Seçicide ayrıca "AAA", "AAAAAAAAAA"ya karşı: **pencere sürekli yeniden kullanılır** (zor) ve uç durumları **hiç eşleşme yok, yalnız en baştaki konumda eşleşir**, ve **tek karakterli bir örüntü ($m=1$ sınır durumu)** deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi örüntünüzü ve metninizi yazın.

11.4 Dene



Tam program: `z_algorithm.c` / `ZAlgorithm.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * The Z-algorithm: Z[i] is how many characters S[i..] shares with S itself from the start. For
 * S = pattern + '#' + text, positions in the text part with Z[i] >= |pattern| mark occurrences.
O(n + m).
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXN 64
#define MAXOCC 32

static void z_array(const char *s, int n, int z[]) {
    for (int i = 0; i < n; i++) z[i] = 0;
    int l = 0, r = 0;
    for (int i = 1; i < n; i++) {
        if (i < r)
            z[i] = (r - i < z[i - l]) ? r - i : z[i - l]; /* reuse the [l,r) window */
        while (i + z[i] < n && s[z[i]] == s[i + z[i]])
            z[i]++; /* extend by direct comparison */
        if (i + z[i] > r) { l = i; r = i + z[i]; } /* window grew: remember it */
    }
}

static int z_search(const char *pattern, int m, const char *text, int n, int occ[]) {
    int c = 0;
    if (m == 0) { /* the empty pattern matches at every position, including n
*/
        for (int s = 0; s <= n; s++) occ[s] = s;
        return n + 1;
    }
    char s[MAXN];
    snprintf(s, sizeof(s), "%s#%s", pattern, text); /* combined string */
    int total = m + 1 + n;
    int z[MAXN];
    z_array(s, total, z);
    for (int i = m + 1; i < total; i++)
        if (z[i] >= m) occ[c++] = i - (m + 1); /* Z[i] >= m: a full match */
    return c;
}

static void print_occ(const int occ[], int count) {
    if (count == 0) { printf("(none)"); return; }
    for (int i = 0; i < count; i++) printf("%s%d", i ? ", " : "", occ[i]);
}

static void run_scenario(const char *label, const char *pattern, const char *text) {
    printf("-- %s --\n", label);
    int m = (int) strlen(pattern), n = (int) strlen(text);
    printf("pattern = \"%s\" (%d letters), text = \"%s\" (%d letters)\n", pattern, m, text, n);
    int occ[MAXOCC];
    int count = z_search(pattern, m, text, n, occ);
    printf("occurrences (%d): ", count);
    print_occ(occ, count);
    printf("\n\n");
}

int main(void) {
    run_scenario("normal: a periodic Z array", "AB", "ABABABABAB");
    run_scenario("hard: the window is reused constantly", "AAA", "AAAAAAAAAAAA");
    run_scenario("edge: no match at all, Z stays small", "XYZ", "ABCDEFGHIJ");
    run_scenario("edge: matches only at the very first position", "ABC", "ABCDEFGHIJ");
    run_scenario("edge: the m=1 boundary case, many matches", "A", "BABABABABA");
}

```

```

    return 0;
}

/* Week 12 -- Strings: Structures and Algorithms
 * The Z-algorithm: Z[i] is how many characters S[i..] shares with S itself from the start. For
 * S = pattern + '#' + text, positions in the text part with Z[i] >= |pattern| mark occurrences.
 * O(n + m).
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.ArrayList;
import java.util.List;

public class ZAlgorithm {
    static int[] zArray(String s) {
        int n = s.length();
        int[] z = new int[n];
        int l = 0, r = 0;
        for (int i = 1; i < n; i++) {
            if (i < r)
                z[i] = Math.min(r - i, z[i - l]); // reuse the [l,r) window
            while (i + z[i] < n && s.charAt(z[i]) == s.charAt(i + z[i]))
                z[i]++; // extend by direct comparison
            if (i + z[i] > r) { l = i; r = i + z[i]; } // window grew: remember it
        }
        return z;
    }

    static List<Integer> zSearch(String pattern, String text) {
        int m = pattern.length(), n = text.length();
        List<Integer> occ = new ArrayList<>();
        if (m == 0) { // the empty pattern matches at every position, including n
            for (int s = 0; s <= n; s++) occ.add(s);
            return occ;
        }
        String s = pattern + "#" + text; // combined string
        int[] z = zArray(s);
        for (int i = m + 1; i < m + 1 + n; i++)
            if (z[i] >= m) occ.add(i - (m + 1)); // Z[i] >= m: a full match
        return occ;
    }

    static void runScenario(String label, String pattern, String text) {
        System.out.println("-- " + label + " --");
        System.out.println("pattern = \"" + pattern + "\" (" + pattern.length() + " letters),\ntext = \"" + text + "\" (" + text.length() + " letters)");
        List<Integer> occ = zSearch(pattern, text);
        System.out.print("occurrences (" + occ.size() + "): ");
        if (occ.isEmpty()) System.out.print("(none)");
        else {
            for (int i = 0; i < occ.size(); i++) System.out.print((i > 0 ? ", " : "") +
occ.get(i));
        }
        System.out.println();
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: a periodic Z array", "AB", "ABABABABAB");
        runScenario("hard: the window is reused constantly", "AAA", "AAAAAAAAAA");
        runScenario("edge: no match at all, Z stays small", "XYZ", "ABCDEFGHJIJ");
        runScenario("edge: matches only at the very first position", "ABC", "ABCDEFGHJIJ");
        runScenario("edge: the m=1 boundary case, many matches", "A", "BABABABABA");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x z_algorithm.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: a periodic Z array --
pattern = "AB" (2 letters), text = "ABABABABAB" (10 letters)
occurrences (5): 0, 2, 4, 6, 8

-- hard: the window is reused constantly --
pattern = "AAA" (3 letters), text = "AAAAAAAAAA" (10 letters)
occurrences (8): 0, 1, 2, 3, 4, 5, 6, 7

-- edge: no match at all, Z stays small --
pattern = "XYZ" (3 letters), text = "ABCDEFGHIJ" (10 letters)
occurrences (0): (none)

-- edge: matches only at the very first position --
pattern = "ABC" (3 letters), text = "ABCDEFGHIJ" (10 letters)
occurrences (1): 0

-- edge: the m=1 boundary case, many matches --
pattern = "A" (1 letters), text = "BABABABABA" (10 letters)
occurrences (5): 1, 3, 5, 7, 9
```

```
javac -Xlint:all ZAlgorithm.java && java ZAlgorithm
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

11.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. Tüm birleşik-dizgi $Z[]$ dizisi için $O(n + m)$ (KMP'nin lps kurulumuyla aynı amorti edilmiş argüman: $[1, r]$ penceresi yalnız büyür, böylece r 'nin ötesinde yapılan toplam iş birleşik dizginin uzunluğuyla sınırlıdır), artı bir konumun bir oluşum işaretleyip işaretlemediğini kontrol etmek için $O(1)$.

⚠ Sık yapılan hatalar

- **Ayracı unutmak, ya da metinde geçebilecek bir ayraç seçmek.** Her iki dizgide de bulunmayan bir ayraç olmadan, $Z[]$, $pattern$ ve $text$ arasındaki sınırı aslında aşan bir eşleşme bildirebilir — yanlış bir pozitif. '#' burada güvenlidir çünkü bu notun örnekleri yalnız A – Z harflerini kullanır.
- **$Z[i] == m$ kullanmak, $Z[i] >= m$ yerine.** Bir Z değeri meşru olarak m 'yi aşabilir (paylaşılan önek, metnin kendisi tekrarlıysa, örüntünün kendi uzunluğunun çok ötesine uzanmaya devam edebilir); doğru eşleşme testi "en az m "dir, "tam olarak m " değil.
- **$Z[0]$ 'ı anlamlı saymak.** Bu tanımla, s 'yi kendisiyle kendi ilk karakterinden başlayarak karşılaştırmak dejenere bir durumdur (bariz biçimde tüm dizgi); $Z[0]$ geleneksel olarak kullanılmaz bırakılır (0, ya da basitçe atlanır), ve döngü her zaman $i = 1$ 'den başlar.

✓ Kendini sına: Z algoritması, lps gibi ayrı bir tablo kurmaktan nasıl kaçınır?

Aslında ayrı bir tablo kurmaktan kaçınmaz — $Z[]$ tablonun kendisidir, ve KMP'nin $lps[]$ 'siyle doğrudan benzer bir rol oynar. Fark, her tablonun neyi tanımladığındadır: $lps[i]$, yalnız örüntü içindeki önek-sonek örtüşmesini tanımlar; $Z[i]$, birleşik dizgideki herhangi bir konumun, birleşik dizginin başlangıcıyla ne kadar örtüştüğünü tanımlar. Örüntüyü metnin önüne yapııştırarak, Z algoritması "örüntü burada mı geçer?"i "metindeki bu konum, s 'nin tam başlangıcıyla en az $|pattern|$ karakter mi örtüşüyor?"a çevirir — iki ayrı mekanizma (bir tablo artı onu kullanan bir ikinci geçiş) yerine tek, tek biçim bir dizi tarafından yanıtlanan tek bir soru.

12. Dizgi-arama algoritmalarının karşılaştırma tablosu

Algoritma	Ön işleme	En kötü durum	En iyi/tipik durum	Ekstra fikir
Saf arama	Yok	$O(n*m)$	$O(n)$	Yok — diğer her algoritmanın geliştirdiği taban çizgisi
KMP	$O(m)$, örüntüden	$O(n + m)$	$O(n + m)$	Metin işaretçisi asla geri sarmaz; başarısızlık işlevi $lps[]$
Rabin-Karp	$O(m)$, örüntüyü hash'le	$O(n*m)$ (çok çakışma)	$O(n + m)$ ortalama	Kayan özet; her aday doğrulanmalı
Boyer-Moore (kötü karakter)	$O(alfabe)$, son oluşum tablosu	$O(n*m)$ (düşük çeşitlilik)	$O(n/m)$	Sağdan sola tarama; bir konumdan fazla atlar
Z algoritması	$O(n + m)$, tüm birleşik dizgi için $Z[]$ kurar	$O(n + m)$	$O(n + m)$	Tek bir kendisiyle-karşılaştırma dizisi tüm aramayı yanıtlar

Hiçbir tek algoritma her eksende diğer her algoritmaya baskın değildir. KMP, **garantili** $O(n + m)$ en kötü durumu olan ve yanlış yapılandırılabilir hiçbir ayarı olmayan tek algoritmadır, bu da onu düşmanca girdi altında doğruluğun önemli olduğu durumlarda güvenli varsayılan yapar. Rabin-Karp, aynı metne karşı **aynı uzunlukta birçok farklı örüntü** aramanız gerektiğinde parlar (her örüntünün özetini bir kez hesaplayın, sonra metnin kayan özetini yalnız bir kez tarayın). Boyer-Moore varyantları, doğal dil metni ve büyük bir alfabede pratikte sıkça en hızlısıdır, çünkü gerçek metin en kötü durumundan çok daha sık büyük kötü-karakter atlamalarını tetikler. Z algoritması kavramsal basitliğiyle takdir edilir — tek bir dizi, tek bir geçiş, ayrı bir ön işleme yordamı yok — ve diğer, daha ileri dizgi algoritmalarının içinde bir yapı taşı olarak karşınıza çıkar.

13. Yeni bir strateji: dinamik programlama, ve düzenleme uzaklığı

13.1 Başlangıç sorusu: iki dizgi ne kadar "farklı"?

Yazım denetleyicileri, yazdığınız şeye yakın sözlük sözcükleri bularak düzeltmeler önerir. `git diff` gibi sürüm kontrol araçları, bir dosyanın iki sürümü arasındaki en az değişiklik kümesini gösterir. DNA analiz yazılımı, iki gen dizisini ayıran kaç mutasyon olduğunu ölçer. Üçü de aynı sorunun bir versiyonunu sorar: iki a ve b dizgisi verildiğinde, a 'yı b 'ye

dönüştürmek için gereken **en az sayıda tek karakterlik düzenleme** — ekleme, silme ya da değiştirme — nedir? Bu **düzenleme uzaklığıdır (edit distance)** (ya da **Levenshtein uzaklığı**, 1965 tarihli bir makalede bunu tanımlayan Vladimir Levenshtein'dan sonra). Bunu yanıtlamak gerçekten yeni bir araca ihtiyaç duyar: bu derste şimdiye kadarki her algoritma ya bir yapıyı bir kez dolaştı ya da bir arama uzayını daralttı, ve hiçbirini, bir konumdaki "doğru" seçimin *her diğer konumdaki* seçimlere de bağlı olduğu bir problemi ele almaz.

13.2 Saf kuvvet neden çok yavaş, ve dinamik programlama bunun yerine ne yapar

Doğrudan, özyinelemeli bir tanım doğal olarak ortaya çıkar: $a[0..i]$ 'yi $b[0..j]$ 'ye dönüştürmek için, ya son karakterler eşleşir (ücretsiz, geri kalanı özyineler), ya eşleşmez, ve üç seçenekten en ucuzunu seçersiniz — son karakteri değiştirin ($a[0..i-1]$ ile $b[0..j-1]$ 'de özyineleyin, maliyet $1 + o$), a 'nın son karakterini silin ($a[0..i-1]$ ile $b[0..j]$ 'de özyineleyin, maliyet $1 + o$), ya da b 'nin son karakterini ekleyin ($a[0..i]$ ile $b[0..j-1]$ 'de özyineleyin, maliyet $1 + o$). Doğrudan kodlandığında, bu özyineleme doğrudur ama felaket derecede yavaştır — neredeyse her adımda üç özyinelemeli çağrıya dallanır, ve **aynı** alt problem (diyelim " a 'nın ilk 3 karakteri ile b 'nin ilk 4 karakteri arasındaki düzenleme uzaklığı") farklı bir yoldan tekrar ulaşıldığında her seferinde sıfırdan yeniden hesaplanır, bu da üstel olarak sık olur. **Dinamik programlama** tam olarak bu israfı tek bir fikirle düzeltir: her ayrı alt problemi **yalnız bir kez** çözün, cevabını bir tabloda saklayın, ve o alt problem tekrar gerektiğinde yeniden hesaplamak yerine bakın. Bu, bir problem iki özelliğe sahip olduğunda işe yarar: **optimal alt yapı (optimal substructure)** (tüm problemin en iyi cevabı, alt problemlerinin en iyi cevaplarından kurulur — yukarıdaki özyineleme zaten bunu gösterdiğinden burada doğrudur) ve **çakışan alt problemler (overlapping sub-problems)** (aynı alt problem gerçekten birçok kez tekrar eder — burada da doğrudur, çünkü $a[0..i]$ ile $b[0..j]$, birkaç farklı önceki (i, j) çiftinden ulaşılabilir). Düzenleme uzaklığı, tekniğin olabilecek en temiz ilk örneklerinden biridir, bu yüzden bu ders onu tekniğin tanıtımı olarak kullanır.

13.3 Tablo: $dp[i][j]$ = a 'nın ilk i karakteri ile b 'nin ilk j karakteri arasındaki düzenleme uzaklığı

$n+1$ satırlı ve $m+1$ sütunlu bir dp tablosu kurun ($n = |a|$, $m = |b|$). Satır 0 ve sütun 0 **taban durumlarıdır**: boş bir dizgiyi b 'nin ilk j karakterine dönüştürmek j ekleme ($dp[0][j] = j$) gerektirir; a 'nın ilk i karakterini boş bir dizgiye dönüştürmek i silme ($dp[i][0] = i$) gerektirir. Her diğer hücre yalnız **zaten hesaplanmış üç komşusuna** bakar — köşegen (değiştirme, ya da düşünülen iki karakter zaten eşleşiyorsa ücretsiz), üst (a 'dan silme), sol (b 'den ekleme) — ve en ucuz seçeneği, artı bir alır (ücretsiz eşleşme hariç, o hiçbir ekstra maliyet getirmeyiz). Her hücre yalnız üstündeki, solundaki ya da sol-üst köşegenindeki hücrelere bağlı olduğundan, tabloyu satır satır, soldan sağa doldurmak, bir hücrenin ihtiyaç duyduğu her değerin o hücreye ulaşıldığında zaten hesaplanmış olmasını garanti eder — tablo hiç özyinelemeye gerek kalmadan tek bir geçişte doldurulabilir. Tüm tablo doldurulduktan sonra, $dp[n][m]$ (sağ-alt köşe) cevabı tutar, ve o köşeden **geriye** yürümek — her zaman saklı değeri gerçekten üreten komşuya doğru — gerçek bir en kısa düzenleme dizisini yeniden kurar.

13.4 Bellekte nasıl durur, ve kod

```

int edit_distance(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM]) {
    for (int i = 0; i <= n; i++) dp[i][0] = i;           /* delete all of a[0..i] */
    for (int j = 0; j <= m; j++) dp[0][j] = j;           /* insert all of b[0..j] */
    for (int i = 1; i <= n; i++) {
        for (int j = 1; j <= m; j++) {
            if (a[i - 1] == b[j - 1])
                dp[i][j] = dp[i - 1][j - 1];           /* match: no cost */
            else {
                int sub = dp[i - 1][j - 1], del = dp[i - 1][j], ins = dp[i][j - 1];
                int best = sub < del ? sub : del;
                best = best < ins ? best : ins;
                dp[i][j] = 1 + best;                     /* substitute, delete or insert */
            }
        }
    }
    return dp[n][m];
}

void traceback(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM]) {
    int i = n, j = m;
    while (i > 0 || j > 0) {
        if (i > 0 && j > 0 && a[i-1] == b[j-1] && dp[i][j] == dp[i-1][j-1]) { i--; j--; } /* match */
        else if (i > 0 && j > 0 && dp[i][j] == dp[i-1][j-1] + 1) { i--; j--; } /* substitute */
        else if (i > 0 && dp[i][j] == dp[i-1][j] + 1) { i--; } /* delete */
        else { j--; } /* insert */
    }
}

static int editDistance(String a, String b, int[][] dp) {
    int n = a.length(), m = b.length();
    for (int i = 0; i <= n; i++) dp[i][0] = i;           // delete all of a[0..i]
    for (int j = 0; j <= m; j++) dp[0][j] = j;           // insert all of b[0..j]
    for (int i = 1; i <= n; i++) {
        for (int j = 1; j <= m; j++) {
            if (a.charAt(i - 1) == b.charAt(j - 1))
                dp[i][j] = dp[i - 1][j - 1];           // match: no cost
            else {
                int sub = dp[i - 1][j - 1], del = dp[i - 1][j], ins = dp[i][j - 1];
                int best = Math.min(sub, Math.min(del, ins));
                dp[i][j] = 1 + best;                     // substitute, delete or insert
            }
        }
    }
    return dp[n][m];
}

```

Animasyonu oynatarak tablonun satır satır dolduğunu — her hücrenin üç komşusu vurgulanmış, en ucuzu seçilmiş — ve sonra bir geriye-yürüme yolunun sağ-alt köşeden geriye yürüyerek, gerçek bir eşleşme, değiştirme, silme ve ekleme dizisini yeniden kurduğunu izleyin.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1							
I	2							
T	3							
T	4							
E	5							
N	6							

1. Taban durumları: $dp[i][0] = i$ (a'nın ilk i harfini silmek), $dp[0][j] = j$ (b'nin ilk j harfini eklemek).

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2					
I	2							
T	3							
T	4							
E	5							
N	6							

3. $dp[1][2]$: $a[0]=K$, $b[1]=I$ -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 2.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4			
I	2							
T	3							
T	4							
E	5							
N	6							

5. $dp[1][4]$: $a[0]=K$, $b[3]=T$ -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 4.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5		
I	2							
T	3							
T	4							
E	5							
N	6							

6. $dp[1][5]$: $a[0]=K$, $b[4]=I$ -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 5.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2							
T	3							
T	4							
E	5							
N	6							

8. $dp[1][7]$: $a[0]=K$, $b[6]=G$ -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 7.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	3	4	5	6	7	
T	3							
T	4							
E	5							
N	6							

10. $dp[2][2]$: $a[1]=I$, $b[1]=I$ -- eşleşiyor, köşegenden ücretsiz kopyalanır. Sonuç: 1.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3							
T	4							
E	5							
N	6							

12. $dp[2][4]$: $a[1]=I$, $b[3]=T$ -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 3.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3							
T	4							
E	5							
N	6							

14. $dp[2][6]$: $a[1]=I$, $b[5]=N$ -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 5.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3							
T	4							
E	5							
N	6							

T != 'G'
min(6,7,5) + 1 = 6

15. dp[2][7]: a[1]=I, b[6]=G -- eşleşmiyor, üç komşunun en ucuzu + 1 alınır. Sonuç: 6.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5							
N	6							

T != 'G'
min(6,7,5) + 1 = 6

17. Satır i=4 (a[3]=T) dolduruldu: [4, 4, 3, 2, 1, 2, 3, 4].

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5	5	4	3	2	2	3	4
N	6	6	5	4	3	3	2	3

T != 'G'
min(6,7,5) + 1 = 6

19. Satır i=6 (a[5]=N) dolduruldu: [6, 6, 5, 4, 3, 3, 2, 3].

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5	5	4	3	2	2	3	4
N	6	6	5	4	3	3	2	3

T != 'G'
min(6,7,5) + 1 = 6

21. (6,7): değer soldan + 1 -- ekleme (insert) b[6], sola gideriz.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5	5	4	3	2	2	3	4
N	6	6	5	4	3	3	2	3

ops: match insert

23. (5,5): değer köşegen + 1 -- değiştirme (substitute), köşegene gideriz.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5	5	4	3	2	2	3	4
N	6	6	5	4	3	3	2	3

ops: substitute match insert

24. (4,4): a[3]=b[3] ve değer köşegenden geldi -- eşleşme (match), köşegene gideriz.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5	5	4	3	2	2	3	4
N	6	6	5	4	3	3	2	3

ops: match match substitute match insert

26. (2,2): a[1]=b[1] ve değer köşegenden geldi -- eşleşme (match), köşegene gideriz.

	(boş)	S	I	T	T	I	N	G
(boş)	0	1	2	3	4	5	6	7
K	1	1	2	3	4	5	6	7
I	2	2	1	2	3	4	5	6
T	3	3	2	1	2	3	4	5
T	4	4	3	2	1	2	3	4
E	5	5	4	3	2	2	3	4
N	6	6	5	4	3	3	2	3

ops: substitute match match match substitute match insert

28. Bitti: edit_distance("KITTEN", "SITTING") = 3. Bir en

eşleşme (match), koşegene gideriz.

kısa duzenleme dizisi: substitute, match, match, match, substitute, match, insert. Tablo $O(n*m)$ sürede ve bellekte dolduruldu.

Seçicide ayrıca "INTENTION" -> "EXECUTION": büyük bir tablo, uzaklık 5 (zor) ve uç durumları özdeş dizgiler, uzaklık 0, hiç paylaşılan harf yok, her konum bir değiştirme, ve "CAT" -> "CATERPILLAR": saf ekleme deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi iki dizginizi yazın.

13.5 Dene

**Tam program:** `edit_distance.c` / `EditDistance.java`

```

/* Week 12 -- Strings: Structures and Algorithms
 * Edit distance (Levenshtein distance): the fewest insertions, deletions and substitutions to
 * turn a into b,
 * a DP table plus a traceback that reconstructs one shortest edit sequence.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXN 16
#define MAXM 16
#define MAXOPS 32

static int edit_distance(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM]) {
    for (int i = 0; i <= n; i++) dp[i][0] = i;          /* delete all of a[0..i] */
    for (int j = 0; j <= m; j++) dp[0][j] = j;          /* insert all of b[0..j] */
    for (int i = 1; i <= n; i++) {
        for (int j = 1; j <= m; j++) {
            if (a[i - 1] == b[j - 1])
                dp[i][j] = dp[i - 1][j - 1];          /* match: no cost */
            else {
                int sub = dp[i - 1][j - 1], del = dp[i - 1][j], ins = dp[i][j - 1];
                int best = sub < del ? sub : del;
                best = best < ins ? best : ins;
                dp[i][j] = 1 + best;                  /* substitute, delete or insert */
            }
        }
    }
    return dp[n][m];
}

static int traceback(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM], char ops[
12]) {
    int i = n, j = m, k = 0;
    char tmp[MAXOPS][12];
    while (i > 0 || j > 0) {
        if (i > 0 && j > 0 && a[i - 1] == b[j - 1] && dp[i][j] == dp[i - 1][j - 1]) {
            snprintf(tmp[k++], 12, "match");
            i--; j--;
        } else if (i > 0 && j > 0 && dp[i][j] == dp[i - 1][j - 1] + 1) {
            snprintf(tmp[k++], 12, "substitute");
            i--; j--;
        } else if (i > 0 && dp[i][j] == dp[i - 1][j] + 1) {
            snprintf(tmp[k++], 12, "delete");
            i--;
        } else {
            snprintf(tmp[k++], 12, "insert");
            j--;
        }
    }
    for (int t = 0; t < k; t++) snprintf(ops[t], 12, "%s", tmp[k - 1 - t]); /* reverse into
order */
    return k;
}

static void run_scenario(const char *label, const char *a, const char *b) {
    printf("-- %s --\n", label);
    int n = (int) strlen(a), m = (int) strlen(b);
    printf("a = \"%s\" (%d letters), b = \"%s\" (%d letters)\n", a, n, b, m);
    static int dp[MAXN][MAXM];
    int distance = edit_distance(a, n, b, m, dp);
    char ops[MAXOPS][12];
    int k = traceback(a, n, b, m, dp, ops);
    printf("edit_distance = %d\nops:", distance);
}

```

```
    for (int t = 0; t < k; t++) printf(" %s", ops[t]);  
    printf("\n\n");  
}  
  
int main(void) {  
    run_scenario("normal: the classic example, distance 3", "KITTEN", "SITTING");  
    run_scenario("hard: a big table, distance 5", "INTENTION", "EXECUTION");  
    run_scenario("edge: identical strings, distance 0", "ALGORITHM", "ALGORITHM");  
    run_scenario("edge: no shared letters, every position a substitution", "ABCDE", "FGHIJ");  
    run_scenario("edge: pure insertion", "CAT", "CATERPILLAR");  
    return 0;  
}
```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Edit distance (Levenshtein distance): the fewest insertions, deletions and substitutions to
turn a into b,
 * a DP table plus a traceback that reconstructs one shortest edit sequence.
 * CEN207 Data Structures (formerly CE205)
 */
import java.util.ArrayList;
import java.util.Collections;
import java.util.List;

public class EditDistance {
    static int editDistance(String a, String b, int[][] dp) {
        int n = a.length(), m = b.length();
        for (int i = 0; i <= n; i++) dp[i][0] = i;           // delete all of a[0..i]
        for (int j = 0; j <= m; j++) dp[0][j] = j;         // insert all of b[0..j]
        for (int i = 1; i <= n; i++) {
            for (int j = 1; j <= m; j++) {
                if (a.charAt(i - 1) == b.charAt(j - 1))
                    dp[i][j] = dp[i - 1][j - 1];           // match: no cost
                else {
                    int sub = dp[i - 1][j - 1], del = dp[i - 1][j], ins = dp[i][j - 1];
                    int best = Math.min(sub, Math.min(del, ins));
                    dp[i][j] = 1 + best;                     // substitute, delete or insert
                }
            }
        }
        return dp[n][m];
    }

    static List<String> traceback(String a, String b, int[][] dp) {
        int i = a.length(), j = b.length();
        List<String> ops = new ArrayList<>();
        while (i > 0 || j > 0) {
            if (i > 0 && j > 0 && a.charAt(i - 1) == b.charAt(j - 1) && dp[i][j] == dp[i - 1][j - 1]) {
                ops.add("match");
                i--; j--;
            } else if (i > 0 && j > 0 && dp[i][j] == dp[i - 1][j - 1] + 1) {
                ops.add("substitute");
                i--; j--;
            } else if (i > 0 && dp[i][j] == dp[i - 1][j] + 1) {
                ops.add("delete");
                i--;
            } else {
                ops.add("insert");
                j--;
            }
        }
        Collections.reverse(ops);
        return ops;
    }

    static void runScenario(String label, String a, String b) {
        System.out.println("-- " + label + " --");
        System.out.println("a = \"" + a + "\" (" + a.length() + " letters), b = \"" + b + "\" (" + b.length() + " letters)");
        int[][] dp = new int[a.length() + 1][b.length() + 1];
        int distance = editDistance(a, b, dp);
        List<String> ops = traceback(a, b, dp);
        System.out.println("edit_distance = " + distance);
        StringBuilder line = new StringBuilder("ops:");
        for (String op : ops) line.append(' ').append(op);
        System.out.println(line);
        System.out.println();
    }
}

```

```

    }

    public static void main(String[] args) {
        runScenario("normal: the classic example, distance 3", "KITTEN", "SITTING");
        runScenario("hard: a big table, distance 5", "INTENTION", "EXECUTION");
        runScenario("edge: identical strings, distance 0", "ALGORITHM", "ALGORITHM");
        runScenario("edge: no shared letters, every position a substitution", "ABCDE", "FGHIJ");
        runScenario("edge: pure insertion", "CAT", "CATERPILLAR");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x edit_distance.c && /tmp/x
```

Beklenen çıktı:

```

-- normal: the classic example, distance 3 --
a = "KITTEN" (6 letters), b = "SITTING" (7 letters)
edit_distance = 3
ops: substitute match match match substitute match insert

-- hard: a big table, distance 5 --
a = "INTENTION" (9 letters), b = "EXECUTION" (9 letters)
edit_distance = 5
ops: substitute substitute substitute substitute substitute match match match match

-- edge: identical strings, distance 0 --
a = "ALGORITHM" (9 letters), b = "ALGORITHM" (9 letters)
edit_distance = 0
ops: match match match match match match match match match match

-- edge: no shared letters, every position a substitution --
a = "ABCDE" (5 letters), b = "FGHIJ" (5 letters)
edit_distance = 5
ops: substitute substitute substitute substitute substitute

-- edge: pure insertion --
a = "CAT" (3 letters), b = "CATERPILLAR" (11 letters)
edit_distance = 8
ops: match match match insert insert insert insert insert insert insert insert

```

```
javac -Xlint:all EditDistance.java && java EditDistance
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

13.6 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. $O(n \cdot m)$ süre $((n+1) \cdot (m+1))$ hücrenin her biri bir kez, $O(1)$ 'de hesaplanır ve gösterildiği gibi tablo için $O(n \cdot m)$ alan — saf özyinelemenin üstel süresine göre çarpıcı bir gelişme, bedeli özyinelemenin $O(n+m)$ çağrı-yığını derinliği yerine $O(n \cdot m)$ bellek olmasıdır. (Daha ileri bir eniyileştirme, tüm tablo yerine yalnız *önceki* satırı tutmak, yalnız uzaklığın kendisine ihtiyaç duyulduğunda, düzenleme dizisine değil, alanı $O(m)$ 'ye indirir — ama burada gösterilen geriye yürümeyi çalıştırmak için tam tablo gerekir.)

⚠ Sık yapılan hatalar

- **Dizgi indisi ile tablo indisi arasında birer kayma.** $dp[i][j]$, a 'nın ilk i karakterini işaret eder, böylece gerçekte karşılaştırılan karakter $a[i-1]$ 'dir, $a[i]$ değil — geriye almak kolay bir tek karakterlik kayma.
- **Taban durumlarının 0 olmadığını unutmak.** $dp[i][0]$ ve $dp[0][j]$ sırasıyla i ve j 'dir (bir tarafı boş bir dizgiye dönüştürmenin maliyeti), sıfır değil — yanlışlıkla sıfırlamak, boş bir önekle karşılaştırma durumunu sessizce ücretsiz gösterir.
- **Tabloyu yanlış sırada doldurmak.** Her hücre köşegen, üst, ve sol komşusunun zaten hesaplanmış olmasına ihtiyaç duyar; satır satır yerine sütun sütun doldurmak (ya da tersi) tutarlı olduğu sürece hâlâ çalışır, ama gerçekten yanlış bir sırada doldurmak (diyelim, sağ-alttan sol-üste) başlatılmamış değerleri okur.

✓ Kendini sına: dinamik programlama neden HEM optimal alt yapıya HEM çakışan alt problemlere ihtiyaç duyar? ✓

Yalnız optimal alt yapı (tüm problemin en iyi cevabı, alt problemlerin en iyi cevaplarından kurulur), özyinelemeli tanımlı **doğru** yapan şeydir — bu olmadan, alt cevapları ezberlemek doğru son cevabı bile üretmezdi. Yalnız çakışan alt problemler, ezberlemeyi **verimlilik** açısından değerli kılan şeydir — her alt problem yalnız bir yoldan ulaşılsaydı (çakışma yok), ezberlemek hiçbir şey kazandırmazdı, çünkü zaten hiçbir şey yeniden hesaplanmazdı. Düzenleme uzaklığı ikisine de sahiptir: bölüm 13.2'deki özyinelemeli tanım kanıtlanabilir doğrudur (optimal alt yapı), ve aynı (i, j) çifti birçok farklı düzenleme dizisi aracılığıyla ulaşılabilir (çakışan alt problemler) — ki bu tam olarak saf özyinelemenin üstel, tablo tabanlı sürümün üstel olmayışının nedenidir.

14. En uzun ortak alt dizi

14.1 Başlangıç sorusu

`git diff` ve DNA karşılaştırma araçları yalnız tek bir sayı (düzenleme uzaklığı) istemez; sıkça iki sürümün **hangi kısımlarının aslında birbirine karşılık geldiğini** bilmek isterler — bitişik olmasa bile, sırayla ne kaldı. Bir dizginin bir **alt dizisi (subsequence)**, sıra *değiştirilmeden* sıfır ya da daha fazla karakter silindikten sonra kalandır — "BCA", "ABCBDAB" 'nin bir alt dizisidir (ilk A'yı, ikinci B'yi, ve son B'yi silin), ama "ACB" değildir (bu yeniden sıralama gerektirir). İki a ve b dizgisinin **en uzun ortak alt dizisi (longest common subsequence, LCS)**, **her ikisinin de** alt dizisi olan en uzun karakter dizisidir — "bu karakterler her iki dizgide de aynı göreceli sırada geçiyor" fikrinin en uzun ipliği, ki bu tam olarak bir fark (diff) aracının gösterdiği "değişmeyen" kavramıdır.

14.2 Fikir: neredeyse aynı tablo, farklı bir yineleme

LCS, düzenleme uzaklığıyla aynı dinamik programlama *şeklini* kullanır — satır satır doldurulan bir $dp[i][j]$ tablosu, her hücre yalnız köşegen, üst, ve sol komşusuna bağlı — ama her hücre için farklı bir **anlam** ve farklı bir **yineleme (recurrence)** kullanır. Burada, $dp[i][j]$, a 'nın ilk i karakteri ile b 'nin ilk j karakterinin en uzun ortak alt dizisinin **uzunluğudur**. Taban durumları $dp[i][0] = dp[0][j] = 0$ 'dir (boş bir dizgi, herhangi bir uzunlukta hiçbir şeyle ortak bir alt dizi paylaşmaz). Her diğer hücre için: düşünülen iki karakter eşleşiyorsa, LCS bir karakter **uzatılabilir** — $dp[i][j] = dp[i-1][j-1] + 1$ — çünkü o eşleşen karakter her zaman iki daha kısa önekin en iyi ortak alt dizisine eklenebilir. Eşleşmiyorlarsa, *bu* adımda hiçbir yeni karakter eklenemez, böylece hücre basitçe iki komşusundan **daha iyisini** taşır — $dp[i][j] = \max(dp[i-1][j], dp[i][j-1])$ — hangisi yardımcı olmuyorsa o taraftan bir karakteri düşürerek. Düzenleme uzaklığından farklı olarak, burada uyuşmayan karakterleri "atlamak" hiçbir şeye mal olmaz; hiçbir değiştirme, ekleme, ya da silme cezası yoktur, yalnız hangi karakterlerin *tutulacağı* sorusu vardır.

14.3 Bellekte nasıl durur, ve kod

```

int lcs_length(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM]) {
    for (int i = 0; i <= n; i++) dp[i][0] = 0;
    for (int j = 0; j <= m; j++) dp[0][j] = 0;
    for (int i = 1; i <= n; i++) {
        for (int j = 1; j <= m; j++) {
            if (a[i - 1] == b[j - 1])
                dp[i][j] = dp[i - 1][j - 1] + 1;          /* extend the diagonal by one */
            else
                dp[i][j] = dp[i - 1][j] >= dp[i][j - 1] ? dp[i - 1][j] : dp[i][j - 1]; /* better neighbor */
        }
    }
    return dp[n][m];
}

void traceback(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM], char out[]) {
    int i = n, j = m, k = dp[n][m];
    out[k] = '\0';
    while (i > 0 && j > 0) {
        if (a[i - 1] == b[j - 1]) { out[--k] = a[i - 1]; i--; j--; } /* part of the LCS */
        else if (dp[i - 1][j] >= dp[i][j - 1]) i--; /* came from above */
        else j--; /* came from the left */
    }
}

static int lcsLength(String a, String b, int[][] dp) {
    int n = a.length(), m = b.length();
    for (int i = 0; i <= n; i++) dp[i][0] = 0;
    for (int j = 0; j <= m; j++) dp[0][j] = 0;
    for (int i = 1; i <= n; i++) {
        for (int j = 1; j <= m; j++) {
            if (a.charAt(i - 1) == b.charAt(j - 1))
                dp[i][j] = dp[i - 1][j - 1] + 1;          // extend the diagonal by one
            else
                dp[i][j] = Math.max(dp[i - 1][j], dp[i][j - 1]); // better neighbor
        }
    }
    return dp[n][m];
}

```

Animasyonu oynatarak tablonun tam olarak düzenleme uzaklığınınki gibi dolduğunu, ama değiştirme yerine eşleşme-köşegen-uzat kuralıyla, ve gerçek paylaşılan karakterleri yeniden kuran bir geriye yürümeyle (bir düzenleme işlemleri dizisi değil) izleyin.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0						
B	0						
C	0						
B	0						
D	0						
A	0						
B	0						

1. Taban durumları: $dp[i][0] = 0$ ve $dp[0][j] = 0$ -- boş bir dizgiyle hiçbir ortak alt dizi paylaşamaz.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'A' != 'D'
 $\max(0,0) = 0$

3. $dp[1][2]$: $a[0]=A$, $b[1]=D$ -- eşleşmiyor, üst ve sol komşudan büyük olanı alınır. Sonuç: 0.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'A' == 'A'
 $dp[1][4] = dp[0][3] + 1 = 1$

5. $dp[1][4]$: $a[0]=A$, $b[3]=A$ -- eşleşiyor, köşegen bir artar. Sonuç: 1.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'A' != 'B'
 $\max(0,1) = 1$

6. $dp[1][5]$: $a[0]=A$, $b[4]=B$ -- eşleşmiyor, üst ve sol komşudan büyük olanı alınır. Sonuç: 1.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'B' == 'B'
 $dp[2][1] = dp[1][0] + 1 = 1$

8. $dp[2][1]$: $a[1]=B$, $b[0]=B$ -- eşleşiyor, köşegen bir artar. Sonuç: 1.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'B' != 'C'
 $\max(0,1) = 1$

10. $dp[2][3]$: $a[1]=B$, $b[2]=C$ -- eşleşmiyor, üst ve sol komşudan büyük olanı alınır. Sonuç: 1.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'B' == 'B'
 $dp[2][5] = dp[1][4] + 1 = 2$

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
C	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0
D	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0
B	0	0	0	0	0	0	0

'B' != 'A'
 $\max(1,2) = 2$

C	0
B	0
D	0
A	0
B	0

12. $dp[2][5]$: $a[1]=B$, $b[4]=B$ -- eşleşiyor, köşegen bir artar. Sonuç: 2.

C	0	1	1	2	2	2	2
B	0						
D	0						
A	0						
B	0						

14. Satır $i=3$ ($a[2]=C$) dolduruldu: $[0, 1, 1, 2, 2, 2, 2]$.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0						
A	0						
B	0						

'B' != 'A'
 $\max(1,2) = 2$

15. Satır $i=4$ ($a[3]=B$) dolduruldu: $[0, 1, 1, 2, 2, 3, 3]$.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0						

'B' != 'A'
 $\max(1,2) = 2$

17. Satır $i=6$ ($a[5]=A$) dolduruldu: $[0, 1, 2, 2, 3, 3, 4]$.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0	1	2	2	3	4	4

19. Tablo tamam: $dp[7][6] = 4$ -- en uzun ortak alt dizinin uzunluğu. Şimdi sağ-alttan geriye yürüyerek onu yeniden kurarız.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0	1	2	2	3	4	4

LCS so far: A

21. $a[5]=b[5]$ -- bu harf LCS'nin parçası: A eklenir, köşegene gideriz.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0	1	2	2	3	4	4

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0	1	2	2	3	4	4

LCS so far: BA

23. $a[3]=b[4]$ -- bu harf LCS'nin parçası: B eklenir, köşegene gideriz.

LCS so far: BA

24. $a[3] \neq b[3]$, $sol > üst$ -- $b[3]$ atılır, sola gideriz.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0	1	2	2	3	4	4

LCS so far: CBA

26. $a[2] \neq b[1]$, $sol > üst$ -- $b[1]$ atılır, sola gideriz.

	(boş)	B	D	C	A	B	A
(boş)	0	0	0	0	0	0	0
A	0	0	0	0	1	1	1
B	0	1	1	1	1	2	2
C	0	1	1	2	2	2	2
B	0	1	1	2	2	3	3
D	0	1	2	2	2	3	3
A	0	1	2	2	3	3	4
B	0	1	2	2	3	4	4

LCS so far: BCBA

28. Bitti: $LCS("ABCBDA", "BDCABA")$ uzunluk 4, bir örnek: "BCBA". Tablo $O(n*m)$ sürede ve bellekte dolduruldu.

Seçicide ayrıca "AGGTAB" ve "GXTXAYB": biyoenformatik klasiği, uzunluk 4 (zor) ve uç durumları hiç paylaşılan harf yok, uzunluk 0, özdeş dizgiler, LCS dizginin tamamı, ve "ACEG" tamamen "ABCDEFGH"nin bir alt dizisi deneyin — ya da dört zorluk seviyesinde rastgele veri için 🎲'e basın, ya da kendi iki dizginizi yazın.

14.4 Dene



Tam program: `longest_common_subsequence.c` / `LongestCommonSubsequence.java`



```

/* Week 12 -- Strings: Structures and Algorithms
 * Longest common subsequence (LCS): the longest sequence of characters appearing, in order, in
 * both a and b.
 * A DP table plus a traceback that reconstructs one actual longest common subsequence.
 * CEN207 Data Structures (formerly CE205)
 */
#include <stdio.h>
#include <string.h>

#define MAXN 16
#define MAXM 16

static int lcs_length(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM]) {
    for (int i = 0; i <= n; i++) dp[i][0] = 0;
    for (int j = 0; j <= m; j++) dp[0][j] = 0;
    for (int i = 1; i <= n; i++) {
        for (int j = 1; j <= m; j++) {
            if (a[i - 1] == b[j - 1])
                dp[i][j] = dp[i - 1][j - 1] + 1;          /* extend the diagonal by one */
            else
                dp[i][j] = dp[i - 1][j] >= dp[i][j - 1] ? dp[i - 1][j] : dp[i][j - 1]; /* better
neighbor */
        }
    }
    return dp[n][m];
}

static void traceback(const char *a, int n, const char *b, int m, int dp[MAXN][MAXM], char out[])
{
    int i = n, j = m, k = dp[n][m];
    out[k] = '\0';
    while (i > 0 && j > 0) {
        if (a[i - 1] == b[j - 1]) { out[--k] = a[i - 1]; i--; j--; } /* part of the LCS */
        else if (dp[i - 1][j] >= dp[i][j - 1]) i--; /* came from above */
        else j--; /* came from the left */
    }
}

static void run_scenario(const char *label, const char *a, const char *b) {
    printf("-- %s --\n", label);
    int n = (int) strlen(a), m = (int) strlen(b);
    printf("a = \"%s\" (%d letters), b = \"%s\" (%d letters)\n", a, n, b, m);
    static int dp[MAXN][MAXM];
    int length = lcs_length(a, n, b, m, dp);
    char out[MAXN];
    traceback(a, n, b, m, dp, out);
    printf("lcs_length = %d, one LCS = \"%s\"\n\n", length, out);
}

int main(void) {
    run_scenario("normal: the classic example, length 4", "ABCBAD", "BDCABA");
    run_scenario("hard: the bioinformatics classic, length 4", "AGGTAB", "GXTXAYB");
    run_scenario("edge: no shared letters at all, length 0", "ABCDE", "FGHIJ");
    run_scenario("edge: identical strings, the LCS is the whole string", "ALGORITHM",
"ALGORITHM");
    run_scenario("edge: ACEG is entirely a subsequence of ABCDEFGH", "ACEG", "ABCDEFGH");
    return 0;
}

```

```

/* Week 12 -- Strings: Structures and Algorithms
 * Longest common subsequence (LCS): the longest sequence of characters appearing, in order, in
 * both a and b.
 * A DP table plus a traceback that reconstructs one actual longest common subsequence.
 * CEN207 Data Structures (formerly CE205)
 */
public class LongestCommonSubsequence {
    static int lcsLength(String a, String b, int[][] dp) {
        int n = a.length(), m = b.length();
        for (int i = 0; i <= n; i++) dp[i][0] = 0;
        for (int j = 0; j <= m; j++) dp[0][j] = 0;
        for (int i = 1; i <= n; i++) {
            for (int j = 1; j <= m; j++) {
                if (a.charAt(i - 1) == b.charAt(j - 1))
                    dp[i][j] = dp[i - 1][j - 1] + 1; // extend the diagonal by one
                else
                    dp[i][j] = Math.max(dp[i - 1][j], dp[i][j - 1]); // better neighbor
            }
        }
        return dp[n][m];
    }

    static String traceback(String a, String b, int[][] dp) {
        int i = a.length(), j = b.length(), k = dp[i][j];
        char[] out = new char[k];
        while (i > 0 && j > 0) {
            if (a.charAt(i - 1) == b.charAt(j - 1)) { out[--k] = a.charAt(i - 1); i--; j--; }
            // part of the LCS
            else if (dp[i - 1][j] >= dp[i][j - 1]) i--;
            // came from above
            else j--;
            // came from the left
        }
        return new String(out);
    }

    static void runScenario(String label, String a, String b) {
        System.out.println("-- " + label + " --");
        System.out.println("a = \"" + a + "\" (" + a.length() + " letters), b = \"" + b + "\" ("
+ b.length() + " letters)");
        int[][] dp = new int[a.length() + 1][b.length() + 1];
        int length = lcsLength(a, b, dp);
        String out = traceback(a, b, dp);
        System.out.println("lcs_length = " + length + ", one LCS = \"" + out + "\"");
        System.out.println();
    }

    public static void main(String[] args) {
        runScenario("normal: the classic example, length 4", "ABCBAB", "BDCABA");
        runScenario("hard: the bioinformatics classic, length 4", "AGGTAB", "GXTXAYB");
        runScenario("edge: no shared letters at all, length 0", "ABCDE", "FGHIJ");
        runScenario("edge: identical strings, the LCS is the whole string", "ALGORITHM",
"ALGORITHM");
        runScenario("edge: ACEG is entirely a subsequence of ABCDEFGH", "ACEG", "ABCDEFGH");
    }
}

```

Dene

```
gcc -std=c11 -Wall -Wextra -o /tmp/x longest_common_subsequence.c && /tmp/x
```

Beklenen çıktı:

```
-- normal: the classic example, length 4 --
a = "ABCBADAB" (7 letters), b = "BDCABA" (6 letters)
lcs_length = 4, one LCS = "BCBA"

-- hard: the bioinformatics classic, length 4 --
a = "AGGTAB" (6 letters), b = "GXTXAYB" (7 letters)
lcs_length = 4, one LCS = "GTAB"

-- edge: no shared letters at all, length 0 --
a = "ABCDE" (5 letters), b = "FGHIJ" (5 letters)
lcs_length = 0, one LCS = ""

-- edge: identical strings, the LCS is the whole string --
a = "ALGORITHM" (9 letters), b = "ALGORITHM" (9 letters)
lcs_length = 9, one LCS = "ALGORITHM"

-- edge: ACEG is entirely a subsequence of ABCDEFGH --
a = "ACEG" (4 letters), b = "ABCDEFGH" (8 letters)
lcs_length = 4, one LCS = "ACEG"
```

```
javac -Xlint:all LongestCommonSubsequence.java && java LongestCommonSubsequence
```

Beklenen çıktı: yukarıdaki C çalıştırmasıyla birebir aynı.

14.5 Karmaşıklık, hatalar, kendini sına

Karmaşıklık. $O(n*m)$ süre ve alan, tam olarak düzenleme uzaklığı gibi — aynı tablo şekli, aynı şekilde doldurulmuş, yalnız her hücrede farklı bir yinelemeyle.



Sık yapılan hatalar

- **"Alt dizi"yi "alt dizgi" ile karıştırmak.** Bir alt dizgi **bitişik** olmalıdır; bir alt dizinin bitişik olması gerekmez. "ACE", "ABCDE" 'nin bir alt dizisidir ama onun bir alt dizgisi değildir — ikisini karıştırmak bu problemle ilgili en yaygın tek kavramsal hatadır.
- **Yanlışlıkla düzenleme uzaklığının yinelemesini yeniden kullanmak.** $dp[i][j] = dp[i-1][j-1] + 1$ 'i koşulsuzca yazmak, ya da uyumsuzluklar için bir "maliyet" eklemek caziptir — ama LCS'nin her iki tarafta da bir karakteri atlamak için **hiçbir cezası** yoktur; yalnız eşleşmeler değeri artırır, ve iki komşunun $\max$ 'ı, bir uyumsuzluğun şimdiye kadarki en iyisini ileriye taşıyan şeydir.
- **Yalnız örüntü uzunluğu isteniyorken gerçek alt diziyi bildirmek, ya da tam tersi.** Yalnız $dp[n][m]$ yalnız "ne kadar uzun?" sorusunu yanıtlar — gerçek karakterleri geri kazanmak, yukarıda gösterildiği gibi sağ-alt köşeden geriye yürüyen bir geriye yürüme gerektirir.

✓ Kendini sına: LCS'nin yinelemesi neden düzenleme uzaklığındaki gibi min+1 yerine max kullanır? ✓

Düzenleme uzaklığı bir dizgiyi diğerine dönüştürmenin en ucuz yolunun **maliyetini** sayar, böylece her eşleşmeyen adım bir düzenlemedir ve ödenmelidir, bu yüzden yineleme *en ucuz* (min) seçeneği alır ve 1 ekler. LCS, **paylaşılan** karakterlerin bir uzunluğunu sayar, böylece eşleşmeyen bir adım hiçbir şeye mal olmaz ve basitçe hangi tarafın alt problemi zaten *daha uzun* bir paylaşılan alt diziye ulaşırsa onu ileriye taşır — bu yüzden min değil max, ve +1 yalnız gerçek bir karakter eşleşmesinde olur, asla bir uyumsuzluk için düz bir ceza olarak değil.

Özet

Bu hafta iki dizgi algoritması ailesini kapsadı. **Yapılar**: bir C dizgisi, `'\0'` kuralı eklenmiş bir `char` dizisidir (ve o kuralın olanaklı kıldığı, burada her zaman açık bir sınır kontrolüyle korunan arabellek taşması hatası); **büyüyen bir arabellek**, amorti edilmiş $O(1)$ ekleme vermek için kapasitesini ikiye katlar; bir **trie**, her karakter için bir kenarla kaç sözcük saklandığından bağımsız işlem başına $O(L)$ ile bütün bir sözcük kümesini saklar; bir **sıkıştırılmış trie (radix ağacı)**, uzun dallanmasız zincirleri tek alt-dizgi etiketli kenarlara toplar, küçük bir ekstra defter tutma karşılığında gerçek alan tasarrufu sağlar — Hafta 4'ün, çarpık simge sıklıklarını sömüren Huffman kodlamasından gerçekten farklı bir sıkıştırma fikri; bir **sonek dizisi**, bir metnin her soneğini sıralı listeler, tekrarlanan örüntü aramalarını $O(m \log n)$ ikili aramalara çevirir. **Arama**: **saf arama** her kaydirmayı dener, en kötü durum $O(n*m)$; **KMP**, örüntüden bir başarısızlık işlevi `lps[]` önceden hesaplar, böylece metin işaretçisi asla geri sarmaz, garantili $O(n + m)$; **Rabin-Karp**, her pencerenin kayan özetini karşılaştırır, ortalama $O(n + m)$, **sahte isabetleri** yakalamak için bir hash eşleşmesini her zaman doğrular; **Boyer-Moore**'un kötü karakter kuralı sağdan sola tarar ve az önce gördüğünü kullanarak atlar; **Z algoritması**, tüm problemi tek bir kendisiyle-karşılaştırma dizisine indirger. Son olarak, bu hafta bu derste ilk kez **dinamik programlamayı** — çakışan alt problemleri yalnız bir kez çözmek, her cevabı bir tabloda saklamak — **düzenleme uzaklığı** (bir dizgiyi diğerine dönüştürmenin en az düzenlemesi) ve **en uzun ortak alt dizi** (karakterlerin en uzun paylaşılan, sırayla dizisi) üzerinden tanıttı, ikisi de aynı tablo şekliyle iki farklı yinelemeyle $O(n*m)$.

Alıştırmalar

1. `c_string_memory.c`'nin `safe_store`'unu, bir taşmayı sessizce bayraklamak yerine, kaç karakterin kopyalanmadan kaldığını da `(strlen(src) - written)` bildirecek şekilde değiştirin. Bölüm 1'deki "edge: cap=8, overflow" senaryosuna karşı test edin ve sayının eşleştiğini doğrulayın.
2. `string_builder.c`'nin `Builder`'ını kullanarak, `initCap = 3`'ten başlayarak 100 karakterlik bir dizgi eklerken kaç büyüme olduğunu elle izleyin. Son kapasite nedir, ve ne kadar kullanılmamış kalır?
3. `trie_insert_search.c`'yi, saklı tam sözcük sayısını (`is_end == true` olan düğümler) döndüren bir `count_words(TrieNode *root)` işlevi eklemek için değiştirin. "hard" senaryosuna (TRIE sözcük ailesi) karşı test edin ve 6 döndürdüğünü doğrulayın.
4. `compressed_trie.c`'nin "edge: ANT, ARM, ART, AXE" senaryosunu kullanarak, programı çalıştırmadan önce son ağacı elle çizin (düğümler, kenar etiketleri, hangi düğümlerin `isEnd` işaretli olduğu), sonra her kenar etiketini dolaşıp yazdıran küçük bir hata ayıklama işlevi ekleyerek çiziminizi programın yapısıyla karşılaştırın.
5. `suffix_array.c`, $O(n^2)$ -en-kötü-durum ekleme sıralamasıyla diziyi kurar. "AAAAAAAAA" (10 A)'yı sıralarken `compare_suffix`'in toplam kaç karakter karşılaştırması yaptığını — maksimal-berabere uç durumunu — elle izleyin, ve bu durumda her karşılaştırmanın neden her zaman daha kısa soneğin sonuna kadar çalıştığını bir cümlede açıklayın.
6. `naive_search.c`'yi kullanarak, (bölüm 6'daki "zor" senaryodan farklı) 10 ve 4 uzunluğunda bir metin ve örüntü oluşturun, öyle ki her kaydırma yine 4 örüntü karakterinin tümünü karşılaştırmaya zorlanır, ama örüntü en az bir kez bulunur. Yapınızı programı çalıştırarak doğrulayın.

7. `kmp_failure_function.c`'nin `compute_lps`'ini `pattern = "AABAABAAA"` (9 harf) için elle izleyin, tüm `lps[]` dizisini yazın, sonra cevabınızı programı çalıştırarak doğrulayın.
8. `rabin_karp.c`'nin "hard" senaryosunu (`mod = 7`) kullanarak, aynı `text` ve `pattern` için de en az bir sahte isabet üreten 5 ile 20 arasında **farklı** bir modül (7 değil) bulun. Küçük bir modülün neden bunu büyük bir modülden daha olası kıldığını bir cümlede açıklayın.
9. `boyer_moore_bad_character.c`'nin yalnız kötü karakter kuralı (bu dersin kapsamadığı iyi sonek kuralı olmadan) bazen gerçekte güvenli olandan daha küçük bir atlama üretebilir. "hard" senaryosunu (`text="AAAAAAAAA"`, `pattern="AAAB"`) kullanarak, her adımda hesaplanan atlama miktarını elle izleyin ve düşük-alfabe-çeşitliliği metnin kötü karakter kuralının zayıf durumu olduğunu bir ya da iki cümlede açıklayın.
10. `edit_distance.c`'nin "hard" senaryosunu (`"INTENTION"`'dan `"EXECUTION"`'a, uzaklık 5) ve `longest_common_subsequence.c`'nin yinelemesini kullanarak, aynı iki dizginin LCS uzunluğunu elle (ya da taslak bir programda `lcs_length`'e bir çağrı ekleyerek) hesaplayın. Eşit uzunluktaki bir dizgi çiftinin düzenleme uzaklığı ile LCS uzunluğu arasında genel bir ilişki var mı? (ipucu: LCS'deki her eşleşen karakter, bir düzenleme dizisinde de "ücretsiz" bir adımdır.)

Kendini sinama testi

✓ 1. Bir C dizgisi neden ayrı bir uzunluk alanına ihtiyaç duymaz, ve bu, uzunluğa ihtiyaç duyan her işleme neye mal olur? ✓

Çünkü dil, bir C dizgisinin uzunluğunu örtük olarak, "ilk `'\0'` baytının alttaki `char` dizisinde nerede olduğu" olarak tanımlar — hiçbir uzunluk başka bir yerde saklanmaz. Bedel: uzunluğa ihtiyaç duyan her işlem (`strlen`, `strcpy`, `strcmp`, ...), `'\0'` 'ı bulana kadar diziyi bayt bayt dolaşmalıdır, "bu dizgi ne kadar uzun?" diye sormayı bile her çağrıda sıfırdan yeniden hesaplanan bir $O(L)$ işlem yapar.

✓ 2. Bir arabelleğin kapasitesini ikiye katlamak (sabit bir miktarla büyütme yerine) neden amorti edilmiş $O(1)$ ekleme verir? ✓

Katlamayla, tüm büyümeler boyunca kopyalanan toplam bayt sayısı, son boyutla $(1 + 2 + 4 + \dots + n/2)$ sınırlı geometrik bir seri oluşturur — böylece n ekleme toplam $O(n)$ kopyalama işi yapar, ekleme başına amorti edilmiş $O(1)$. Bunun yerine sabit bir k büyümesi, n/k büyüme gerektirir, her biri n 'e kadar bayt kopyalar, herhangi bir sabit k için doğrusal değil karesel olan $O(n^2/k)$ toplam kopyalama verir.

✓ 3. Bir trie'de, gerçek kenarları izleyerek bir sorgu dizgisinin sonuna ulaşmak, kendi başına, sorgunun saklı bir sözcük olduğunun kanıtı neden değildir? ✓

Çünkü gerçek kenarları izlemek yalnız sorgunun trie'nin tuttuğu bir şeyin **öneki** olduğunu kanıtlar — trie o noktanın ötesinde daha uzun saklı bir sözcüğe doğru devam edebilir. Sorgu, yalnız ulaşılan *son* düğüm de açıkça `isEnd` olarak işaretliyse, önceden eklenmiş tam bir sözcüktür; bir düğüm hem daha uzun bir sözcüğün yolunda olabilir hem de aynı anda daha kısa bir sözcüğün sonu olabilir (`"CARD"` da saklıyken `"CAR"` 'in düğümünün olduğu gibi).

✓ 4. Sıkıştırılmış bir trie düz bir trie'ye göre özellikle neyi tasarruf eder, ve bu tasarruf en büyük olduğu koşul nedir? ✓

Her maksimal dallanmasız tek-çocuklu düğüm uzanımını, tüm alt-dizgiyi tutan tek bir kenara toplayarak **düğüm**leri (ve her düğümün maliyeti olan işaretçileri/belleği) tasarruf eder. Tasarruf, saklı başka herhangi bir şeyle az paylaşan uzun sözcükler için en büyüktür — düz bir trie, böyle bir sözcüğün tüm dallanmasız yolu boyunca karakter başına bir düğüme ihtiyaç duyarken, sıkıştırılmış bir trie tüm uzanım için yalnız bir yaprak düğüme ihtiyaç duyar.

✓ 5. Bir sıkıştırılmış trie'nin sıkıştırması, ikisi de bir ağacı küçültse de, Hafta 4'ün Huffman kodlamasından temelde nasıl farklıdır? ✓

Huffman kodlaması, simgeler üzerinde çarpık bir **olasılık dağılımını** sömürerek sıkıştırır — sık simgeler kısa kodlar alır (kısa kök-yaprak yolları), simgelerin gerçekte ne olduğundan bağımsız olarak. Sıkıştırılmış bir trie, **yapısal fazlalığı** ortadan kaldırarak sıkıştırır — yalnız bir çocuğu olan düğümlerin uzun zincirleri, herhangi bir belirli sözcüğün ne kadar sık geçtiğinden bağımsız olarak, tamamen saklanan gerçek karakter dizileriyle belirlenir. Biri sıklık odaklı bir sıkıştırma; diğeri şekil odaklı bir sıkıştırma.

✓ 6. Aynı metnin iki soneğini karşılaştırmak neden bağları çözmek için özel bir dizgi-sonu bitiş işaretine hiç ihtiyaç duymaz? ✓

Çünkü bir sonlu dizginin iki farklı soneği her zaman **farklı uzunluklara** sahiptir — bayt bayt özdeş olamazlar. Biri diğerinin öneki olduğunda, sıradan sözlük karşılaştırması zaten daha kısa olanı önce sıralar (tam olarak "CAR" 'ın bir sözlükte "CARD" 'dan önce sıralanması gibi), böylece hiçbir ekstra işaret olmadan karşılaştırma kuralının kendisi her sonek çiftini doğru ve tam olarak sıralar.

✓ 7. Saf aramanın $O(n*m)$ en kötü durumu, metin ve örüntü ne olursa olsun, KMP için neden imkansızdır? ✓

Saf aramanın en kötü durumu, farklı kaydırmalar arasında **aynı metin karakterlerini yeniden incelemekten** gelir — her yeni kaydırma sıfırdan karşılaştırmaya yeniden başlar. KMP'nin lps tablosu, metin işaretçisi i 'nin **asla geri gitmemesini** garanti eder, böylece her metin karakteri toplamda yalnız küçük, sınırlı bir sayıda karşılaştırılır, örüntünün içeriğinden bağımsız olarak — toplam iş $n + m$ 'e orantılıdır, hiçbir girdi için asla çarpımlarına değil.

✓ 8. Her Rabin-Karp hash eşleşmesi neden gerçek bir oluşum olarak bildirilmeden önce karakter karakter doğrulanmalıdır? ✓

Çünkü bir hash fonksiyonu, olası alt-dizgilerin çok daha büyük uzayını mod olası değerden oluşan küçük bir kümeye eşler — güvercin yuvası ilkesiyle, bir hash değerini paylaşan farklı alt-dizgiler (bir çakışma) bazı girdiler için kodlanarak kaçınılacak bir hata değil, matematiksel bir kesinliktir. Gerçek bir eşleşmeyi tesadüfi bir hash çakışmasından ("sahte isabet") ayırt etmenin tek yolu gerçek karakterleri karşılaştırmaktır.

✓ **9. Dinamik programlamayı düzenleme uzaklığının saf özyinelemeli tanımından daha hızlı yapan temel fikir nedir, ve bir problemin uygulanabilmesi için ihtiyaç duyduğu iki özellik nedir?** ✓

Temel fikir: her ayrılt alt problemi tam olarak **bir kez** çözün, cevabını saklayın, ve tekrar ettiğinde yeniden hesaplamak yerine bakın. **Optimal alt yapı** gerektirir (tüm problemin en iyi cevabı, alt problemlerin en iyi cevaplarından kurulu, bu da özyinelemeli tanımı başlangıçta doğru yapar) ve **çakışan alt problemler** (aynı alt problem gerçekten farklı yollarla birçok kez tekrar eder, bu da ezberlemeyi hiçbir şey yerine gerçekten iş kazandıran bir şey yapar).

✓ **10. Düzenleme uzaklığı ve en uzun ortak alt dizi, aynı tablo şeklini kullanır. Aralarındaki tek gerçek fark nedir, ve bu, min+1'i neden max'a çevirir?** ✓

Düzenleme uzaklığı bir **maliyeti** sayar — her eşleşmeyen adım ödenmesi gereken bir düzenlemedir, böylece yineleme *en ucuz* komşuyu alır ve 1 ekler. LCS, paylaşılan karakterlerin bir **uzunluğunu** sayar — eşleşmeyen bir adım hiçbir şeye mal olmaz ve basitçe hangi komşu zaten *daha uzun* paylaşılan alt diziye ulaştıysa onu ileriye taşır, bu yüzden yineleme komşuların **maksimumunu** alır, ve +1 yalnız gerçek bir karakter eşleşmesinde olur, asla düz bir uyumsuzluk cezası olarak değil.

İleriye bakış

Hafta 13 ve 14, dersin sınav haftası politikasına göre, proje gösterimlerine ve ikinci bir sınava dönmeden önce yeni malzemeye devam ediyor. Burada düzenleme uzaklığı ve en uzun ortak alt dizi üzerinden tanıtilan dinamik programlama stratejisi dizgilere özgü değildir — aynı "çakışan alt problemlerin tablosu, bir kez doldurulur, geriye yürümeyle okunur" örüntüsü, bir problem kendisinin daha küçük sürümlerine bölünebildiğinde ve cevapları yeniden kullanılabildiğinde algoritma tasarımı boyunca tekrar tekrar karşınıza çıkar, bu yüzden bu haftanın `dp[i][j]` tablo şeklini yeniden tanıyacağınız bir şablon olarak aklınızda tutun.

Kaynaklar

- Ders izlencesi, Hafta 12: `CEN207-2026-2027-Guz-Izlence.tr.md`.
- T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein. *Introduction to Algorithms*. MIT Press — dizgi eşleştirme (saf arama, Rabin-Karp, KMP) ve dinamik programlama (çalışılmış örnekler olarak düzenleme uzaklığı ve en uzun ortak alt dizi) bölümleri, 3. ya da 4. baskıda.
- D. E. Knuth, J. H. Morris, V. R. Pratt, "Fast Pattern Matching in Strings," *SIAM Journal on Computing*, 6(2), 1977 — özgün KMP makalesi.
- R. S. Boyer, J S. Moore, "A Fast String Searching Algorithm," *Communications of the ACM*, 20(10), 1977 — özgün Boyer-Moore makalesi.
- R. M. Karp, M. O. Rabin, "Efficient Randomized Pattern-Matching Algorithms," *IBM Journal of Research and Development*, 31(2), 1987 — özgün Rabin-Karp makalesi.
- E. Fredkin, "Trie Memory," *Communications of the ACM*, 3(9), 1960 — özgün trie makalesi.
- D. R. Morrison, "PATRICIA — Practical Algorithm To Retrieve Information Coded In Alphanumeric," *Journal of the ACM*, 15(4), 1968 — klasik sıkıştırılmış trie / radix ağacı.
- V. I. Levenshtein, "Binary Codes Capable of Correcting Deletions, Insertions, and Reversals," *Soviet Physics Doklady*, 10(8), 1966 (Rusça özgünü 1965) — düzenleme uzaklığının kökeni.

- R. Sedgewick, K. Wayne. *Algorithms*, 4. baskı. Addison-Wesley, 2011 — Dizgiler bölümü (trie'ler, alt-dizgi arama, KMP, Boyer-Moore, Rabin-Karp).
- williamfiset/Algorithms (<https://github.com/williamfiset/Algorithms>, MIT Lisansı) — trie, KMP, ve dinamik programlama algoritmalarının Java referans uygulamaları.
- Programiz DSA (<https://www.programiz.com/dsa>) — trie'lere, KMP algoritmasına, ve dinamik programlamaya adım adım girişler.